Α Ρ Ι Σ Τ Ο Τ Ε Λ Ε Ι Ο Π Α Ν Ε Π Ι Σ Τ Η Μ Ι Ο
Θ Ε Σ Σ Α Λ Ο Ν Ι Κ Η Σ
ΣΧΟΛΗ ΘΕΤΙΚΩΝ ΕΠΙΣΤΗΜΩΝ
ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Π Τ Υ Χ Ι Α Κ Η Ε Ρ Γ Α Σ Ι Α

«ΑΝΑΠΤΥΞΗ ΣΥΣΤΗΜΑΤΟΣ ΛΗΨΗΣ ΚΛΙΝΙΚΗΣ ΑΠΟΦΑΣΗΣ ΓΙΑ ΤΗΝ ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ»

DEVELOPMENT OF A CLINICAL DECISION - SUPPORT SYSTEM FOR THE PREDICTION OF PRETERM BIRTH

ΕΛΕΝΗ ΜΠΟΥΣΙΟΥ
ΑΕΜ: 4154

ΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ:
Βασιλειάδης Νικόλαος, Καθηγητής

ΣΥΝΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ:
Παναγιώτης Μπαμίδης, Καθηγητής

ΘΕΣΣΑΛΟΝΙΚΗ ΙΟΥΝΙΟΣ 2025

ΠΕΡΙΛΗΨΗ

Το αντικείμενο της παρούσας εργασίας είναι η πρόβλεψη του πρόωρου τοκετού με χρήση μηχανικής μάθησης. Ο πρόωρος τοκετός ορίζεται ως ο τοκετός που συμβαίνει πριν από την 37η εβδομάδα κύησης και αποτελεί μία από τις σημαντικότερες αιτίες νεογνικής νοσηρότητας και θνησιμότητας. Οι αιτίες που τον προκαλούν είναι ποικίλες και σχετίζονται με την υγεία της μητέρας, του εμβρύου και άλλους παράγοντες ιατρικής, κοινωνικοοικονομικής και περιβαλλοντικής προέλευσης. Είναι αναγκαία λοιπόν η έγκαιρη αναγνώριση του κινδύνου πρόωρου τοκετού ώστε να δοθεί η απαραίτητη φροντίδα ή ακόμη και να αποφευχθεί αν είναι δυνατόν.

Στην εργασία αυτή, εξετάζεται η πρόβλεψη του πρόωρου τοκετού μέσω αλγορίθμων μηχανικής μάθησης. Το διαθέσιμο σύνολο δεδομένων αποτελούνταν από 973 έγκυες που συλλέχθηκαν από το Γενικό Νοσοκομείο Θεσσαλονίκης «Ιπποκράτειο» και περιλάμβανε κλινικές και δημογραφικές μεταβλητές, όπως ηλικία, ύψος, βάρος, BMI, συνήθειες καπνίσματος, καθώς και στοιχεία από το ιατρικό ιστορικό και την πορεία της κύησης. Αφού έγινε έλεγχος για ύπαρξη μεροληψίας στο σύνολο δεδομένων, πραγματοποιήθηκε καθαρισμός των δεδομένων ώστε η μελέτη να υλοποιηθεί σε αμερόληπτο σύνολο δεδομένων.

Στη συνέχεια, το πρόβλημα της πρόβλεψης προσεγγίστηκε από διάφορες οπτικές. Αρχικά επιχειρήθηκε η πρόβλεψη του πρόωρου τοκετού ως πρόβλημα δυαδικής ταξινόμησης και έπειτα ως πρόβλημα παλινδρόμησης με προσπάθεια εντοπισμού της συγκεκριμένης εβδομάδας που θα συμβεί ο τοκετός. Μάλιστα, η πρόβλεψη υλοποιήθηκε εκ νέου με στρογγυλοποίηση της εβδομάδας τοκετού σε ακέραιο αριθμό, προκειμένου να γίνει καταλληλότερο για κλινική χρήση το αποτέλεσμά της. Ακολούθησε πρόβλεψη του μήνα τοκετού με σκοπό την απλοποίηση της διαδικασίας. Τέλος, δοκιμάστηκε πρόβλεψη του τοκετού με κατηγορίες σε διαστήματα δύο εβδομάδων.

Η αξιολόγηση της απόδοσης του κάθε μοντέλου έγινε με χρήση των μετρικών ταξινόμησης Ακρίβεια (Accuracy), Ακρίβεια Πρόβλεψης (Precision), Ανάκληση (Recall) και F1-score και αντίστοιχα των μετρικών παλινδρόμησης Συντελεστής Προσδιορισμού (R^2 score), Μέσο Απόλυτο Σφάλμα (MAE), Μέσο Τετραγωνικό Σφάλμα (MSE) και Τετραγωνική Ρίζα Μέσου Τετραγωνικού Σφάλματος (RMSE).

Από τις διάφορες προσεγγίσεις που εφαρμόστηκαν, έγινε φανερό ότι οι καλύτεροι αλγόριθμοι για την πρόβλεψη τοκετού εξαρτώνται από τον τύπο του προβλήματος. Πιο συγκεκριμένα, για δυαδική ταξινόμηση, ξεχωρίζουν ο Optimized Voting και η Logistic Regression με υψηλό F1 score (0.91) και ROC-AUC (0.98). Στην παλινδρόμηση για την πρόβλεψη εβδομάδας τοκετού, οι Bagging και Random Forest Regressor έχουν την καλύτερη απόδοση με R^2 στο 0.76 και χαμηλό σφάλμα (0.9). Στην πρόβλεψη μήνα τοκετού, ο XGBoost δίνει τα καλύτερα αποτελέσματα με ακρίβεια μέχρι και 0.86 και F1 κοντά στο 0.81. Τέλος, στην ταξινόμηση εβδομάδας τοκετού σε ομάδες, πάλι ο XGBoost και ο Optimized Voting ξεχωρίζουν με τις υψηλότερες επιδόσεις.

Έτσι, τα αποτελέσματα που προέκυψαν δείχνουν ότι η χρήση της μηχανικής μάθησης μπορεί να συμβάλλει σημαντικά στην έγκαιρη πρόβλεψη του πρόωρου τοκετού, καθώς και να αποτελέσει τη βάση για μελλοντική ανάπτυξη ενός συστήματος λήψης κλινικής απόφασης πρόβλεψης πρόωρου τοκετού.

ABSTRACT

The subject of this thesis is the prediction of preterm birth using machine learning. Preterm birth is defined as birth that occurs before the 37th week of gestation and is one of the most important causes of neonatal morbidity and mortality. The causes that cause it are varied and are related to the health of the mother, the fetus and other factors of medical, socioeconomic and environmental origin. It is therefore necessary to identify the risk of preterm birth early in order to provide the necessary care or even to avoid it if possible.

In this work, the prediction of preterm birth through machine learning algorithms is examined. The available dataset consisted of 973 pregnant women collected from the General Hospital of Thessaloniki "Ippokrateio" and included clinical and demographic variables, such as age, height, weight, BMI, smoking habits, as well as data from the medical history and the course of the pregnancy. After checking for bias in the dataset, the data were cleaned so that the study could be implemented in an unbiased dataset.

Subsequently, the prediction problem was approached from various perspectives. Initially, the prediction of preterm birth was attempted as a binary classification problem and then as a regression problem with an attempt to identify the specific week in which the birth will occur. In fact, the prediction was implemented again by rounding the week of delivery to an integer, in order to make its result more suitable for clinical use. This was followed by a prediction of the month of delivery in order to simplify the process. Finally, a prediction of delivery with categories in two-week intervals was tested.

The performance of each model was evaluated using the classification metrics Accuracy, Precision, Recall and F1-score and the regression metrics Coefficient of Determination (R^2 score), Mean Absolute Error (MAE), Mean Square Error (MSE) and Root Mean Square Error (RMSE).

From the various approaches that were applied, it became clear that the best algorithms for predicting delivery depend on the type of problem. More specifically, for binary classification, Optimized Voting and Logistic Regression stand out with a high F1 score (0.91) and ROC-AUC (0.98). In the regression for predicting the week of delivery, Bagging and Random Forest Regressor have the best performance with R^2 at 0.76 and low error (0.9). In predicting the month of delivery, XGBoost gives the best results with an accuracy of up to 0.86 and F1 close to 0.81. Finally, in classifying the week of delivery into groups, XGBoost and Optimized Voting again stand out with the highest performance.

Thus, the results obtained show that the use of machine learning can significantly contribute to the timely prediction of preterm birth, as well as form the basis for future development of a clinical decision-support system for predicting preterm birth.

ΕΥΧΑΡΙΣΤΙΕΣ

Πριν την παρουσίαση των αποτελεσμάτων της παρούσας εργασίας, αισθάνομαι την ανάγκη να ευχαριστήσω τον επιβλέποντα καθηγητή κ. Νικόλαο Βασιλειάδη για τα χρήσιμα σχόλιά του και τους μεταδιδακτορικούς ερευνητές Εμμανουήλ Ρήγα και Αντώνη Μπίλλη για την πολύτιμη καθοδήγηση και την καρποφόρα συνεργασία. Επίσης, θα ήθελα να ευχαριστήσω τον συνεπιβλέποντα καθηγητή κ. Παναγιώτη Μπαμίδη και τους καθηγητές γυναικολόγους Θεμιστοκλή Δαγκλή και Ιωάννη Τσακιρίδη που παρείχαν τα δεδομένα και την επιστημονική περιγραφή του προβλήματος. Τέλος, ιδιαίτερα ευχαριστώ οφείλω στην οικογένειά μου, τους γονείς μου και τις αδελφές μου, για τη στήριξή τους όλα αυτά τα χρόνια και για την ενθάρρυνση στις δύσκολες στιγμές.

23/06/2025

Ελένη Μπούσιου

ΠΕΡΙΕΧΟΜΕΝΑ

ΠΕΡΙΛΗΨΗ ..... **VII**

ABSTRACT ..... **IX**

ΕΥΧΑΡΙΣΤΙΕΣ ..... **XI**

ΠΕΡΙΕΧΟΜΕΝΑ ..... **XIII**

ΛΙΣΤΑ ΣΧΗΜΑΤΩΝ ..... **XV**

ΛΙΣΤΑ ΠΙΝΑΚΩΝ ..... **XVII**

ΛΙΣΤΑ ΕΞΙΣΩΣΕΩΝ ..... **XVIII**

ΚΕΦΑΛΑΙΟ 1: ΕΙΣΑΓΩΓΗ **19**

1.1 ΠΡΟΩΡΟΣ ΤΟΚΕΤΟΣ **21**
1.2 ΑΝΑΓΚΑΙΟΤΗΤΑ ΠΡΟΒΛΕΨΗΣ **21**
1.3 ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ ΚΑΙ ΙΑΤΡΙΚΗ **21**
1.4 ΣΚΟΠΟΣ ΤΗΣ ΕΡΓΑΣΙΑΣ **22**
1.5 ΜΕΘΟΔΟΛΟΓΙΑ **22**
1.6 ΔΟΜΗ ΤΗΣ ΕΡΓΑΣΙΑΣ **22**

ΚΕΦΑΛΑΙΟ 2: ΒΙΒΛΙΟΓΡΑΦΙΚΗ ΑΝΑΣΚΟΠΗΣΗ **25**

2.1 ΜΕΛΕΤΕΣ ΜΕ ΚΛΙΝΙΚΑ ΚΑΙ ΙΑΤΡΙΚΑ ΧΑΡΑΚΤΗΡΙΣΤΙΚΑ ΩΣ ΠΡΟΓΝΩΣΤΙΚΟΙ ΠΑΡΑΓΟΝΤΕΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ **27**
2.2 ΜΕΛΕΤΕΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ ΜΕ ΒΑΣΗ ΜΕΓΑΛΑ ΔΕΔΟΜΕΝΑ ΚΑΙ ΠΡΟΗΓΜΕΝΟΥΣ ΑΛΓΟΡΙΘΜΟΥΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ **28**
2.3 ΕΞΕΙΔΙΚΕΥΜΕΝΕΣ ΕΦΑΡΜΟΓΕΣ ΚΑΙ ΘΕΩΡΗΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΣΤΗΝ ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ **30**
2.4 ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ ΜΕ ΒΑΣΗ ΤΗΝ ΗΛΕΚΤΡΟΜΗΤΡΙΚΗ ΚΑΤΑΓΡΑΦΗ (EHG) **31**
2.5 ΚΑΙΝΟΤΟΜΙΕΣ ΠΑΡΟΥΣΑΣ ΠΤΥΧΙΑΚΗΣ **32**

ΚΕΦΑΛΑΙΟ 3: ΈΛΕΓΧΟΣ ΚΑΙ ΑΠΑΛΟΙΦΗ ΠΡΟΚΑΤΑΛΗΨΗΣ ΣΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ **33**

3.1 ΠΕΡΙΓΡΑΦΗ ΣΥΝΟΛΟΥ ΔΕΔΟΜΕΝΩΝ **35**

3.2 ΈΛΕΓΧΟΣ BIAS ΣΤΟ DATASET 38
3.3 SAMPLING BIAS 41
3.4 ΔΗΜΙΟΥΡΓΙΑ ΑΝΑΝΕΩΜΕΝΟΥ DATASET 44

ΚΕΦΑΛΑΙΟ 4: ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ 47

4.1 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ 49
4.2 ΑΛΓΟΡΙΘΜΟΙ ΠΡΟΒΛΕΨΗΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ 50
4.3 ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ ΑΠΟΔΟΣΗΣ ΜΟΝΤΕΛΩΝ 57
4.4 ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΓΚΡΙΣΗ ΜΟΝΤΕΛΩΝ 58
4.5 ΣΥΓΚΡΙΣΗ ΜΕ ΠΡΟΗΓΟΥΜΕΝΗ ΑΝΑΛΥΣΗ ΚΑΙ ΈΛΕΓΧΟΣ ΣΤΑΤΙΣΤΙΚΗΣ ΣΗΜΑΝΤΙΚΟΤΗΤΑΣ 61

ΚΕΦΑΛΑΙΟ 5: ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 65

5.1 ΣΗΜΑΣΙΑ ΚΑΙ ΑΝΑΓΚΑΙΟΤΗΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 67
5.2 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΚΑΙ ΔΙΑΣΤΑΥΡΟΥΜΕΝΗ ΕΠΙΚΥΡΩΣΗ 67
5.3 ΜΟΝΤΕΛΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 68
5.4 ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ΥΠΕΡΠΑΡΑΜΕΤΡΩΝ ΜΕ GRID SEARCH CV 76
5.5 ΑΞΙΟΛΟΓΗΣΗ ΜΟΝΤΕΛΩΝ 82
5.6 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΕΩΝ 83
5.6.1 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 83
5.6.2 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 84
5.6.3 ΣΥΓΚΡΙΣΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΠΡΙΝ ΚΑΙ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 86
5.7 ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ 86
5.8 ΣΥΓΚΡΙΣΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΠΡΑΓΜΑΤΙΚΗ ΚΑΙ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ 90
5.9 ΕΝΑΛΛΑΚΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 92
5.9.1 ΠΡΟΒΛΕΨΗ ΜΗΝΑ ΤΟΚΕΤΟΥ (ΟΜΑΔΟΠΟΙΗΣΗ ΚΑΤΑ ΜΗΝΑ) 92
5.9.2 ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΣΕ ΔΙΑΣΤΗΜΑΤΑ ΔΥΟ ΕΒΔΟΜΑΔΩΝ 95

ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ 103

ΚΕΦΑΛΑΙΟ 7: ΕΠΙΛΟΓΟΣ ΚΑΙ ΜΕΛΛΟΝΤΙΚΗ ΔΟΥΛΕΙΑ 106

ΠΑΡΑΡΤΗΜΑ Ι:ΑΝΑΦΟΡΕΣ 108

ΛΙΣΤΑ ΣΧΗΜΑΤΩΝ

ΕΙΚΟΝΑ 1: ΔΙΑΔΙΚΑΣΙΑ ΑΠΟΣΥΜΠΙΕΣΗΣ ΤΟΥ DATASET 45
ΕΙΚΟΝΑ 2: ΑΠΟΤΕΛΕΣΜΑΤΑ ΕΝΤΟΛΗΣ DF.HEAD() 45
ΕΙΚΟΝΑ 3: ΚΑΘΑΡΙΣΜΟΣ ΔΕΔΟΜΕΝΩΝ 49
ΕΙΚΟΝΑ 4: ΕΥΡΕΣΗ ΣΗΜΑΝΤΙΚΟΤΕΡΟΥ ΧΑΡΑΚΤΗΡΙΣΤΙΚΟΥ ΣΤΗΝ ΔΙΑΔΙΚΑΣΙΑ ΠΡΟΒΛΕΨΗΣ 49
ΕΙΚΟΝΑ 5: ΕΚΠΑΙΔΕΥΣΗ, ΕΣΩΤΕΡΙΚΗ ΕΠΙΚΥΡΩΣΗ ΚΑΙ ΕΞΙΣΟΡΡΟΠΗΣΗ ΔΕΔΟΜΕΝΩΝ 50
ΕΙΚΟΝΑ 6: ΥΛΟΠΟΙΗΣΗ RANDOM FOREST 51
ΕΙΚΟΝΑ 7: ΥΛΟΠΟΙΗΣΗ SVM 51
ΕΙΚΟΝΑ 8: ΥΛΟΠΟΙΗΣΗ LOGISTIC REGRESSION 52
ΕΙΚΟΝΑ 9: ΥΛΟΠΟΙΗΣΗ KNN 53
ΕΙΚΟΝΑ 10: ΥΛΟΠΟΙΗΣΗ DECISION TREE 53
ΕΙΚΟΝΑ 11: ΥΛΟΠΟΙΗΣΗ GRADIENT BOOSTING 54
ΕΙΚΟΝΑ 12: ΥΛΟΠΟΙΗΣΗ ADABOOST 54
ΕΙΚΟΝΑ 13: ΥΛΟΠΟΙΗΣΗ XGBOOST 55
ΕΙΚΟΝΑ 14: ΥΛΟΠΟΙΗΣΗ NAIVE BAYES 55
ΕΙΚΟΝΑ 15: ΥΛΟΠΟΙΗΣΗ BAGGING 56
ΕΙΚΟΝΑ 16: ΥΛΟΠΟΙΗΣΗ OPTIMIZED VOTING 57
ΕΙΚΟΝΑ 17: ΚΑΜΠΥΛΕΣ ROC 60
ΕΙΚΟΝΑ 18: ΚΑΜΠΥΛΕΣ PR 61
ΕΙΚΟΝΑ 19: ΈΛΕΓΧΟΣ ΓΙΑ ΣΤΑΤΙΣΤΙΚΑ ΣΗΜΑΝΤΙΚΗ ΔΙΑΦΟΡΑ ΜΕΤΑΞΥ ΤΩΝ ΜΕΤΡΙΚΩΝ 63
ΕΙΚΟΝΑ 20: ΚΑΘΑΡΙΣΜΟΣ ΚΑΙ ΕΚΠΑΙΔΕΥΣΗ ΔΕΔΟΜΕΝΩΝ 67
ΕΙΚΟΝΑ 21: 10-FOLD CROSS-VALIDATION 68
ΕΙΚΟΝΑ 22: ΥΛΟΠΟΙΗΣΗ RANDOM FOREST REGRESSOR 68
ΕΙΚΟΝΑ 23: ΥΛΟΠΟΙΗΣΗ SVR 69
ΕΙΚΟΝΑ 24: ΥΛΟΠΟΙΗΣΗ LINEAR REGRESSION 70
ΕΙΚΟΝΑ 25: ΥΛΟΠΟΙΗΣΗ K-NEIGHBORS REGRESSOR 71
ΕΙΚΟΝΑ 26: ΥΛΟΠΟΙΗΣΗ DECISION TREE REGRESSOR 72
ΕΙΚΟΝΑ 27: ΥΛΟΠΟΙΗΣΗ GRADIENT BOOSTING REGRESSOR 73
ΕΙΚΟΝΑ 28: ΥΛΟΠΟΙΗΣΗ ADABOOST REGRESSOR 74
ΕΙΚΟΝΑ 29: ΥΛΟΠΟΙΗΣΗ XGBOOST REGRESSOR 75
ΕΙΚΟΝΑ 30: ΥΛΟΠΟΙΗΣΗ BAGGING REGRESSOR 75
ΕΙΚΟΝΑ 31: ΥΛΟΠΟΙΗΣΗ VOTING REGRESSOR 76
ΕΙΚΟΝΑ 32: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ RANDOM FOREST REGRESSOR 77
ΕΙΚΟΝΑ 33: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ SVR 77
ΕΙΚΟΝΑ 34: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ LINEAR REGRESSION 78
ΕΙΚΟΝΑ 35: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ K-NEIGHBORS REGRESSOR 78
ΕΙΚΟΝΑ 36: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ DECISION TREE REGRESSOR 79
ΕΙΚΟΝΑ 37: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ GRADIENT BOOSTING REGRESSOR 79
ΕΙΚΟΝΑ 38: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ADABOOST REGRESSOR 80
ΕΙΚΟΝΑ 39: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ XGB REGRESSOR 81
ΕΙΚΟΝΑ 40: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ BAGGING REGRESSOR 81
ΕΙΚΟΝΑ 41: ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ VOTING REGRESSOR 82
ΕΙΚΟΝΑ 42: ΜΕΤΑΤΡΟΠΗ ΤΗΣ GA ΣΕ ΑΚΕΡΑΙΑ ΤΙΜΗ 87
ΕΙΚΟΝΑ 43: ΔΗΜΙΟΥΡΓΙΑ ΚΑΤΗΓΟΡΙΚΗΣ ΜΕΤΑΒΛΗΤΗΣ «ΜΗΝΑΣ ΤΟΚΕΤΟΥ» (MONTH_BIRTH) ΒΑΣΕΙ ΤΗΣ GA 92
ΕΙΚΟΝΑ 44: ΔΗΜΙΟΥΡΓΙΑ ΚΑΤΗΓΟΡΙΚΗΣ ΜΕΤΑΒΛΗΤΗΣ «GA_BIN» ΒΑΣΕΙ ΤΗΣ GA 96

ΛΙΣΤΑ ΠΙΝΑΚΩΝ

ΠΙΝΑΚΑΣ 1: ΤΙΜΕΣ DI ΚΑΙ SPD 40
ΠΙΝΑΚΑΣ 2: ΈΛΕΓΧΟΣ BIAS ΣΤΗΝ ΜΕΤΑΒΛΗΤΗ MATERNAL AGE 42
ΠΙΝΑΚΑΣ 3: ΈΛΕΓΧΟΣ BIAS ΣΤΗΝ ΜΕΤΑΒΛΗΤΗ SMOKING 43
ΠΙΝΑΚΑΣ 4: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ 58
ΠΙΝΑΚΑΣ 5: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ ΣΤΟ ΑΡΧΙΚΟ DATASET [5] 61
ΠΙΝΑΚΑΣ 6: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ 83
ΠΙΝΑΚΑΣ 7: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 84
ΠΙΝΑΚΑΣ 8: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ 87
ΠΙΝΑΚΑΣ 9: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 88
ΠΙΝΑΚΑΣ 10: ΣΥΓΚΡΙΣΗ ΑΠΟΔΟΣΗΣ ΜΟΝΤΕΛΩΝ ΜΕ GA ΩΣ ΔΕΚΑΔΙΚΗ ΚΑΙ ΑΚΕΡΑΙΗ ΤΙΜΗ (ΧΩΡΙΣ GRID SEARCH CV) 90
ΠΙΝΑΚΑΣ 11: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΜΗΝΑ ΤΟΚΕΤΟΥ 93
ΠΙΝΑΚΑΣ 12: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΜΗΝΑ ΤΟΚΕΤΟΥ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 94
ΠΙΝΑΚΑΣ 13: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΣΕ ΔΙΑΣΤΗΜΑΤΑ ΔΥΟ ΕΒΔΟΜΑΔΩΝ 96
ΠΙΝΑΚΑΣ 14: ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΣΕ ΔΙΑΣΤΗΜΑΤΑ ΔΥΟ ΕΒΔΟΜΑΔΩΝ ΜΕΤΑ ΤΗΝ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ 99

ΛΙΣΤΑ ΕΞΙΣΩΣΕΩΝ

ΕΞΙΣΩΣΗ 1: ΤΥΠΟΣ DI 39
ΕΞΙΣΩΣΗ 2: ΤΥΠΟΣ SPD..... 40

ΚΕΦΑΛΑΙΟ 1: ΕΙΣΑΓΩΓΗ

ΕΙΣΑΓΩΓΗ

1.1 ΠΡΟΩΡΟΣ ΤΟΚΕΤΟΣ

Ο πρόωρος τοκετός ορίζεται ως ο τοκετός πριν από την συμπλήρωση της 37ης εβδομάδας κύησης. Η συχνότητα του πρόωρου τοκετού ανέρχεται σε περίπου 10% των συνολικών κυήσεων και δυστυχώς το ποσοστό αυτό δεν έχει μειωθεί σημαντικά τα τελευταία χρόνια [1]. Μάλιστα είναι μία αρκετά σοβαρή επιπλοκή που έχει άμεση συσχέτιση με τα αυξημένα ποσοστά νεογνικής νοσηρότητας αλλά και θνησιμότητας.

Οι αιτίες που μπορούν να τον προκαλέσουν σχετίζονται με την υγεία της μητέρας, του εμβρύου, το ιστορικό εγκυμοσύνης, γενετικούς και περιβαλλοντικούς παράγοντες, κοινωνικοοικονομικές συνθήκες, ακόμη και το επίπεδο μόρφωσης της μητέρας [2].

1.2 ΑΝΑΓΚΑΙΟΤΗΤΑ ΠΡΟΒΛΕΨΗΣ

Η πρόβλεψη του πρόωρου τοκετού κρίνεται αναγκαία καθώς αυτός μπορεί να επιφέρει πολλές επιπτώσεις στην υγεία και μετέπειτα ανάπτυξη του εμβρύου αλλά και στην υγεία της μητέρας.

Μία τέτοια πρόβλεψη είναι ιδιαίτερα κρίσιμη σε περιπτώσεις πρόωρου τοκετού όπου κατάλληλη φαρμακευτική αγωγή πρέπει να δοθεί εγκαίρως για να αποτραπεί αυτή η εξέλιξη. Μάλιστα, η δυνατότητα πρόβλεψης της εβδομάδας τοκετού είναι ιδιαίτερα χρήσιμη για γυναίκες που ζουν σε απομακρυσμένες περιοχές και δεν έχουν άμεση πρόσβαση σε νοσοκομειακές μονάδες. Δηλαδή η έγκαιρη αναγνώριση των γυναικών που διατρέχουν αυξημένο κίνδυνο πρόωρου τοκετού επιτρέπει την εφαρμογή προληπτικών παρεμβάσεων, την καλύτερη προετοιμασία του ιατρικού προσωπικού, την ετοιμότητα και, σε πολλές περιπτώσεις, τη λήψη μέτρων για την επιβράδυνση ή ακόμη και την αποφυγή του.

Έτσι, η ανάπτυξη αξιόπιστων μεθόδων πρόβλεψης πέρα από ιατρικά αναγκαία είναι και κοινωνικοοικονομικά επιθυμητή.

1.3 ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ ΚΑΙ ΙΑΤΡΙΚΗ

Η μηχανική μάθηση αποτελεί έναν εξελισσόμενο κλάδο της τεχνητής νοημοσύνης και επικεντρώνεται στην ανάπτυξη υπολογιστικών αλγορίθμων που «μαθαίνουν» από δεδομένα και προσαρμόζονται σε νέα σενάρια χωρίς ρητό προγραμματισμό [3].

Η ιατρική επιστήμη παράγει καθημερινά τεράστιο όγκο δεδομένων, προερχόμενων από ηλεκτρονικούς ιατρικούς φακέλους, απεικονιστικές εξετάσεις και κλινικές μελέτες. Η μηχανική μάθηση προσφέρει σημαντικές δυνατότητες αξιοποίησης αυτών των δεδομένων, με στόχο την ανάπτυξη διαγνωστικών και προγνωστικών μοντέλων, τα οποία συχνά υπερβαίνουν τις δυνατότητες του ανθρώπινου νου

Μέσω αυτών των εφαρμογών, η μηχανική μάθηση μπορεί να συμβάλει ουσιαστικά στην εξέλιξη της ιατρικής φροντίδας και στην υποστήριξη της λήψης κλινικών αποφάσεων, ενισχύοντας την ακρίβεια, την ταχύτητα και την πρόληψη σε κρίσιμα ιατρικά σενάρια.

1.4 ΣΚΟΠΟΣ ΤΗΣ ΕΡΓΑΣΙΑΣ

Σκοπός της παρούσας εργασίας είναι η διερεύνηση της δυνατότητας χρήσης αλγορίθμων μηχανικής μάθησης για την πρόβλεψη πρόωρου τοκετού.

Μέσω της χρήσης σύγχρονων αλγορίθμων μηχανικής μάθησης, η εργασία αποσκοπεί στη δημιουργία εργαλείων που θα μπορούσαν να ενσωματωθούν στον προγεννητικό έλεγχο, προσφέροντας μία πιο ολοκληρωμένη εικόνα της πορείας της κύησης.

Ιδιαίτερη έμφαση δίνεται στη διαδικασία απομεροληψίας του συνόλου δεδομένων (debias), ώστε να βελτιωθεί η αξιοπιστία των προβλέψεων. Με αυτόν τον τρόπο, επιδιώκεται η ενίσχυση της εμπιστοσύνης των ιατρών στο σύστημα υποστήριξης λήψης αποφάσεων, συμβάλλοντας στην υιοθέτηση ενός trustworthy AI [4]. Πρόκειται για ένα σύστημα τεχνητής νοημοσύνης που είναι εξηγήσιμο, διαφανές, δίκαιο, αξιόπιστο και ασφαλές. Αυτή η προσέγγιση που ακολουθήθηκε είναι σύμφωνη με νέες οδηγίες για την αξιοποίηση της ΤΝ στην υγεία.

1.5 ΜΕΘΟΔΟΛΟΓΙΑ

Η μεθοδολογία που ακολουθήθηκε στην παρούσα εργασία είναι η εξής:

→ Καθαρισμός, απομεροληψία (debias) του υπάρχοντος συνόλου δεδομένων και δημιουργία νέου: Τυχαία αφαίρεση δειγμάτων που προκαλούσαν μεροληψία στο σύνολο δεδομένων για τη βελτίωση της ακρίβειας στα αποτελέσματα.

→ Εκπαίδευση του συνόλου δεδομένων, Εσωτερική Επικύρωση: Διαχωρισμός των δεδομένων σε σύνολα εκπαίδευσης και επικύρωσης για αξιολόγηση της απόδοσης..

→ Τεχνική εξισορρόπησης (SMOTE): Εφαρμογή για αντιμετώπιση της ανισορροπίας μεταξύ των κλάσεων.

→ Διασταυρούμενη Επικύρωση (10-fold cross-validation): Χωρισμός των δεδομένων σε 10 τμήματα ώστε κάθε τμήμα να χρησιμοποιείται εναλλάξ για επικύρωση, εξασφαλίζοντας πιο αξιόπιστη αξιολόγηση.

→ Εφαρμογή μοντέλων Μηχανικής Μάθησης: Δοκιμή διαφορετικών αλγορίθμων για την επίλυση του προβλήματος.

→ Αξιολόγηση και Σύγκριση αποτελεσμάτων: Ανάλυση των επιδόσεων του κάθε αλγορίθμου και αξιολόγηση με βάση κατάλληλες μετρικές.

→ Συμπεράσματα: Παρουσίαση των αποτελεσμάτων που προέκυψαν από την εφαρμογή στους επιλεγμένους αλγορίθμους.

1.6 ΔΟΜΗ ΤΗΣ ΕΡΓΑΣΙΑΣ

Η εργασία δομείται σε κεφάλαια ως εξής:

- Στο Κεφάλαιο 2 υπάρχει η σχετική βιβλιογραφία βάσει της οποίας έγινε η συγγραφή της εργασίας.
- Στο Κεφάλαιο 3 περιγράφονται οι μεταβλητές του συνόλου δεδομένων που χρησιμοποιήθηκε για την πρόβλεψη του πρόωρου τοκετού καθώς και η διαδικασία απομεροληψίας του υπάρχοντος συνόλου δεδομένων και η δημιουργία ενός νέου αμερόληπτου.
- Στο Κεφάλαιο 4 αναλύεται η διαδικασία πρόβλεψης πρόωρου τοκετού μέσω αλγορίθμων μηχανικής μάθησης, παρουσιάζονται τα αποτελέσματα και συγκρίνονται με αυτά προηγούμενης ανάλυσης επί του μεροληπτικού συνόλου δεδομένων.
- Στο Κεφάλαιο 5 υλοποιείται η πρόβλεψη της εβδομάδας τοκετού με διαφορετικές προσεγγίσεις (π.χ. παλινδρόμηση, κατηγοριοποίηση) και συγκρίνονται τα αποτελέσματα που προέκυψαν.
- Στο Κεφάλαιο 6 γίνεται ανακεφαλαίωση και εξάγονται τα συμπεράσματα που προέκυψαν από την εφαρμογή των αλγορίθμων μηχανικής μάθησης.
- Στο Κεφάλαιο 7 συνοψίζεται η χρησιμότητα της μηχανικής μάθησης για την πρόβλεψη πρόωρου τοκετού και προτείνονται επεκτάσεις της μελέτης που προηγήθηκε.
- Στο Παράρτημα Ι παρουσιάζεται η βιβλιογραφία που αξιοποιήθηκε κατά την συγγραφή της παρούσας εργασίας.

ΚΕΦΑΛΑΙΟ 2: ΒΙΒΛΙΟΓΡΑΦΙΚΗ ΑΝΑΣΚΟΠΗΣΗ

ΒΙΒΛΙΟΓΡΑΦΙΚΗ ΑΝΑΣΚΟΠΗΣΗ

Οι περισσότερες μελέτες που έχουν γίνει σχετικά με τον πρόωρο τοκετό βασίζονται σε διαφορετικά σύνολα δεδομένων που περιλαμβάνουν δημογραφικά στοιχεία, ιατρικό ιστορικό των εγκύων και παραμέτρους μαιευτικές. Έχουν εφαρμοστεί πολλοί αλγόριθμοι μηχανικής μάθησης σε προηγούμενες μελέτες για την πρόβλεψη του πρόωρου τοκετού, με απώτερο σκοπό την βέλτιστη ακρίβεια και αξιοπιστία του αποτελέσματος, όπως έγινε φανερό με τη χρήση διαφόρων μετρικών ταξινόμησης. Παρακάτω παρουσιάζονται μερικές από αυτές και αναλύονται το σύνολο δεδομένων που αξιοποίησαν, η προεπεξεργασία που δέχτηκε αυτό, οι αλγόριθμοι που εφαρμόστηκαν και τα αποτελέσματα που πέτυχαν.

2.1 ΜΕΛΕΤΕΣ ΜΕ ΚΛΙΝΙΚΑ ΚΑΙ ΙΑΤΡΙΚΑ ΧΑΡΑΚΤΗΡΙΣΤΙΚΑ ΩΣ ΠΡΟΓΝΩΣΤΙΚΟΙ ΠΑΡΑΓΟΝΤΕΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ

Στη μελέτη των Kyparissidis-Kokkinidis κ.ά. [5], χρησιμοποιήθηκαν δεδομένα από 873 εγκύους του Γενικού Νοσοκομείου Ιπποκράτειο, με ηλικία κύησης μεγαλύτερη ή ίση με 28 εβδομάδες και 24 χαρακτηριστικά όπως ηλικία, ΔΜΣ, κατάσταση καπνίσματος, ιστορικό πρόωρου τοκετού, parity. Τα δεδομένα αυτά συλλέχθηκαν μέσω μίας μελέτης κοόρτης και περιλάμβαναν επίσης εξωτερικό σύνολο επικύρωσης με 100 δείγματα. Η προεπεξεργασία των δεδομένων αποτελούνταν από κωδικοποίηση κατηγορικών δεδομένων (one-hot encoding για ονομαστικά χαρακτηριστικά και label encoding για τακτικά), καταλογισμό ελλιπών τιμών με διάμεσο (για αριθμητικά χαρακτηριστικά) ή συχνότερη μεταβλητή (για κατηγορικά χαρακτηριστικά) και εξισορρόπηση του συνόλου δεδομένων μέσω υποδειγματοληψίας της πλειοψηφικής τάξης και SMOTE. Εξετάστηκαν αρκετοί αλγόριθμοι μηχανικής μάθησης, όπως Random Forest, Logistic Regression, Gradient Boosting, XGBoost και Bagging, με το Optimized Voting να επιτυγχάνει την καλύτερη απόδοση (Accuracy=94%, Precision=90%, Recall=97%, FI-score=91%). Οι μετρικές αξιολόγησης που χρησιμοποιήθηκαν ήταν οι ROC-AUC και PR-AUC. Το μοντέλο ήταν ικανό να προβλέψει πρόωρο τοκετό έως και 9 εβδομάδες πριν. Για την ερμηνεία των αποτελεσμάτων αξιοποιήθηκε το SHAP, μία τεχνική που δείχνει πώς και σε ποιον βαθμό συνέβαλε το κάθε χαρακτηριστικό στο τελικό αποτέλεσμα της πρόβλεψης. Μάλιστα από αυτή την ερμηνεία φαίνεται η ιδιαίτερη βαρύτητα χαρακτηριστικών όπως το μήκος του τραχήλου της μήτρας, ο ΔΜΣ και οι μετρήσεις Doppler.

Στο ίδιο πλαίσιο, οι Vovsha κ.ά. στην μελέτη τους [6] εστιάζουν στην πρόβλεψη του κινδύνου πρόωρου τοκετού σε γυναίκες που πρόκειται να γεννήσουν για πρώτη φορά (nulliparas). Τα δεδομένα περιείχαν χαρακτηριστικά όπως η ηλικία της μητέρας, το ιστορικό υγείας, οι συνθήκες εγκυμοσύνης, καθώς και άλλες κλινικές παράμετροι. Η προεπεξεργασία των δεδομένων περιλάμβανε την κανονικοποίηση των χαρακτηριστικών για την εξάλειψη της επίδρασης των διαφορετικών κλιμάκων και την αντιμετώπιση των ελλιπών τιμών με τη μέθοδο της μέσης τιμής ή της διαγραφής των γραμμών με ελλιπή δεδομένα. Για την ανάλυση των δεδομένων έγινε χρήση αλγορίθμων μηχανικής μάθησης, όπως η λογιστική παλινδρόμηση και οι μέθοδοι υποστήριξης διανυσμάτων (SVM). Η λογιστική παλινδρόμηση χρησιμοποιήθηκε για

την εκτίμηση της πιθανότητας πρόωρου τοκετού, ενώ οι μέθοδοι SVM εφαρμόστηκαν για την ταξινόμηση των περιπτώσεων σε κατηγορίες κινδύνου. Η επιλογή αυτών των αλγορίθμων βασίστηκε στην ικανότητά τους να διαχειρίζονται δεδομένα υψηλής διάστασης και να προσφέρουν υψηλή ακρίβεια στην πρόβλεψη. Τα αποτελέσματα έδειξαν ότι οι μέθοδοι SVM παρουσίασαν υψηλότερη ακρίβεια στην πρόβλεψη του κινδύνου πρόωρου τοκετού σε σύγκριση με τη λογιστική παλινδρόμηση, με βελτιωμένη ικανότητα διάκρισης μεταξύ των χαμηλών και υψηλών κινδύνων. Συνολικά, τα μοντέλα αυτά προσέφεραν αξιόπιστες προβλέψεις, οι οποίες μπορούν να χρησιμοποιηθούν για την πρώιμη διάγνωση και την προληπτική φροντίδα των εγκύων, μειώνοντας έτσι τις πιθανότητες εμφάνισης πρόωρων τοκετών.

Σε μία άλλη σχετική έρευνα που έγινε από τους Begum κ.ά. [7], χρησιμοποιήθηκε δείγμα από 3500 εγκύους με 10 χαρακτηριστικά. Μερικά από αυτά είναι ο διαβήτης, η ηλικία και ο ΔΜΣ της εγκύου καθώς και η υπέρταση. Τα δεδομένα συλλέχθηκαν από τρεις πηγές («Maa-O-Shishu Hospital», «Nishkriti» και «Shahaji Medical Hall»). Κατά την προεπεξεργασία, εφαρμόστηκαν τεχνικές κανονικοποίησης, τυποποίησης και δυαδοποίησης καθώς και γραφικές αναλύσεις (ιστόγραμμα, scatter matrix) για την κατανόηση της κατανομής των χαρακτηριστικών. Στην ανάλυση έγινε χρήση ορισμένων αλγορίθμων ταξινόμησης όπως k-NN, Decision Tree, SVM και Naïve Bayes. Τα δεδομένα χωρίστηκαν σε σύνολο εκπαίδευσης (80%) και δοκιμής (20%). Οι μετρικές αξιολόγησης που αξιοποιήθηκαν σε αυτή την έρευνα, περιλάμβαναν ακρίβεια, ανάκληση, F1-score και πίνακα σύγχυσης. Καταλήγει ότι το Decision Tree πέτυχε το μεγαλύτερο ποσοστό σε όλες τις μετρικές (99%).

2.2 ΜΕΛΕΤΕΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ ΜΕ ΒΑΣΗ ΜΕΓΑΛΑ ΔΕΔΟΜΕΝΑ ΚΑΙ ΠΡΟΗΓΜΕΝΟΥΣ ΑΛΓΟΡΙΘΜΟΥΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ

Μία άλλη μελέτη, όπως για παράδειγμα εκείνη των Koivu και Sairanen [8] που χρησιμοποίησε δεδομένα από το CDC στις Ηνωμένες Πολιτείες, βασίστηκε σε πολύ μεγαλύτερα σύνολα δεδομένων που έφταναν περίπου 16 εκατομμύρια εγκύους. Αυτά τα δεδομένα αποτελούνταν από πληροφορίες για δημογραφικά στοιχεία, ιστορικό εγκυμοσύνης και λοιμώξεις. Η προεπεξεργασία που έγινε σε αυτά απέκλεισε ανήλικες εγκύους, εγκύους με διάφορες λοιμώξεις, εγκυμοσύνες πολύδυμες, εγκύους με ηλικία κύησης μικρότερη από 21 εβδομάδες και τη μεταβλητή parity. Χρησιμοποιήθηκαν αλγόριθμοι λογιστικής παλινδρόμησης (LR), δέντρα απόφασης ενισχυμένα με κλίση (GBDT) και δύο μοντέλα τεχνητού νευρωνικού δικτύου (ANN). Η λογιστική παλινδρόμηση χρησιμοποιήθηκε ως σημείο αναφοράς λόγω της απλότητας και της ευρωστίας της. Για την ενίσχυση της απόδοσης, εφαρμόστηκε κανονικοποίηση και βελτιστοποίηση παραμέτρων με τον αλγόριθμο BFGS. Από την άλλη πλευρά, το GBDT, και συγκεκριμένα η έκδοση LightGBM (LGBM), επιλέχθηκε για την ικανότητά του να διαχειρίζεται μεγάλα σύνολα δεδομένων με υψηλή ταχύτητα και ακρίβεια. Όσον αφορά τα τεχνητά νευρωνικά δίκτυα, εξετάστηκαν δύο αρχιτεκτονικές: ένα βαθύ νευρωνικό δίκτυο δύο επιπέδων με Leaky ReLU και ένα αυτοκανονικοποιούμενο νευρωνικό δίκτυο (SELU) με τέσσερα κρυφά επίπεδα. Το SELU δίκτυο επιλέχθηκε για την ανώτερη απόδοσή του, ενώ εφαρμόστηκε βελτιστοποίηση Adam και κανονικοποίηση με αρχικοποίηση βαρών LeCun. Τα αποτελέσματα έδειξαν ότι το SELU δίκτυο παρουσίασε την καλύτερη απόδοση για τα δεδομένα CDC και για τα δεδομένα της Νέας Υόρκης. Τέλος, για τη βελτίωση των

προβλέψεων, εφαρμόστηκαν στρατηγικές μάθησης συνόλου (ensemble learning), όπως ο μέσος όρος και ο σταθμισμένος μέσος όρος (WA) των πιθανοτήτων από διαφορετικά μοντέλα. Τα αποτελέσματα έδειξαν ότι οι στρατηγικές αυτές παρήγαγαν προβλέψεις παρόμοιες με τα καλύτερα μοντέλα, εξασφαλίζοντας σταθερή απόδοση σε διαφορετικά σύνολα δεδομένων.

Ορισμένες εργασίες, όπως αυτή των AlSaad κ.ά. [9] που χρησιμοποιεί το μοντέλο PredictPTB, βασίστηκαν σε δεδομένα από ηλεκτρονικά αρχεία υγείας (EHR) που περιλαμβάνουν διαγνώσεις, φάρμακα, διαδικασίες και εργαστηριακές παραγγελίες. Η αρχιτεκτονική του μοντέλου PredictPTB απλοποιεί την αρχιτεκτονική RETAIN και βασίζεται σε αμφίδρομα νευρωνικά δίκτυα LSTM (BiLSTM-Bidirectional Long Short-Term Memory) που επιτρέπουν την αξιοποίηση τόσο των προηγούμενων όσο και των μελλοντικών πληροφοριών για κάθε δεδομένο βήμα. Αυτή η προσέγγιση μειώνει την πολυπλοκότητα του μοντέλου, ενώ ταυτόχρονα βελτιώνει την ακρίβεια των προβλέψεων, καθώς το μοντέλο επικεντρώνεται σε πιο αντιπροσωπευτικά χαρακτηριστικά και περιορίζει τον αριθμό των παραμέτρων για να αποφευχθεί η υπερβολική προσαρμογή. Τα δεδομένα αναλύθηκαν σε τέσσερα χρονικά σημεία (1, 3, 6 και 9 μήνες πριν από τον τοκετό) και οργανώθηκαν σε χρονικά παράθυρα με τα μακροπρόθεσμα δεδομένα να περιέχουν όλο το ιατρικό ιστορικό των εγκύων και τα βραχυπρόθεσμα να επικεντρώνονται μόνο στην τρέχουσα εγκυμοσύνη. Η ανάλυση επιβεβαίωσε ότι τα χαρακτηριστικά που συλλέγονται μετά την έναρξη της εγκυμοσύνης είναι πιο χρήσιμα για την πρόβλεψη του PTB. Επιπρόσθετα, για συνδυασμό όλων των τρόπων του συνόλου δεδομένων (διάγνωση, φαρμακευτική αγωγή, διαδικασίες και εργαστηριακά αποτελέσματα), οι τιμές ROC-AUC και PR-AUC έδειξαν ότι πέτυχε καλύτερα αποτελέσματα 30 ημέρες πριν από τον τοκετό συγκριτικά με τα μοντέλα RETAIN και MLP. Μάλιστα η ανάλυση των δεδομένων σε επίπεδο κώδικα και επίσκεψης αποκάλυψε ότι παράγοντες όπως η προεκλαμψία, ο πρόωρος τοκετός σε προηγούμενη εγκυμοσύνη και η καισαρική τομή αυξάνουν τον κίνδυνο PTB στις επόμενες εγκυμοσύνες.

Μία αναδρομική μελέτη κοόρτης των Zhang κ.ά. [10] επίσης αξιοποίησε δεδομένα προερχόμενα από τα ηλεκτρονικά αρχεία υγείας (EHR) και ερευνούσε τους παράγοντες κινδύνου για πρόωρο τοκετό. Πιο συγκεκριμένα τα δεδομένα του συλλέχθηκαν από το Δεύτερο Νοσοκομείο του Ιατρικού Πανεπιστήμιου Wenzhou την περίοδο Οκτώβριος 2019 – Δεκέμβριος 2020. Το σύνολο δεδομένων αποτελούνταν από 5411 έγκυες, αφού αποκλείστηκαν περιπτώσεις εγκύων με ελλιπείς ιατρικούς φακέλους ή ειδικές παθολογικές καταστάσεις και υπέστη και προεπεξεργασία όπως διαγραφή ή συμπλήρωση ελλιπών τιμών. Παράλληλα μέσω λογιστικής μονοπαραγοντικής και πολυπαραγοντικής ανάλυσης εξετάστηκαν 21 παράγοντες κινδύνου. Από αυτούς τους παράγοντες σημαντικότεροι αναδείχθηκαν η πρόωρη ρήξη μεμβρανών, η πολύδυμη κύηση και ο προδρομικός πλακούντας. Εφαρμόστηκαν διάφοροι αλγόριθμοι μηχανικής μάθησης με το μοντέλο AdaBoost να αποδίδει τις υψηλότερες βαθμολογίες (F1-score 0.969 και AUC 0.93). Οι μετρικές που αξιοποιήθηκαν περιλάμβαναν μεταξύ άλλων την ειδικότητα, την ευαισθησία και το F1-score. Τέλος, με αυτό το μοντέλο η εξωτερική επαλήθευση για μη πρόωρους τοκετούς πέτυχε ακρίβεια 100% ενώ για τους πρόωρους 72,73%.

2.3 ΕΞΕΙΔΙΚΕΥΜΕΝΕΣ ΕΦΑΡΜΟΓΕΣ ΚΑΙ ΘΕΩΡΗΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΣΤΗΝ ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ

Ακόμη, η μελέτη των Watson κ.ά. [11] προτείνει τη χρήση της εφαρμογής QUiPP για την πρόβλεψη του πρόωρου τοκετού. Πιο συγκεκριμένα η εφαρμογή αυτή αποτελεί μία ασφαλή και ακριβή εναλλακτική στη στρατηγική «θεραπεία όλων» που συνιστάται από το Εθνικό Ινστιτούτο Υγείας και Κλινικής Ιατρικής (NICE) του Ηνωμένου Βασιλείου για γυναίκες με απειλούμενο πρόωρο τοκετό (PTL) πριν από τις 30 εβδομάδες κύησης. Βασίζεται στη χρήση της ποσοτικής εμβρυϊκής φιμπρονεκτίνης (qfFN), μίας πρωτεΐνης που αυξάνεται σε περιπτώσεις πρόωρου τοκετού, σε συνδυασμό με δεδομένα όπως η ηλικία κύησης και το ιστορικό προηγούμενου πρόωρου τοκετού. Η εφαρμογή προβλέπει με ακρίβεια τον κίνδυνο τοκετού εντός 7 ημερών, με αρνητική προγνωστική τιμή (NPV) 98,2% για qfFN<10 ng/mL και θετική προγνωστική τιμή (PPV) 37,0% για qfFN>200 ng/mL. Χρησιμοποιώντας ένα όριο κινδύνου 5%, η εφαρμογή θα μπορούσε να μειώσει σημαντικά τις περιττές παρεμβάσεις, καθώς εννέα φορές λιγότερες γυναίκες θα χρειάζονταν θεραπεία, ενώ όλες οι πραγματικές περιπτώσεις πρόωρου τοκετού θα εντοπίζονταν με ακρίβεια. Επιπλέον, η ακρίβεια της εφαρμογής παραμένει σταθερή πριν και μετά τις 30 εβδομάδες κύησης, καθιστώντας την χρήσιμη τόσο σε χαμηλότερες όσο και σε υψηλότερες ηλικίες κύησης. Σημαντικό πλεονέκτημα της εφαρμογής είναι η δυνατότητα διαχείρισης εξωτερικών ασθενών για γυναίκες με κίνδυνο<10% εντός 7 ημερών, αποφεύγοντας την άσκοπη εισαγωγή και τα πιθανά προβλήματα που αυτή συνεπάγεται. Ωστόσο, η διαφοροποίηση στη διαχείριση μεταξύ γυναικών με κίνδυνο<1% και 5-10% παραμένει κρίσιμη, δεδομένων των διαφορετικών πιθανοτήτων τοκετού πριν από τις 30 εβδομάδες.

Η μελέτη των Moreira κ.ά. [12] συνιστά τη χρήση της μηχανής διανυσμάτων υποστήριξης (SVM) για την πρόβλεψη πρόωρου τοκετού σε εγκύους με υπερτασική διαταραχή. Τα δεδομένα που χρησιμοποιήθηκαν περιλάμβαναν 205 έγκυες γυναίκες που διαγνώστηκαν με υπέρταση. Συλλέχθηκαν από το Maternity School Assis Chateaubriand στο Ομοσπονδιακό Πανεπιστήμιο της Ceará στη Βραζιλία. Η προεπεξεργασία των δεδομένων αποτελούνταν από βήματα καθαρισμού και εξαγωγής χαρακτηριστικών ώστε να βελτιωθεί η ποιότητά τους και να λειτουργεί αποδοτικότερα ο αλγόριθμος. Για την εκπαίδευση και την αξιολόγηση του μοντέλου χρησιμοποιήθηκε η μέθοδος επικύρωσης. Με τη μέθοδο αυτή χωρίζονται τα δεδομένα σε δέκα υποσύνολα, κάθε ένα από τα οποία χρησιμοποιείται μία φορά για δοκιμή και τα υπόλοιπα εννέα για εκπαίδευση. Η διαδικασία αυτή επαναλαμβάνεται δέκα φορές, εξασφαλίζοντας ότι το μοντέλο εκπαιδεύεται και αξιολογείται σε διαφορετικά σύνολα δεδομένων, αποφεύγοντας έτσι την επικάλυψη του συνόλου δοκιμής και ενισχύοντας την αξιοπιστία των αποτελεσμάτων. Επίσης, ο αλγόριθμος SVM χρησιμοποιήθηκε με γραμμικό πυρήνα, ο οποίος είναι κατάλληλος για την αντιμετώπιση γενικών συνόλων δεδομένων και για την εύρεση του βέλτιστου υπερεπιπέδου στον χαρακτηριστικό χώρο. Ο SVM ενσωματώνει την έννοια της μεγιστοποίησης του περιθωρίου διαχωρισμού, επιτρέποντας την αποτελεσματική ταξινόμηση των δεδομένων σε δύο κλάσεις, ενώ η χρήση του γραμμικού πυρήνα καθιστά τον υπολογισμό αποδοτικό και γρήγορο. Τα αποτελέσματα της εφαρμογής του μοντέλου ήταν αρκετά καλά, με ακρίβεια 0,821, ποσοστό αληθών θετικών (TP) 0,839, ποσοστό ψευδών θετικών (FP) 0,268 και περιοχή ROC 0,785. Στη συνέχεια, η συγκεκριμένη μελέτη αποδεικνύει ότι ο αλγόριθμος SVM με γραμμική συνάρτηση πυρήνα είναι πολύ αποτελεσματικός και στην αναγνώριση άλλων επιπλοκών όπως η

χαμηλή βαθμολογία Apgar και η πιθανότητα το έμβρυο να είναι μικρότερο της ηλικίας κύησης (SGA). Μάλιστα η μεθοδολογία αυτή μπορεί να εφαρμοστεί σε έξυπνα συστήματα υποστήριξης αποφάσεων (DSS) και να ενσωματωθεί σε εφαρμογές υγείας για κινητές συσκευές (m-health) γεγονός που την καθιστά χρήσιμη και πρακτική στην πρόληψη κινδύνων σχετικών με την εγκυμοσύνη.

Υπάρχει ακόμη, μία μελέτη από τους Grzymala-Busse κ.ά. [13] που χρησιμοποιεί δεδομένα υγειονομικής περίθαλψης εγκύων για την πρόβλεψη του πρόωρου τοκετού. Τα δεδομένα υποβλήθηκαν σε προεπεξεργασία ώστε να αφαιρεθούν τυχόν σφάλματα. Η μεθοδολογία που εφαρμόστηκε ήταν αυτή του συστήματος μηχανικής μάθησης LERS (Learning from Examples based on Rough Sets). Πρόκειται για μία μεθοδολογία που βασίζεται στη θεωρία των ακατέργαστων συνόλων. Ο αλγόριθμος LEM2 του LERS έκανε χρήση των δεδομένων για την εξαγωγή κανόνων ταξινόμησης, που δοκιμάστηκαν σε νέα παραδείγματα ώστε να επιτευχθεί η πρόβλεψη του πρόωρου τοκετού. Σύμφωνα με τις μετρικές αξιολόγησης η μέθοδος αυτή συγκριτικά με τις χειρωνακτικές μεθόδους ήταν πιο αποδοτική (ακρίβεια 68%-90%).

2.4 ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ ΜΕ ΒΑΣΗ ΤΗΝ ΗΛΕΚΤΡΟΜΗΤΡΙΚΗ ΚΑΤΑΓΡΑΦΗ (EHG)

Τέλος, κάποιες μελέτες πρόβλεψης πρόωρου τοκετού στηρίζονται στην ηλεκτρομητρική καταγραφή (EHG). Δηλαδή σε μία μη επεμβατική μέθοδο που μετρά τη βιοηλεκτρική δραστηριότητα των λείων μυών της μήτρας μέσω ηλεκτροδίων στην κοιλιακή χώρα.

Το άρθρο των Despotović κ.ά. [14] για παράδειγμα εξετάζει την πρόβλεψη πρόωρου τοκετού μέσω ανάλυσης ηλεκτρομητρικών καταγραφών (EHG) που πραγματοποιήθηκαν μεταξύ της 22^{ης} και 25^{ης} εβδομάδας κύησης. Για τον σκοπό αυτό χρησιμοποιήθηκε η δημόσια διαθέσιμη βάση δεδομένων Term-Preterm EHG (TPEHG). Η μελέτη αξιολόγησε φασματικά και μη γραμμικά χαρακτηριστικά όπως η διάμεση συχνότητα, η φασματική πυκνότητα ισχύος, η εντροπία δείγματος και ο εκθέτης Lyapunov. Επιπλέον, εξετάστηκε η απόδοση αλγορίθμων μηχανικής μάθησης (k-Κοντινότεροι Γείτονες (k-NN), Μηχανές Υποστήριξης Διανυσμάτων (SVM) και Τυχαίο Δάσος (Random Forest)) για την ταξινόμηση πρόωρων και τελειόμηνων κυήσεων. Με έμφαση στη χρήση συντομότερων καταγραφών 15 λεπτών, εφαρμόστηκε η μέθοδος εμπειρικής αποσύνθεσης (EMD) και ο μετασχηματισμός Hilbert για την εξαγωγή χαρακτηριστικών, ενώ χρησιμοποιήθηκε η προσέγγιση ADASYN για την εξισορρόπηση των δεδομένων. Τα αποτελέσματα έδειξαν ότι η Random Forest με δειγματοληψία ADASYN πέτυχε την καλύτερη απόδοση με ευαισθησία 98,4% και συνολική ακρίβεια (AUC) 99%.

Έτσι και στην μελέτη πρόβλεψης πρόωρου τοκετού των Narmadha κ.ά. [15] αξιοποιούνται δεδομένα εγκύων προερχόμενα από ηλεκτροϋστογράφημα (EHG) και με έμφαση στη παρακολούθηση της μήτρας. Μέσω της προεπεξεργασίας που υφίστανται τα σήματα EHG, αφαιρείται ο θόρυβος και εξάγονται κρίσιμα χαρακτηριστικά. Μερικά από αυτά είναι η εντροπία και η ενέργεια Teager-Kaiser. Ακόμη, χρησιμοποιήθηκαν και οι αλγόριθμοι k-Κοντινότεροι Γείτονες (k-NN) και Λογιστική Παλινδρόμηση (LR). Για πιο έγκυρη ακρίβεια έγινε χρήση του μοντέλου

AdaBoost. Το βέλτιστο αποτέλεσμα ωστόσο δόθηκε από το μοντέλο SVM με πολυωνυμικό πυρήνα που πέτυχε ακρίβεια 99,7%.

2.5 ΚΑΙΝΟΤΟΜΙΕΣ ΠΑΡΟΥΣΑΣ ΠΤΥΧΙΑΚΗΣ

Η παρούσα μελέτη προσεγγίζει την πρόβλεψη του πρόωρου τοκετού μέσω κάποιων καινοτομιών. Μία καινοτομία έγκειται στο γεγονός ότι πριν την εφαρμογή αλγορίθμων μηχανικής μάθησης έγινε έλεγχος για την ύπαρξη προκατάληψης στο διαθέσιμο σύνολο δεδομένων, κάτι που δεν αναφέρεται στις προηγούμενες μελέτες. Επομένως, οι διάφοροι αλγόριθμοι εκτελέστηκαν σε αμερόληπτο σύνολο δεδομένων. Ακόμη, μία άλλη καινοτομία είναι ότι η μελέτη αυτή προσεγγίζει το ζήτημα όχι μόνο ως πρόβλημα δυαδικής ταξινόμησης (πρόωρος ή όχι πρόωρος τοκετός), αλλά και ως πρόβλημα παλινδρόμησης, στοχεύοντας στην ακριβή πρόβλεψη της εβδομάδας τοκετού. Η πρόβλεψη της εβδομάδας τοκετού υλοποιήθηκε εκ νέου και με στρογγυλοποίηση σε ακέραιο αριθμό, προκειμένου να γίνει το αποτέλεσμά της καταλληλότερο για κλινική χρήση. Ακολούθησε πρόβλεψη του μήνα τοκετού με σκοπό την απλοποίηση της διαδικασίας και τέλος, δοκιμάστηκε πρόβλεψη του τοκετού με κατηγορίες σε διαστήματα δύο εβδομάδων. Μέσω αυτών των διαφορετικών μεταξύ τους προσεγγίσεων επιδιώχθηκε η αύξηση της αξιοπιστίας των προβλέψεων και η κλινική εφαρμογή των αποτελεσμάτων.

ΚΕΦΑΛΑΙΟ 3: ΈΛΕΓΧΟΣ ΚΑΙ ΑΠΑΛΟΙΦΗ ΠΡΟΚΑΤΑΛΗΨΗΣ ΣΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ

ΈΛΕΓΧΟΣ ΚΑΙ ΑΠΑΛΟΙΦΗ ΠΡΟΚΑΤΑΛΗΨΗΣ ΣΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ

3.1 ΠΕΡΙΓΡΑΦΗ ΣΥΝΟΛΟΥ ΔΕΔΟΜΕΝΩΝ

Για την ανάπτυξη του συστήματος πρόβλεψης της κλινικής απόφασης για πρόωρο τοκετό αξιοποιήθηκε ένα συγκεκριμένο dataset και ορισμένοι αλγόριθμοι μηχανικής μάθησης.

Το dataset (σύνολο δεδομένων) που χρησιμοποιήθηκε περιλαμβάνει πληροφορίες από 873 έγκυες γυναίκες και προήλθε από το Γενικό Νοσοκομείο Θεσσαλονίκης «Ιπποκράτειο». Πιο συγκεκριμένα, αποτελούνταν από κλινικά δεδομένα σχετικά με την υγεία και τα χαρακτηριστικά των εγκύων γυναικών, καθώς και πιθανές παραμέτρους που συνδέονται με τον πρόωρο τοκετό. Η συλλογή και η αρχική επεξεργασία των δεδομένων πραγματοποιήθηκε στο πλαίσιο του ερευνητικού έργου HosmartAI[1] που χρηματοδοτήθηκε από την Ευρωπαϊκή Ένωση μέσω του προγράμματος Horizon 2020 και στοχεύει στην ενσωμάτωση έξυπνων τεχνολογιών στον τομέα της υγείας, με έμφαση στην εξηγήσιμη τεχνητή νοημοσύνη (Explainable AI).

Παρακάτω παρουσιάζονται οι μεταβλητές που αναλύθηκαν όπως κατατάσσονται σε δύο κατηγορίες με βάση τον τύπο τους

- Συνεχείς: Πρόκειται για αριθμητικές τιμές που μπορούν να πάρουν οποιαδήποτε τιμή μέσα σε ένα εύρος.
- Δυαδικές: Δέχονται δύο πιθανές τιμές (0: για απουσία και 1: για παρουσία).

Από τις μεταβλητές του dataset συνεχείς είναι οι ακόλουθες:

- Maternal age: η ηλικία της μητέρας.
- GA (Gestational Age); η ηλικία κύησης κατά την οποία συνέβη ο τοκετός.
- BW centile (Birth Weight centile): εκατοστιαία θέση του βάρους γέννησης σε σύγκριση με τον πληθυσμό αναφοράς.
- UtA doppler (Uterine Artery doppler): εκτίμηση ροής αίματος στη μητριαία αρτηρία.
- b-hcg (Beta-Human Chorionic Gonadotropin): επίπεδα Β (βήτα)-χοριακής γοναδοτροπίνης (ορμόνη που παράγεται από τον πλακούντα λίγο μετά την εμφύτευση του γονιμοποιημένου ωαρίου στη μήτρα).
- DVP: υπερηχογράφημα Α επιπέδου – αξιολόγηση της κατάστασης του εμβρύου ανατομικά και λειτουργικά.
- MCA doppler (Middle Cerebral Artery doppler): μέτρηση της αιματικής ροής στη

[1] https://www.hosmartai.eu/.

μέση εγκεφαλική αρτηρία του εμβρύου.

- Papp-A (Pregnancy Associated Plasma Protein-A): επίπεδα πρωτεΐνης PAPP-A (το πιο σύγχρονο προγεννητικό τεστ πληθυσμιακής διαλογής για τις συνηθέστερες χρωμοσωμικές ανωμαλίες, όπως το σύνδρομο Down ή οι τρισωμίες 18 και 13).
- Height: το ύψος της μητέρας.
- UA doppler (Umbilical Artery doppler): μέτρηση ροής αίματος στην ομφαλική αρτηρία με στόχο την αξιολόγηση της πλακουντιακής λειτουργίας.
- DV doppler (Ductus Venosus doppler): μέτρηση στη ροή αίματος του φλεβώδους πόρου ώστε να γίνει έλεγχος ύπαρξης εμβρυϊκής υποξίας (έλλειψης οξυγόνου).
- EFW (Estimation of Fetal Weight): εκτιμώμενο βάρος εμβρύου μέσω υπερηχογραφήματος.
- Cervical length: μήκος του τραχήλου της μήτρας.
- BMI (Body Mass Index): δείκτης μάζας σώματος της μητέρας.
- Gravida: συνολικός αριθμός κυήσεων, συμπεριλαμβανομένων αποβολών και εξωμήτριων κυήσεων.
- Parity.1: αριθμός προηγούμενων τοκετών όπου το έμβρυο είχε φτάσει τουλάχιστον τις 24 εβδομάδες κύησης (ανεξαρτήτως ζωντανής ή νεκρής γέννησης).

Οι δυαδικές μεταβλητές του dataset είναι οι παρακάτω:

- Smoking: κατάσταση καπνίσματος.
- Conception_ART: χρήση υποβοηθούμενης αναπαραγωγής (ART).
- History_of_SGA_FGR: ιστορικό γέννησης εμβρύου μικρότερου της 10^{ης} εκατοστιαίας θέσης (SGA - Small for Gestational Age) ή εμβρύου με περιορισμό ανάπτυξης (FGR - Fetal Growth Restriction).
- History_of_PTD: ιστορικό πρόωρου τοκετού (γέννηση πριν από τις 37 εβδομάδες).
- Preterm_birth: πιθανή ένδειξη για πρόωρο τοκετό στην παρούσα κύηση.
- Placental_cord_insertion: θέση εισαγωγής του ομφάλιου λώρου στον πλακούντα.
- Placental_cord_insertion_abnormal: παθολογική ή μη φυσιολογική εισαγωγή του ομφάλιου λώρου.
- GDM (Gestational Diabetes Mellitus): σακχαρώδης διαβήτης κύησης.
- PREECLAMPSIA: παρουσία προεκλαμψίας κατά τη διάρκεια της κύησης (πάθηση της κύησης που ορίζεται ως υψηλή αρτηριακή πίεση και περίσσεια λευκώματος στα ούρα μετά από τις 20 εβδομάδες κύησης, σε μία γυναίκα που προηγουμένως είχε φυσιολογική αρτηριακή πίεση).
- DM (Diabetes Mellitus): γενικός σακχαρώδης διαβήτης (προϋπάρχων ή διαγνωσμένος κατά την κύηση).
- Epilepsy (επιληψία): πρόκειται για μία νευρολογική διαταραχή η οποία χαρακτηρίζεται από επαναλαμβανόμενες κρίσεις λόγω ανώμαλης ηλεκτρικής δραστηριότητας στον εγκέφαλο.

- Cholestatis: διαταραχή του ήπατος που προκαλεί έντονο κνησμό και αυξημένα ηπατικά ένζυμα.
- Hypothyroidism: χαμηλά επίπεδα θυρεοειδιτιδών ορμονών που μπορεί να οδηγήσουν σε επιπλοκές στην κύηση.
- Thalassemia: κληρονομική διαταραχή του αίματος που επηρεάζει την παραγωγή αιμοσφαιρίνης.
- Hyperthyroidism: υπερβολική παραγωγή θυρεοειδιτιδών ορμονών που αυξάνουν τον κίνδυνο πρόωρου τοκετού και προεκλαμψίας.
- THROMBOPHILIA: κατάσταση κατά την οποία το αίμα έχει αυξημένη τάση σχηματισμού θρόμβων.
- Hashimoto: αυτοάνοση θυρεοειδίτιδα που προκαλεί υποθυρεοειδισμό.
- LUPUS (Συστηματικός Ερυθηματώδης Λύκος): αυτοάνοσο νόσημα που επηρεάζει πολλαπλά όργανα.
- APS (Antiphospholipid Syndrome): αυτοάνοση κατάσταση που αυξάνει τον κίνδυνο θρόμβωσης και αποβολών.
- HYPERTENSION (υπέρταση): υψηλή αρτηριακή πίεση που μπορεί να οδηγήσει σε προεκλαμψία.
- ΑΓΓΕΙΙΤΙΔΑ WEGENER: αυτοάνοση διαταραχή που προκαλεί φλεγμονή των αιμοφόρων αγγείων.
- Chronic Hypertension (χρόνια υπέρταση): προϋπάρχουσα υψηλή πίεση πριν την εγκυμοσύνη.
- THROMBOPENIA: χαμηλός αριθμός αιμοπεταλίων που οδηγεί σε αιμορραγικές επιπλοκές.
- ELEVATED LIVER ENZYMES: αυξημένα ηπατικά ένζυμα.
- RA (Rheumatoid Arthritis): αυτοάνοση διαταραχή που επηρεάζει τις αρθρώσεις.
- Cardiac disease: γενικός όρος για καρδιαγγειακές παθήσεις.
- Asthma: χρόνια αναπνευστική πάθηση που μπορεί να επηρεάσει τη ροή του οξυγόνου στο έμβρυο.
- SJOGREN (Σύνδρομο Sjogren): αυτοάνοσο νόσημα που επηρεάζει τους αδένες που παράγουν υγρά.
- Polycystic kidneys: κληρονομική πάθηση που προκαλεί την ανάπτυξη κύστεων στους νεφρούς.
- Mediter fever: μεσογειακός πυρετός.
- Crohn disease: χρόνια φλεγμονώδης νόσος του εντέρου.
- CF (Cystic Fibrosis - Κυστική Ίνωση): κληρονομική διαταραχή που επηρεάζει τους πνεύμονες και το πεπτικό σύστημα.
- MS (Multiple Sclerosis): αυτοάνοση νόσος (σκλήρυνση) που επηρεάζει το νευρικό σύστημα.
- Placental location_fundal: ο πλακούντας είναι τοποθετημένος στο ανώτερο τμήμα

της μήτρας (βέλτιστη θέση).

- Placental location_high anterior: ο πλακούντας βρίσκεται ψηλά στην πρόσθια επιφάνεια της μήτρας.
- Placental location_high anterior with posterior paraplacenta: ο πλακούντας βρίσκεται ψηλά στην πρόσθια πλευρά της μήτρας και υπάρχει παραπλακούντας στην οπίσθια επιφάνεια.
- Placental location_high left: ο πλακούντας είναι τοποθετημένος ψηλά αριστερά στη μήτρα.
- Placental location_high posterior: ο πλακούντας βρίσκεται ψηλά στην οπίσθια επιφάνεια της μήτρας.
- Placental location_high posterior with anterior paraplacenta: ο πλακούντας βρίσκεται ψηλά στην οπίσθια επιφάνεια της μήτρας και υπάρχει παραπλακούντας στην πρόσθια πλευρά.
- Placental location_high right: ο πλακούντας είναι τοποθετημένος ψηλά δεξιά στη μήτρα.
- Placental location_low anterior: χαμηλή πρόσθια τοποθέτηση πλακούντα (ενδέχεται να δημιουργήσει προβλήματα στον τοκετό).
- Placental location_low posterior: χαμηλή οπίσθια τοποθέτηση πλακούντα.
- Placental location_low posterior with anterior paraplacenta: ο πλακούντας βρίσκεται χαμηλά στην οπίσθια επιφάνεια και υπάρχει παραπλακούντας στην πρόσθια πλευρά.
- Placental location_low right: ο πλακούντας είναι τοποθετημένος χαμηλά δεξιά στη μήτρα.
- Placental location_previa (προδρομικός πλακούντας): καλύπτει πλήρως ή μερικώς τον τράχηλο και συχνά απαιτεί καισαρική τομή.
- Single umbilical artery_0: απουσία μίας εκ των δύο αρτηριών στον ομφάλιο λώρο.
- Single umbilical artery_1: απουσία μίας εκ των δύο αρτηριών στον ομφάλιο λώρο.

3.2 ΈΛΕΓΧΟΣ BIAS ΣΤΟ DATASET

Ο έλεγχος για την ύπαρξη προκατάληψης (bias) σε ένα σύνολο δεδομένων (dataset) αποτελεί βασική προϋπόθεση για την ανάπτυξη δίκαιων και αξιόπιστων συστημάτων μηχανικής μάθησης (machine learning - ML). Δεδομένου ότι τα δεδομένα αποτελούν την βάση της εκπαίδευσης των χρησιμοποιούμενων αλγορίθμων, η παρουσία μεροληψίας μπορεί να έχει αρνητική επίδραση στην ποιότητα καθώς και στην αντικειμενικότητα των παραγόμενων προβλέψεων. Σε περίπτωση που δεν εντοπιστεί και δεν αντιμετωπιστεί εγκαίρως, το αναπτυσσόμενο μοντέλο ενδέχεται να παράγει άδικα ή ανακριβή αποτελέσματα, γεγονός που μειώνει την αξιοπιστία και την χρηστικότητα του τελικού μοντέλου.

Για την ανίχνευση του bias, στην παρούσα μελέτη, επιλέχθηκε η χρήση του AI Fairness 360 (AIF360) [16]. Πρόκειται για μία βιβλιοθήκη ανοιχτού κώδικα από την

IBM που παρέχει εργαλεία για την ανάλυση και την μείωση της αδικίας (bias) σε μοντέλα μηχανικής μάθησης και μπορεί να εφαρμοστεί σε δεδομένα με δυαδικές αλλά και συνεχείς μεταβλητές.

Πιο συγκεκριμένα η ανάλυση εντοπισμού προκαταλήψεων έγινε σε σχέση με την έκβαση της «Preterm_birth» (πρόωρος τοκετός), η οποία αποτελεί τη μεταβλητή – στόχο του μοντέλου. Ο έλεγχος πραγματοποιήθηκε με βάση διάφορα προστατευμένα χαρακτηριστικά (protected attributes), δηλαδή μεταβλητές των οποίων οι τιμές θα μπορούσαν να οδηγήσουν σε bias.

Αρχικά στην διερεύνηση χρησιμοποιήθηκε η κλάση StandardDataset του AIF360 που προεπεξεργάζεται το pandas DataFrame ώστε να είναι συμβατό με τα fairness metrics. Τα βασικά ορίσματα της κλάσης αυτής είναι:

- df: το DataFrame με τα δεδομένα.
- label_name: η μεταβλητή στόχος (Preterm_birth).
- favorable_classes: η θετική έκβαση ([0] αν θεωρούμε ότι «όχι πρόωρος τοκετός» είναι το επιθυμητό).
- protected_attribute_names: η μεταβλητή που ελέγχεται για bias.
- privileged_classes: ποια τιμή θεωρείται το προνομιούχο group.

Για κάθε μεταβλητή ορίστηκαν δύο ομάδες:

- privileged_groups: η ομάδα με μειωμένο ρίσκο πρόωρου τοκετού.
- unprivileged_groups: η ομάδα με αυξημένο ρίσκο, ή που θα μπορούσε να υποστεί διακριτική μεταχείριση.

Η επιβεβαίωση του διαχωρισμού κάθε ελεγχόμενης μεταβλητής στα παραπάνω groups, έγινε μέσω μίας εντολής που υπολογίζει τη μέση πιθανότητα πρόωρου τοκετού για κάθε ομάδα

(print(df.groupby("ελεγχόμενη μεταβλητή")["Preterm_birth"].mean())).

Εφαρμόστηκε κανονικοποίηση (binary split) για χρήση των μετρικών fairness του AIF360, όπου ήταν εφικτό. Μάλιστα στις συνεχείς μεταβλητές έγινε ομαδοποίηση ή απλή παρατήρηση μέσων τιμών μέσω του groupby(), καθώς υπήρχαν περιορισμοί στην βιβλιοθήκη.

Έπειτα, αξιοποιήθηκε η BinaryLabelDatasetMetric για την εξαγωγή δύο βασικών δεικτών fairness:

- Disparate Impact (DI) [17]: Μετρά την αναλογία των ευνοϊκών ποσοστών έκβασης μεταξύ των μη προνομιούχων και των προνομιούχων ομάδων (1).

Εξίσωση 1: Τύπος DI

$$\text{Disparate Impact}=\frac{P(y=1|unprivileged)}{P(y=1|privileged)} \quad (1)$$

Μία τιμή κοντά στο 1 υποδηλώνει δικαιοσύνη.

Bias υποδηλώνει μία τιμή <= 0.8 (σύμφωνα με τον κανόνα του Equal Employment Opportunity Commission (EEOC) στις ΗΠΑ) και > 1.2 (δεν είναι αυστηρά καθορισμένο όριο, αλλά χρησιμοποιείται ενίοτε αναλυτικά για να επισημάνει ότι ίσως πρέπει να εξεταστούν και περιπτώσεις "αντίστροφης" μεροληψίας, δηλαδή είναι περισσότερο συμπερασματικό εργαλείο).
Μία τιμή μικρότερη από 1 υποδεικνύει μία προκατάληψη προς την πρόβλεψη θετικών αποτελεσμάτων για την προνομιούχα τάξη.
Μία τιμή μεγαλύτερη από 1 υποδηλώνει μία προκατάληψη προς την κατηγορία χωρίς προνόμια.

- Statistical Parity Difference (SPD) [18]: Η διαφορά στην πιθανότητα ευνοϊκών αποτελεσμάτων μεταξύ των μη προνομιούχων και των προνομιούχων ομάδων (2).

Εξίσωση 2: Τύπος SPD

Statistical Parity Difference= $\mathrm{P}(y = 1|unprivileged)$ - $\mathrm{P}(y = 1|unprivileged)$ (2)

Μία τιμή κοντά στο 0 υποδηλώνει δικαιοσύνη.
Η αρνητική τιμή υποδεικνύει ότι η μη προνομιούχα ομάδα είναι λιγότερο πιθανό να λάβει θετικά αποτελέσματα από την προνομιούχα ομάδα.
Η θετική τιμή υποδηλώνει ότι η προνομιούχα ομάδα έχει μικρότερη πιθανότητα να λάβει θετικά αποτελέσματα σε σύγκριση με τη μη προνομιούχα ομάδα.

Οι μεταβλητές και οι τιμές που προέκυψαν κατά την ανάλυσή τους παρουσιάζονται στον Πίνακα 1.

Πίνακας 1: Τιμές DI και SPD

Μεταβλητή	Privileged Group	Unprivileged Group	DI	SPD
Maternal age	0 (<35)	1 (>=35)	0.94	-0.03
History_of_PTD	0 (χωρίς ιστορικό)	1 (με ιστορικό)	0.0	-0.68
BMI	0 (μη παχύσαρκες)	1 (παχύσαρκες)	0.90	-0.06
Cervical length	0 (>=15 mm)	1 (<15 mm)	0.0	-0.70
Smoking	1 (καπνίζει)	0 (δεν καπνίζει)	0.79	-0.08
Conception_ART	1 (με ART)	0 (χωρίς ART)	0.97	-0.009
History_of_SGA_FGR	1	0	0.32	-0.67
Placental_cord_insertion	0	3	0.08	0.91
Placental_cord_insertion_abnormal	1 (φυσιολογικό)	0 (μη φυσιολογικό)	1.13	0.04
Gravida	0-2	3-7	1.50	0.16
Parity.1	1-5	0	0.85	-0.05
GDM	0 (χωρίς διαβήτη)	1 (με διαβήτη)	1.13	0.04
PREECLAMPSIA	0 (όχι)	1 (ναι)	2.85	0.60

Μεταβλητή	Privileged Group	Unprivileged Group	DI	SPD
b-hcg	0 (χαμηλό)	1 (υψηλό)	1.01	0.003
EFW	1 (υψηλό)	0 (χαμηλό)	1.15	0.04
BW centile	1 (υψηλό)	0 (χαμηλό)	1.11	0.03

Οι τιμές που προέκυψαν από την ανάλυση στους δείκτες DI και SPD υποδηλώνουν ότι υπάρχει bias στις κλινικές μεταβλητές History_of_PTD, Cervical length, History_of_SGA_FGR, Placental_cord_insertion, Gravida και PREECLAMPSIA. Ωστόσο οι παραπάνω είναι κλινικοί δείκτες πρόβλεψης συνδεδεμένες με τον πρόωρο τοκετό. Οπότε ίσως δεν πρόκειται για bias αλλά για αντικειμενικό κίνδυνο σε συγκεκριμένες κατηγορίες εγκύων.

Αυτό σημαίνει ότι οι διαφοροποιήσεις που παρατηρούνται μεταξύ των ομάδων στις συγκεκριμένες κλινικές μεταβλητές πιθανώς αντικατοπτρίζουν πραγματικές σχέσεις μεταξύ των μεταβλητών αυτών και του να συμβεί ή όχι πρόωρος τοκετός. Ειδικότερα, μεταβλητές όπως το ιστορικό πρόωρου τοκετού, η προεκλαμψία, το μήκος του τραχήλου της μήτρας, έχουν άμεση αιτιώδη συσχέτιση με τον πρόωρο τοκετό και αναγνωρίζονται στη βιβλιογραφία ως σημαντικοί προγνωστικοί παράγοντες. Επομένως, η παρουσία διαφορών μεταξύ των ομάδων σε αυτές τις περιπτώσεις πιθανώς δεν αντανακλά bias αλλά αντικειμενικό κίνδυνο όπως αναφέρθηκε παραπάνω.

Παρατηρήθηκε ακόμη πιθανότητα ύπαρξης bias στην μεταβλητή Smoking λόγω οριακής τιμής. Για αυτό έγιναν περαιτέρω έλεγχοι συσχέτισής της με την μεταβλητή Preterm_birth μέσω των στατιστικών μεθόδων Chi-square και Fisher’s Exact Test. Τα αποτελέσματα όμως έδειξαν ότι δεν υπάρχει στατιστικά σημαντική σχέση.

3.3 SAMPLING BIAS

Από τα αποτελέσματα της προηγούμενης ανάλυσης και το γεγονός ότι στο dataset που χρησιμοποιείται εμφανίζεται ποσοστό πρόωρου τοκετού 33%, πολύ υψηλότερο από το πραγματικό που είναι στο 8-10%, προέκυψε το συμπέρασμα ότι υπάρχει sampling bias και όχι απλό bias [19].

Για να μειωθεί το ποσοστό πρόωρων τοκετών που παρατηρήθηκε και να προσεγγίζει το πραγματικό ποσοστό ακολούθησε τυχαία αφαίρεση δειγμάτων από το dataset. Μάλιστα σύμφωνα με την στατιστική για να διασφαλιστεί ακρίβεια στους ελέγχους και τα αντίστοιχα συμπεράσματα η τυχαία αφαίρεση δειγμάτων χρειάστηκε να εφαρμοστεί 30 φορές. Έπειτα έγινε εκ νέου έλεγχος για την ύπαρξη bias στις κοινωνικοοικονομικής προέλευσης μεταβλητές των νέων datasets.

Αναλυτικά η διαδικασία που ακολουθήθηκε:

Αρχικά στο δοθέν dataset υπολογίστηκε ο αριθμός των δειγμάτων που στην μεταβλητή Preterm_birth έχουν τιμή 1 και ορίστηκε το επιθυμητό πλήθος δειγμάτων με αυτή την τιμή. Έτσι προέκυψε ο αριθμός των δειγμάτων που οφείλουν να αφαιρεθούν (συνολικά 170).

Δημιουργήθηκε ένας φάκελος στον οποίο τοποθετήθηκαν αργότερα τα νέα datasets που προέκυψαν.

Στη συνέχεια εφαρμόστηκε ένας βρόχος 30 επαναλήψεων που επέλεγε κάθε φορά 170 τυχαία δείγματα για να αφαιρέσει. Σε κάθε επανάληψη γινόταν έλεγχος προκειμένου να αφαιρούνται διαφορετικά δείγματα, εφόσον ήταν δυνατό να συμβεί αυτό. Το νέο ποσοστό πρόωρων τοκετών για καθένα από τα 30 νέα datasets μετά από υπολογισμούς βρέθηκε ότι είναι 8.73%.

Αφού ολοκληρώθηκε η δημιουργία των νέων datasets, με την χρήση του AI Fairness 360 και μέσω της διαδικασίας που εφαρμόστηκε στο αρχικό dataset (περιγράφεται αναλυτικά στο 4.1) ελέγχθηκαν για ύπαρξη bias οι μεταβλητές Maternal age και Smoking μέσω των μετρικών Disparate Impact (DI) και Statistical Parity Difference (SPD).

Στον Πίνακα 2 και στον Πίνακα 3 παρουσιάζονται τα αποτελέσματα που προέκυψαν.

Πίνακας 2: Έλεγχος bias στην μεταβλητή Maternal age

Maternal age	DI	SPD
Dataset 1	0.92	-0.05
Dataset 2	0.94	-0.04
Dataset 3	0.93	-0.05
Dataset 4	0.93	-0.05
Dataset 5	0.94	-0.04
Dataset 6	0.96	-0.02
Dataset 7	0.97	-0.02
Dataset 8	0.98	-0.01
Dataset 9	0.99	-0.007
Dataset 10	0.96	-0.02
Dataset 11	1.01	0.01
Dataset 12	1.04	0.03
Dataset 13	0.94	-0.04
Dataset 14	0.95	-0.03
Dataset 15	0.96	-0.02
Dataset 16	0.95	-0.03
Dataset 17	0.96	-0.02
Dataset 18	0.97	-0.02
Dataset 19	0.96	-0.02
Dataset 20	0.97	-0.02
Dataset 21	0.93	-0.05
Dataset 22	0.96	-0.02
Dataset 23	1.01	0.01

Maternal age	**DI**	**SPD**
Dataset 24	0.99	-0.003
Dataset 25	0.92	-0.05
Dataset 26	0.96	-0.02
Dataset 27	0.98	-0.01
Dataset 28	0.96	-0.02
Dataset 29	0.94	-0.04
Dataset 30	0.96	-0.02

Πίνακας 3: Έλεγχος bias στην μεταβλητή Smoking

Smoking	**DI**	**SPD**
Dataset 1	0.84	-0.03
Dataset 2	0.76	-0.05
Dataset 3	0.65	-0.09
Dataset 4	0.76	-0.05
Dataset 5	0.70	-0.07
Dataset 6	0.89	-0.02
Dataset 7	0.60	-0.11
Dataset 8	1.07	0.01
Dataset 9	1.00	0.0006
Dataset 10	0.67	-0.08
Dataset 11	0.58	-0.12
Dataset 12	0.89	-0.02
Dataset 13	0.73	-0.06
Dataset 14	0.70	-0.07
Dataset 15	0.73	-0.06
Dataset 16	0.80	-0.04
Dataset 17	0.60	-0.11
Dataset 18	0.62	-0.10
Dataset 19	0.70	-0.07
Dataset 20	0.70	-0.07
Dataset 21	0.67	-0.08
Dataset 22	0.84	-0.03

Smoking	DI	SPD
Dataset 23	0.89	-0.02
Dataset 24	0.62	-0.10
Dataset 25	0.76	-0.05
Dataset 26	0.70	-0.07
Dataset 27	0.76	-0.05
Dataset 28	0.73	-0.06
Dataset 29	0.62	-0.10
Dataset 30	0.76	-0.05

Όσον αφορά την μεταβλητή Maternal age, οι τιμές των δεικτών DI και SPD βρίσκονται σε όλα τα datasets μεταξύ τιμών που υποδηλώνουν μη ύπαρξη bias.

Αντίθετα, για την μεταβλητή Smoking προκύπτει το συμπέρασμα ότι σε μόνο 7 από τα 30 datasets που δημιουργήθηκαν δεν εμφανίζεται bias. Επειδή όμως οι τιμές των υπολοίπων datasets ήταν οριακές (πολύ κοντά στο όριο των 0.8) και μάλιστα αυτά τα σύνολα δεδομένων δημιουργήθηκαν έπειτα από αφαίρεση αρκετών δειγμάτων, έγινε περαιτέρω έλεγχος για την συσχέτιση μεταξύ των μεταβλητών Smoking και Preterm_birth μέσω των στατιστικών μεθόδων Chi-square και Fisher's Exact Test. Τα αποτελέσματα έδειξαν συσχέτιση μόνο σε 7 από τα 30 datasets οπότε θεωρήθηκε unbiased και αυτή η μεταβλητή.

3.4 ΔΗΜΙΟΥΡΓΙΑ ΑΝΑΝΕΩΜΕΝΟΥ DATASET

Πριν την εφαρμογή κάθε αλγορίθμου μηχανικής μάθησης (ML) που περιγράφεται στην ενότητα 4.2, επιλέχθηκε ένα συγκεκριμένο dataset στο οποίο εφαρμόστηκε η απαιτούμενη προεπεξεργασία των δεδομένων.

Αρχικά έγινε αποσυμπίεση του αρχείου ZIP στο οποίο είναι αποθηκευμένα τα 30 διαφορετικά datasets που δημιουργήθηκαν με την διαδικασία που αναλύθηκε στην ενότητα 3.3.

Πιο συγκεκριμένα το αρχείο reduced_datasets.zip αποσυμπιέζεται στον φάκελο /content/reduced_data/.

Έγινε χρήση της βιβλιοθήκης zipfile για να ανοίξει το αρχείο και να αποσυμπιεστεί στο συγκεκριμένο path.

Έπειτα πραγματοποιήθηκε προβολή των αρχείων στον αποσυμπιεσμένο φάκελο. Για να επιτευχθεί αυτό χρησιμοποιήθηκε η συνάρτηση os.listdir().

Με την χρήση της ίδιας συνάρτησης (os.listdir()) προβλήθηκε το περιεχόμενο του υποφακέλου preterm_dataset_versions και στη συνέχεια, εξετάστηκε το περιεχόμενο του υποφακέλου /content/reduced_data/content/preterm_dataset_versions/.

Ακολούθησε η φόρτωση του Excel αρχείου και επιλέχθηκε για χρήση στους αλγορίθμους πρόβλεψης το αρχείο reduced_preterm_dataset_1.xlsx, το οποίο βρίσκεται στον υποφάκελο preterm_dataset_versions και φορτώνεται σε ένα DataFrame της βιβλιοθήκης pandas (με χρήση της συνάρτησης pd.read_excel()).

Τα δεδομένα του Excel αρχείου αποθηκεύονται σε έναν πίνακα δεδομένων και έτσι είναι δυνατή η επεξεργασία και ανάλυσή τους.

Για την επιβεβαίωση ότι η παραπάνω διαδικασία εφαρμόστηκε σωστά γίνεται προβολή των πρώτων γραμμών του DataFrame με την εντολή df.head() (Εικόνα 1, Εικόνα 2).

```
import pandas as pd
import zipfile
import os

# Αποσυμπίεση
zip_path = '/content/reduced_datasets.zip'
with zipfile.ZipFile(zip_path, 'r') as zip_ref:
    zip_ref.extractall('/content/reduced_data/')

# Προβολή αρχείων στον φάκελο
os.listdir('/content/reduced_data/')

os.listdir('/content/reduced_data/content/preterm_dataset_versions/')

# Φόρτωση τελικού αρχείου
df = pd.read_excel('/content/reduced_data/content/preterm_dataset_versions/reduced_preterm_dataset_1.xlsx')

# Προβολή δεδομένων
df.head()
```

Εικόνα 1: Διαδικασία αποσυμπίεσης του dataset

	Maternal age	GA	BW centile	UtA doppler	b-hcg	DVP	MCA doppler	Papp-A	Height	UA doppler	...	Placental location_high posterior with anterior paraplacenta	Placental location_high right	Placental location_ligh anterior with posterior paraplacenta	Placental location_low anterior	Placental location_low posterior	Placental location_low posterior with anterior paraplacenta	Placental location_low right	Pl locatio
0	33.000000	25.285714	16.129898	0.880	0.95	4.0	2.10	1.12	165.0	0.91	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
1	36.435616	32.571429	74.037300	0.675	1.30	3.6	1.87	0.50	175.0	0.79	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
2	42.000000	28.714286	71.680853	1.350	1.00	1.4	1.87	0.90	160.0	1.11	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
3	33.000000	29.285714	22.836726	0.640	1.13	4.1	2.02	1.12	163.0	1.08	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
4	39.454795	31.428571	81.205926	0.805	1.20	4.9	2.01	1.00	168.0	0.97	...	0.0	1.0	0.0	0.0	0.0	0.0	0.0	

5 rows × 73 columns

Εικόνα 2: Αποτελέσματα εντολής df.head()

ΚΕΦΑΛΑΙΟ 4: ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ

ΠΡΟΒΛΕΨΗ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ

4.1 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ

Πριν τη διαδικασία πρόβλεψης πρόωρου τοκετού, ήταν απαραίτητη η κατάλληλη προεπεξεργασία των δεδομένων ώστε να διασφαλιστεί η ποιότητα και η αξιοπιστία των αποτελεσμάτων. Λόγω της τροποποίησης του αρχικού dataset (περιγράφεται στην ενότητα 3.3) κατά την επεξεργασία του επιλεγμένου συνόλου δεδομένων, πολλές τιμές της μεταβλητής Preterm_birth αναγνωρίζονταν ως NaN, χωρίς να είναι στην πραγματικότητα. Για τον λόγο αυτό, όπως φαίνεται στην Εικόνα 3, η μεταβλητή μετατράπηκε σε αριθμητική (ακέραια) μορφή και αφαιρέθηκαν οι εγγραφές που, ενώ φαινομενικά περιείχαν τιμές, στην πραγματικότητα ήταν κενές.

Επιπλέον, αφαιρέθηκε η μεταβλητή GA (εβδομάδα τοκετού), καθώς από σχετική ανάλυση (Εικόνα 4) διαπιστώθηκε ότι επηρέαζε δυσανάλογα την πρόβλεψη, αποκαλύπτοντας ουσιαστικά την τιμή της εξαρτημένης μεταβλητής (Preterm_birth) κατά την εκπαίδευση των μοντέλων.

```
# Καθαρισμός δεδομένων
df['Preterm_birth'] = pd.to_numeric(df['Preterm_birth'], errors='coerce')
df_clean = df.dropna(subset=['Preterm_birth']).copy() # Αφαίρεση των γραμμών με τιμή NaN
df_clean = df_clean.drop(columns=['GA']) # Αφαίρεση γιατί επηρεάζει σημαντικά την πρόβλεψη
df_clean['Preterm_birth'] = df_clean['Preterm_birth'].astype(int)
```

Εικόνα 3: Καθαρισμός δεδομένων

```
import matplotlib.pyplot as plt

importances = rf.feature_importances_
feature_names = X.columns
indices = np.argsort(importances)[::-1]

plt.figure(figsize=(10,6))
plt.title("Feature Importances")
plt.bar(range(X.shape[1]), importances[indices])
plt.xticks(range(X.shape[1]), feature_names[indices], rotation=90)
plt.tight_layout()
plt.show()
```

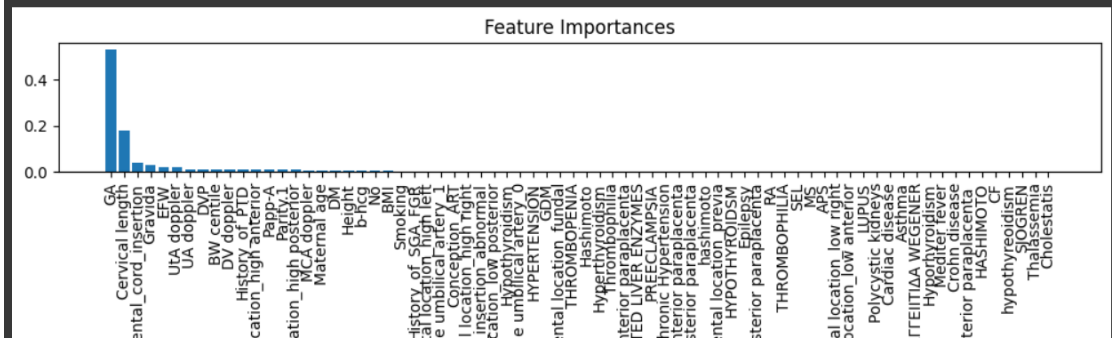

Εικόνα 4: Εύρεση σημαντικότερου χαρακτηριστικού στην διαδικασία πρόβλεψης

Για την εκπαίδευση και την εσωτερική επικύρωση, το σύνολο δεδομένων χωρίστηκε σε δύο υποσύνολα σε αναλογία 70%-30%. Ο διαχωρισμός πραγματοποιήθηκε πριν την εφαρμογή της τεχνικής εξισορρόπησης SMOTE (Synthetic Minority Over-sampling Technique), ώστε να αποφευχθεί η εισαγωγή τεχνητής πληροφορίας στο test set (Εικόνα 5).

```
X = df_clean.drop(columns=['Preterm_birth']) # Όλες οι μεταβλητές του dataset εκτός της Preterm_birth
y = df_clean['Preterm_birth'] # Η μεταβλητή στόχος (Preterm_birth)

# Διαχωρισμός σε Train(70%)/Test(30%) (πριν την εξισορρόπηση)
# random_state=42: αναπαραγωγιμότητα του ίδιου αποτελέσματος
# stratify=y: απαλοιφή ανισορροπιών στα δύο sets
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

# Εξισορρόπηση μόνο στο training set
sm = SMOTE(random_state=42)
X_train_balanced, y_train_balanced = sm.fit_resample(X_train, y_train)
```

Εικόνα 5: Εκπαίδευση, Εσωτερική επικύρωση και Εξισορρόπηση δεδομένων

Τέλος, διενεργήθηκε 10-πλή διασταυρούμενη επικύρωση (10-fold cross-validation) για την αποφυγή υπερεκπαίδευσης των μοντέλων. Η διαδικασία αυτή διέφερε ελαφρώς ανάλογα τον αλγόριθμο που χρησιμοποιήθηκε κάθε φορά και παρουσιάζεται αναλυτικά στην παρακάτω ενότητα.

4.2 ΑΛΓΟΡΙΘΜΟΙ ΠΡΟΒΛΕΨΗΣ ΠΡΟΩΡΟΥ ΤΟΚΕΤΟΥ

Μετά την ολοκλήρωση της προεπεξεργασίας των δεδομένων, εφαρμόστηκαν μοντέλα πρόβλεψης πρόωρου τοκετού (PTB), με στόχο τη βέλτιστη ακρίβεια πρόβλεψης. Για την υλοποίηση των μοντέλων χρησιμοποιήθηκε η βιβλιοθήκη scikit-learn.

Στη συνέχεια περιγράφονται αναλυτικά τα μοντέλα που χρησιμοποιήθηκαν, καθώς και η διαδικασία εφαρμογής και αξιολόγησης κάθε ενός από αυτά.

i) **Random Forest (Τυχαίο Δάσος)** (Εικόνα 6), μία μέθοδος συνόλου που κατασκευάζει πολλαπλά δέντρα αποφάσεων και συνδυάζει τα αποτελέσματά τους για τη βελτίωση της ακρίβειας και τον έλεγχο της υπερεκπαίδευσης. Μπορεί να διαχειριστεί μεγάλα σύνολα δεδομένων με υψηλή διαστατικότητα, προσφέροντας καλή ισορροπία μεταξύ προκατάληψης και διακύμανσης.

Στη μελέτη αυτή , ο αλγόριθμος εκπαιδεύτηκε με χρήση των προεπεξεργασμένων και εξισορροπημένων δεδομένων. Για την αποφυγή υπερεκπαίδευσης και την εξαγωγή αξιόπιστων μετρικών, εφαρμόστηκε 10-fold cross-validation, με τυχαιοποιημένη και stratified κατανομή. Προκειμένου να αντιμετωπιστεί το πρόβλημα ανισορροπίας μεταξύ των δύο κλάσεων χρησιμοποιήθηκε class_weight='balanced'. Ο αριθμός των δέντρων του δάσους ορίστηκε σε 100, μία τιμή που προσφέρει ικανοποιητική ακρίβεια. Το μοντέλο εκπαιδεύτηκε στο balanced training set και αξιολογήθηκε στο test set που είχε κρατηθεί εξ αρχής.

```
# 10-Fold Cross-Validation για internal validation
# n_estimators=100:αριθμός δέντρων στο δάσος (συνήθης επιλογή η συγκεκριμένη τιμή)
# class_weight='balanced': ενίσχυση του βάρους της κλάσης μειοψηφίας
rf = RandomForestClassifier(n_estimators=100, random_state=42, class_weight='balanced')

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(rf, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
rf.fit(X_train_balanced, y_train_balanced)
y_pred = rf.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = rf.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 6: Υλοποίηση Random Forest

ii) **Support Vector Machine (SVM)** (Εικόνα 7), ένα μη γραμμικό μοντέλο που χρησιμοποιεί τον πυρηνικό τεχνικό χειρισμό (kernel trick) για να διαχειρίζεται πολύπλοκες κατανομές δεδομένων. Είναι αποδοτικό σε δεδομένα υψηλής διαστατικότητας και απαιτεί μικρή μνήμη, γεγονός που το καθιστά κατάλληλο για τα σύνθετα και ποικίλα δεδομένα της μαιευτικής.

```
# Κανονικοποίηση (μετασχηματισμός των δεδομένων ώστε να έχουν μέσο όρο 0 και τυπική απόκλιση 1)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Εξισορρόπηση μόνο στο training set
sm = SMOTE(random_state=42)
X_train_balanced, y_train_balanced = sm.fit_resample(X_train, y_train)

# 10-Fold Cross-Validation για internal validation
# kernel='rbf': κατάλληλο για μη γραμμικά δεδομένα
# class_weight='balanced': ενίσχυση του βάρους της κλάσης μειοψηφίας
svm = SVC(kernel='rbf', probability=True, random_state=42, class_weight='balanced')

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(svm, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
svm.fit(X_train_balanced, y_train_balanced)
y_pred = svm.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = svm.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 7: Υλοποίηση SVM

Ο αλγόριθμος εφαρμόστηκε με χρήση του μη γραμμικού πυρήνα 'rbf', κατάλληλου για την ανάλυση δεδομένων με μη γραμμικά όρια απόφασης. Ορίστηκε class_weight='balanced' ώστε να αντιμετωπιστεί η ανισορροπία της εξαρτημένης μεταβλητής. Προτού γίνει η εκπαίδευση του μοντέλου, εφαρμόστηκε κανονικοποίηση στα χαρακτηριστικά μέσω του StandardScaler, ώστε όλα τα δεδομένα να έχουν μέσο

όρο 0 και τυπική απόκλιση 1. Ακολούθησε εξισορρόπηση του training set με την τεχνική SMOTE. Για την εσωτερική επικύρωση, χρησιμοποιήθηκε 10-fold cross-validation. Το μοντέλο εκπαιδεύτηκε στο balanced training set και αξιολογήθηκε στο test set.

iii) **Logistic Regression (Λογιστική Παλινδρόμηση)** (Εικόνα 8), ένα γραμμικό μοντέλο για δυαδική ταξινόμηση που παρέχει πιθανοτικές προβλέψεις. Επιλέχθηκε για την απλότητά του και την εγγενή δυνατότητα ερμηνείας.

Εφαρμόστηκε με τον βελτιστοποιημένο 'liblinear', κατάλληλο για μικρού μεγέθους datasets και δυαδική ταξινόμηση. Χρησιμοποιήθηκε η ρύθμιση class_weight='balanced' για την αντιμετώπιση της ανισορροπίας των κλάσεων και τέθηκε max_iter=1000 για την αποφυγή αποτυχίας σύγκλισης λόγω του αριθμού των χαρακτηριστικών και της πολυπλοκότητας των δεδομένων. Αξιοποιήθηκε τεχνική 10-fold cross-validation με stratifed κατανομή για την εσωτερική αξιολόγηση του μοντέλου. Το τελικό μοντέλο εκπαιδεύτηκε στο balanced training set και δοκιμάστηκε στο test set.

```
# 10-Fold Cross-Validation για internal validation
# solver='liblinear': κατάλληλο για μικρά datasets και δυαδική ταξινόμηση
# class_weight='balanced': ενίσχυση του βάρους της κλάσης μειοψηφίας
# max_iter=1000: διασφάλιση ότι το μοντέλο συγκλίνει (συνήθης χρήση αυτής της τιμής)
logreg = LogisticRegression(solver='liblinear', random_state=42, class_weight='balanced', max_iter=1000)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(logreg, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
logreg.fit(X_train_balanced, y_train_balanced)
y_pred = logreg.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = logreg.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 8: Υλοποίηση Logistic Regression

iv) **K-Nearest Neighbors (KNN)** (Εικόνα 9), ένας απλός, βασισμένος σε παραδείγματα αλγόριθμος, που ταξινομεί ένα σημείο δεδομένων με βάση την πλειοψηφία των πιο κοντινών γειτόνων του. Είναι εύκολος στην εφαρμογή και ιδανικός ως σημείο αναφοράς για τη σύγκριση πιο σύνθετων μοντέλων.

Για την εφαρμογή του αλγορίθμου, επιλέχθηκε τιμή n_neighbors=5, που αποτελεί συχνά χρησιμοποιούμενη τιμή για την αρχική αξιολόγηση. Πριν την εφαρμογή του όμως, τα δεδομένα υποβλήθηκαν σε κανονικοποίηση ώστε όλα τα χαρακτηριστικά να αποκτήσουν συγκρίσιμη κλίμακα (μέσος όρος 0 και τυπική απόκλιση 1). Η εξισορρόπηση της εξαρτημένης μεταβλητής πραγματοποιήθηκε μόνο στο training set μέσω της μεθόδου SMOTE, όπως και στους υπόλοιπους αλγορίθμους. Ακολούθως, εφαρμόστηκε 10-fold cross-validation και υπολογίστηκαν οι βασικές μετρικές απόδοσης. Το τελικό μοντέλο εκπαιδεύτηκε στο balanced training set και δοκιμάστηκε στο test set.

```
# Κανονικοποίηση (μετασχηματισμός των δεδομένων ώστε να έχουν μέσο όρο 0 και τυπική απόκλιση 1)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Εξισορρόπηση μόνο στο training set
sm = SMOTE(random_state=42)
X_train_balanced, y_train_balanced = sm.fit_resample(X_train_scaled, y_train)

# 10-Fold Cross-Validation για internal validation
# n_neighbors=5: αριθμός γειτόνων (συνήθης χρήση αυτής της τιμής)
knn = KNeighborsClassifier(n_neighbors=5)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(knn, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
knn.fit(X_train_balanced, y_train_balanced)
y_pred = knn.predict(X_test_scaled) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = knn.predict_proba(X_test_scaled)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 9: Υλοποίηση KNN

v) **Decision Tree (Δέντρο Αποφάσεων)** (Εικόνα 10), που χρησιμοποιεί δενδροειδή δομή αποφάσεων και συνεπειών για την ταξινόμηση. Είναι εύκολο στην κατανόηση και στην ερμηνεία, κατάλληλο για αρχική εξερεύνηση των δεδομένων.

Κατά την εφαρμογή του, για την ενίσχυση της ευαισθησίας προς την κλάση μειοψηφίας (Preterm_birth - πρόωρος τοκετός), χρησιμοποιήθηκε η παράμετρος class_weight='balanced', που αναπροσαρμόζει αυτόματα τα βάρη των κλάσεων. Η εσωτερική επικύρωση πραγματοποιήθηκε με 10-fold cross-validation, όπως και στους υπόλοιπους αλγορίθμους, και αξιολογήθηκαν οι έξι βασικές μετρικές ταξινόμησης. Η εκπαίδευση έγινε στο balanced training set και η τελική αξιολόγηση στο test set.

```
# 10-Fold Cross-Validation για internal validation
# class_weight='balanced': ενίσχυση του βάρους της κλάσης μειοψηφίας
dt = DecisionTreeClassifier(random_state=42, class_weight='balanced')

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(dt, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
dt.fit(X_train_balanced, y_train_balanced)
y_pred = dt.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = dt.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 10: Υλοποίηση Decision Tree

vi) **Gradient Boosting** (Εικόνα 11), τεχνική συνόλου που κατασκευάζει μοντέλα διαδοχικά, με κάθε νέο μοντέλο να διορθώνει τα λάθη των προηγούμενων. Είναι ισχυρό εργαλείο για τη βελτίωση της ακρίβειας.

Η εκπαίδευση του balanced training set πραγματοποιήθηκε με τις προεπιλεγμένες παραμέτρους και σταθερό τυχαίο seed για αναπαραγωγιμότητα. Η αξιολόγηση έγινε με 10-fold cross-validation, βάσει των έξι μετρικών απόδοσης και η τελική πρόβλεψη πραγματοποιήθηκε στο test set.

```
# 10-Fold Cross-Validation για internal validation
gb = GradientBoostingClassifier(random_state=42)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(gb, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
gb.fit(X_train_balanced, y_train_balanced)
y_pred = gb.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = gb.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 11: Υλοποίηση Gradient Boosting

vii) **AdaBoost (Adaptive Boosting)** (Εικόνα 12), μέθοδος συνόλου που συνδυάζει πολλούς αδύναμους ταξινομητές δημιουργώντας έναν ισχυρό, εστιάζοντας στα πιο δύσκολα προς ταξινόμηση παραδείγματα.

Η υλοποίηση χρησιμοποιεί το προεπιλεγμένο base estimator (decision stumps) και αξιολογείται μέσω 10-fold cross-validation με χρήση τυπικών μετρικών ταξινόμησης. Ο τελικός ταξινομητής εκπαιδεύεται στο εξισορροπημένο training set και αξιολογείται στο test set.

```
# 10-Fold Cross-Validation για internal validation
ab = AdaBoostClassifier(random_state=42)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(ab, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
ab.fit(X_train_balanced, y_train_balanced)
y_pred = ab.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = ab.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 12: Υλοποίηση AdaBoost

viii) **XGBoost (Extreme Gradient Boosting)** (Εικόνα 13), προηγμένος αλγόριθμος ενισχυμένης βαθμιδωτής ενίσχυσης, γνωστός για την αποδοτικότητά του και την υψηλή επίδοση σε δομημένα δεδομένα. Είναι εξαιρετικός στη διαχείριση ελλιπών δεδομένων και πολύ παραμετροποιήσιμος.

Η διαδικασία περιλαμβάνει την επαναλαμβανόμενη εκπαίδευση διαδοχικών μοντέλων, όπου κάθε νέο μοντέλο προσπαθεί να διορθώσει τα λάθη των

προηγούμενων, βελτιώνοντας έτσι την ακρίβεια του τελικού συνδυασμού. Η εκπαίδευση πραγματοποιήθηκε με 10-fold cross-validation στο εξισορροπημένο training set, χρησιμοποιώντας διάφορες μετρικές ταξινόμησης για αξιολόγηση. Τέλος, ο τελικός ταξινομητής εκπαιδεύτηκε στο πλήρες balanced training set και αξιολογήθηκε στο test set.

```
# 10-Fold Cross-Validation για internal validation
# eval_metric='logloss': μετρική εκπαίδευσης κατάλληλη για δυαδική αναζήτηση
# scale_pos_weight=1: καμία κατηγορία ('0' ή '1') δεν έχει πλεονέκτημα
xgb = XGBClassifier(eval_metric='logloss', random_state=42, scale_pos_weight=1)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(xgb, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
xgb.fit(X_train_balanced, y_train_balanced)
y_pred = xgb.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = xgb.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 13: Υλοποίηση XGBoost

ix) **Naive Bayes** (Εικόνα 14), πιθανολογικός ταξινομητής που βασίζεται στο θεώρημα του Bayes, υποθέτοντας ανεξαρτησία μεταξύ των προβλεπτικών μεταβλητών. Είναι ιδιαίτερα αποδοτικός σε μικρά σύνολα δεδομένων με κατηγορικά χαρακτηριστικά.

Η εκπαίδευση και η αξιολόγηση πραγματοποιήθηκαν με 10-fold cross-validation στο εξισορροπημένο training set, χρησιμοποιώντας τυπικές μετρικές ταξινόμησης για να εκτιμηθεί η απόδοση του μοντέλου. Στη συνέχεια, το τελικό μοντέλο εκπαιδεύτηκε στο πλήρες balanced training set και αξιολογήθηκε στο ανεξάρτητο test set.

```
# 10-Fold Cross-Validation για internal validation
nb = GaussianNB()

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(nb, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
nb.fit(X_train_balanced, y_train_balanced)
y_pred = nb.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = nb.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 14: Υλοποίηση Naive Bayes

x) **Bagging (Bootstrap Aggregating)** (Εικόνα 15), μέθοδος συνόλου που βελτιώνει τη σταθερότητα και την ακρίβεια εκπαιδεύοντας πολλά μοντέλα σε διαφορετικά υποσύνολα των δεδομένων. Μειώνει τη διακύμανση και αποτρέπει την υπερεκπαίδευση.

Εκπαιδεύτηκαν 50 δέντρα σε διαφορετικά τυχαία δείγματα του training set και το τελικό αποτέλεσμα προέκυψε από την πλειοψηφική ψήφο των δέντρων. Η απόδοση του μοντέλου εκτιμήθηκε μέσω 10-fold cross-validation στο εξισορροπημένο training set με χρήση τυπικών μετρικών ταξινόμησης. Τέλος, το μοντέλο εκπαιδεύτηκε στο πλήρες balanced training set και αξιολογήθηκε στο test set.

```
# 10-Fold Cross-Validation για internal validation
# estimator=DecisionTreeClassifier: βασικός ταξινομητής
# n_estimators=50: αριθμός δέντρων απόφασης (τυχαία επιλογή αυτής της τιμής)
# n_jobs=-1: χρήση όλων των πυρήνων CPU για παράλληλη εκπαίδευση
bagging = BaggingClassifier(estimator=DecisionTreeClassifier(random_state=42), n_estimators=50, random_state=42, n_jobs=-1)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(bagging, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
bagging.fit(X_train_balanced, y_train_balanced)
y_pred = bagging.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = bagging.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 15: Υλοποίηση Bagging

xi) **Μέθοδοι Συνδυασμού Μοντέλων (Model Ensemble Methods)**, όπως **Voting** και **Stacking** (Εικόνα 16), δοκιμάστηκαν για περαιτέρω βελτίωση της επίδοσης.

- Voting: συνδυάζει τις προβλέψεις πολλών μοντέλων, αξιοποιώντας τα πλεονεκτήματα του καθενός.
- Stacking: χρησιμοποιεί τις προβλέψεις διαφόρων μοντέλων ως είσοδο σε ένα ανώτερου επιπέδου μοντέλο που δίνει την τελική πρόβλεψη.

Ο συνδυαστικός αλγόριθμος Voting Classifier αξιοποιεί τη συλλογιστική περισσότερων βασικών ταξινομητών, εν προκειμένω μίας λογιστικής παλινδρόμησης και ενός μοντέλου XGBoost, για να ενισχύσει την ακρίβεια της πρόβλεψης. Χρησιμοποιήθηκε η τεχνική «soft voting», όπου η τελική πρόβλεψη προκύπτει από τον μέσο όρο των πιθανοτήτων των επιμέρους μοντέλων. Η απόδοση αξιολογήθηκε μέσω 10-fold cross-validation στο εξισορροπημένο training set με χρήση διαφόρων μετρικών ταξινόμησης. Ο τελικός ταξινομητής εκπαιδεύτηκε στο πλήρες balanced training set και αξιολογήθηκε στο test set.

```python
# Ορισμός επιμέρους μοντέλων
# solver='liblinear': κατάλληλο για μικρά datasets και δυαδική ταξινόμηση
# class_weight='balanced': ενίσχυση του βάρους της κλάσης μειοψηφίας
# max_iter=1000: διασφάλιση ότι το μοντέλο συγκλίνει (συνήθης χρήση αυτής της τιμής)
# eval_metric='logloss': μετρική εκπαίδευσης κατάλληλη για δυαδική αναζήτηση
# scale_pos_weight=1: καμία κατηγορία ('0' ή '1') δεν έχει πλεονέκτημα
logreg = LogisticRegression(solver='liblinear', random_state=42, class_weight='balanced', max_iter=1000)
xgb = XGBClassifier(eval_metric='logloss', random_state=42, scale_pos_weight=1)

# 10-Fold Cross-Validation για internal validation
# voting='soft': χρησιμοποιεί τις προβλεπόμενες πιθανότητες των μοντέλων και παίρνει τον μέσο όρο για την τελική πρόβλεψη
# n_jobs=-1: χρήση όλων των πυρήνων CPU για παράλληλη εκπαίδευση
voting = VotingClassifier(estimators=[('logistic regression', logreg), ('xg boost', xgb)], voting='soft', n_jobs=-1)

cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['accuracy', 'precision', 'recall', 'f1', 'roc_auc', 'average_precision']
cv_results = cross_validate(voting, X_train_balanced, y_train_balanced, cv=cv, scoring=scoring)
# Εκτύπωση του μέσου όρου κάθε μετρικής από τα 10 folds
for metric in scoring:
    print(f"{metric.upper()}: {np.mean(cv_results['test_' + metric]):.4f}")

# Τελική εκπαίδευση στο balanced training set και αξιολόγηση στο test set
voting.fit(X_train_balanced, y_train_balanced)
y_pred = voting.predict(X_test) # Προβλέψεις ανά κατηγορία ('0' ή '1')
y_proba = voting.predict_proba(X_test)[:, 1] # Πιθανότητες για την κατηγορία '1' (πρόωρος τοκετός)
```

Εικόνα 16: Υλοποίηση Optimized Voting

Η επιλογή των μοντέλων που περιγράφηκαν παραπάνω καλύπτει ένα ευρύ φάσμα απλών, συνδυαστικών και ενισχυμένων αλγορίθμων, επιτρέποντας μία συγκριτική ανάλυση της απόδοσής τους. Παρακάτω παρουσιάζονται αναλυτικά οι μετρικές αξιολόγησης που χρησιμοποιήθηκαν.

4.3 ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ ΑΠΟΔΟΣΗΣ ΜΟΝΤΕΛΩΝ

Για την αποτίμηση της απόδοσης των ταξινομητικών μοντέλων που εφαρμόστηκαν στην παρούσα μελέτη, χρησιμοποιήθηκαν έξι βασικές μετρικές αξιολόγησης [20]:

- **ROC-AUC (Receiver Operating Characteristic – Area Under Curve)**

Η ROC-AUC μετρά την ικανότητα ενός μοντέλου να διαχωρίζει τις δύο κλάσεις, υπολογίζοντας την περιοχή κάτω από την καμπύλη ROC, η οποία απεικονίζει την ευαισθησία (Recall) έναντι της Ψευδώς Θετικής Ποσοστιαίας Τιμής (False Positive Rate). Τιμή ROC-AUC ίση με 1 υποδηλώνει τέλεια διάκριση, ενώ τιμή 0.5 ισοδυναμεί με τυχαία πρόβλεψη. Η συγκεκριμένη μετρική είναι ιδιαίτερα χρήσιμη σε προβλήματα ανισορροπίας μεταξύ κλάσεων.

- **PR-AUC (Precision-Recall – Area Under Curve)**

Η PR-AUC είναι πιο κατάλληλη όταν η κλάση ενδιαφέροντος (Preterm_birth=1) αποτελεί μειοψηφία στο σύνολο των δειγμάτων. Αντιπροσωπεύει την περιοχή κάτω από την καμπύλη Precision – Recall και αξιολογεί την ικανότητα του μοντέλου να διατηρεί υψηλή ακρίβεια πρόβλεψης (Precision) όταν αυξάνεται η ανάκληση (Recall).

- **Accuracy (Ακρίβεια)**

Ο λόγος των σωστών προβλέψεων προς τον συνολικό αριθμό δειγμάτων. Αποτελεί την πιο ευρέως χρησιμοποιούμενη μετρική.

- **Precision (Ακρίβεια Πρόβλεψης)**

Ορίζεται ως το ποσοστό των σωστά προβλεπόμενων θετικών παραδειγμάτων επί του συνόλου των προβλέψεων ως θετικά. Είναι ιδιαίτερα σημαντική σε εφαρμογές όπου τα ψευδώς θετικά έχουν σημαντικό κόστος ή κλινικές επιπτώσεις.

- **Recall (Ανάκληση ή Ευαισθησία)**

Ο λόγος των σωστά προβλεπόμενων θετικών περιπτώσεων προς τον συνολικό αριθμό των πραγματικά θετικών περιπτώσεων. Στο παρόν ιατρικό πρόβλημα, η υψηλή ανάκληση θεωρείται κρίσιμη, καθώς υποδηλώνει τη δυνατότητα του μοντέλου να εντοπίζει όσο το δυνατόν περισσότερα περιστατικά πρόωρου τοκετού.

- **F1 Score**

Ο αρμονικός μέσος των Precision και Recall. Προσφέρει μία ισορροπημένη εκτίμηση όταν χρειάζεται συμβιβασμός μεταξύ των δύο, ειδικά σε περιπτώσεις όπου καμία από τις δύο μετρικές δεν μπορεί να αγνοηθεί.

Οι παραπάνω μετρικές εφαρμόστηκαν σε κάθε μοντέλο μέσω 10-fold cross-validation, χρησιμοποιώντας το εξισορροπημένο σύνολο εκπαίδευσης (training set). Η αναλυτική συγκριτική παρουσίαση των αποτελεσμάτων αυτών, παρουσιάζεται συγκεντρωτικά στην επόμενη ενότητα.

4.4 ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΓΚΡΙΣΗ ΜΟΝΤΕΛΩΝ

Στην παρούσα ενότητα παρουσιάζονται τα αποτελέσματα των πειραμάτων που διεξήχθησαν στο πλαίσιο της προσπάθειας πρόβλεψης πρόωρου τοκετού με αλγορίθμους μηχανικής μάθησης. Αναλυτικά οι τιμές που προέκυψαν για κάθε μετρική προβάλλονται στον Πίνακα 4.

Πίνακας 4: Αποτελέσματα πρόβλεψης πρόωρου τοκετού

Metric/Model	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Random Forest	0.96	0.85	0.96	0.90	0.97	0.95
SVM	0.58	1.00	0.11	0.19	0.69	0.40
Logistic Regression	0.95	0.85	0.98	0.91	0.98	0.92
K-Nearest Neighbors	0.93	0.66	0.83	0.74	0.91	0.76
Decision Tree	0.94	0.85	0.85	0.85	0.90	0.75
Gradient Boosting	0.96	0.83	0.94	0.88	0.97	0.94
AdaBoost	0.96	0.79	0.96	0.87	0.98	0.93
XGBoost	0.96	0.85	0.94	0.89	0.98	0.92
Naïve Bayes	0.80	0.78	0.60	0.67	0.83	0.69
Bagging	0.95	0.85	0.94	0.89	0.97	0.89

Metric/Model	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Optimized Voting	0.96	0.85	0.98	0.91	0.98	0.93

Ο Random Forest παρουσίασε εξαιρετικά αποτελέσματα σε όλες τις μετρικές, με ιδιαίτερα υψηλό Recall (0.96) και Accuracy (0.96) για αυτό και είναι κατάλληλος για προβλήματα όπως η πρόβλεψη πρόωρου τοκετού, όπου η αναγνώριση των θετικών περιπτώσεων είναι κρίσιμη.

Με την χρήση του Support Vector Machine (SVM) αν και η Precision ήταν τέλεια (1.00), το μοντέλο απέτυχε να αναγνωρίσει τη μεγάλη πλειοψηφία των θετικών περιπτώσεων (Recall: 0.11), οδηγώντας σε πολύ χαμηλό F1-score. Συνεπώς, κρίνεται ακατάλληλο για την παρούσα ανάλυση.

Η Logistic Regression παρά το σχετικά απλό μοντέλο πέτυχε πολύ υψηλό Recall (0.98) και F1-score (0.91).

Ο K-Nearest Neighbors (KNN) εμφάνισε καλή Accuracy (0.93) και Recall (0.83), όμως η Precision (0.66) είναι σχετικά χαμηλή, υποδεικνύοντας πιθανές ψευδώς θετικές προβλέψεις.

Η πρόβλεψη με το Decision Tree παρουσίασε σταθερή απόδοση σε όλες τις μετρικές (Precision, Recall και F1: 0.85), όμως υστερεί ελαφρώς σε σύγκριση με πιο εξελιγμένες τεχνικές όπως τα συνδυαστικά μοντέλα.

Ο Gradient Boosting πέτυχε πολύ υψηλές τιμές Accuracy (0.96) και Recall (0.94), γεγονός που τον καθιστά ιδανικό για εφαρμογές που απαιτούν υψηλή ανίχνευση θετικών περιπτώσεων.

Ο AdaBoost είχε αντίστοιχη απόδοση με τον Gradient Boosting, με πολύ καλό Recall (0.96) και F1-score (0.87). Ελαφρώς χαμηλότερη Precision (0.79), αλλά εξαιρετική συνολικά απόδοση.

Ο XGBoost συνδυάζει υψηλή ακρίβεια και ισορροπία, με F1-score (0.89) και πολύ καλές τιμές σε όλες τις υπόλοιπες μετρικές.

Το μοντέλο του Naïve Bayes αν και γρήγορο και εύκολο στην εφαρμογή, υστερεί στις βασικές μετρικές (Recall: 0.60, F1-score: 0.67), και έτσι δεν συστήνεται για την παρούσα περίπτωση.

Ο Bagging Classifier αποδίδει παρόμοια με τα καλύτερα μοντέλα, με F1-score 0.89 και υψηλές τιμές Precision/Recall, αξιοποιώντας τη δύναμη του συνδυασμού απλών μοντέλων.

Ο Optimized Voting Classifier συνδυάζει τα πλεονεκτήματα πολλών ισχυρών μοντέλων και πετυχαίνει πολύ υψηλό Recall (0.98) και F1-score (0.91).

Στο παρακάτω διάγραμμα (Εικόνα 17) παρουσιάζονται οι ROC καμπύλες για όλους τους ταξινομητές που χρησιμοποιήθηκαν στην παρούσα εργασία. Η ROC (Receiver Operating Characteristic) καμπύλη απεικονίζει τη σχέση μεταξύ του False Positive Rate (FPR) και του True Positive Rate (TPR), προσφέροντας μία συνολική εικόνα της διαχωριστικής ικανότητας κάθε μοντέλου. Όπως παρατηρείται, τα περισσότερα συνδυαστικά μοντέλα παρουσιάζουν καμπύλες που βρίσκονται κοντά στην άνω αριστερή γωνία, υποδεικνύοντας πολύ καλή απόδοση.

Στη συνέχεια παρουσιάζεται και το διάγραμμα (Εικόνα 18) που απεικονίζει τις καμπύλες Precision-Recall (PR) για κάθε μοντέλο. Οι συγκεκριμένες καμπύλες είναι ιδιαίτερα χρήσιμες σε περιπτώσεις ανισόρροπων δεδομένων. Όσο πιο «τετραγωνισμένη» και ψηλά βρίσκεται η καμπύλη, τόσο καλύτερη είναι η απόδοση του μοντέλου. Παρατηρείται ότι τα μοντέλα Gradient Boosting, AdaBoost, XGBoost και Optimized Voting υπερτερούν σαφώς έναντι των υπολοίπων, επιτυγχάνοντας υψηλό PR-AUC και διατηρώντας υψηλή ακρίβεια.

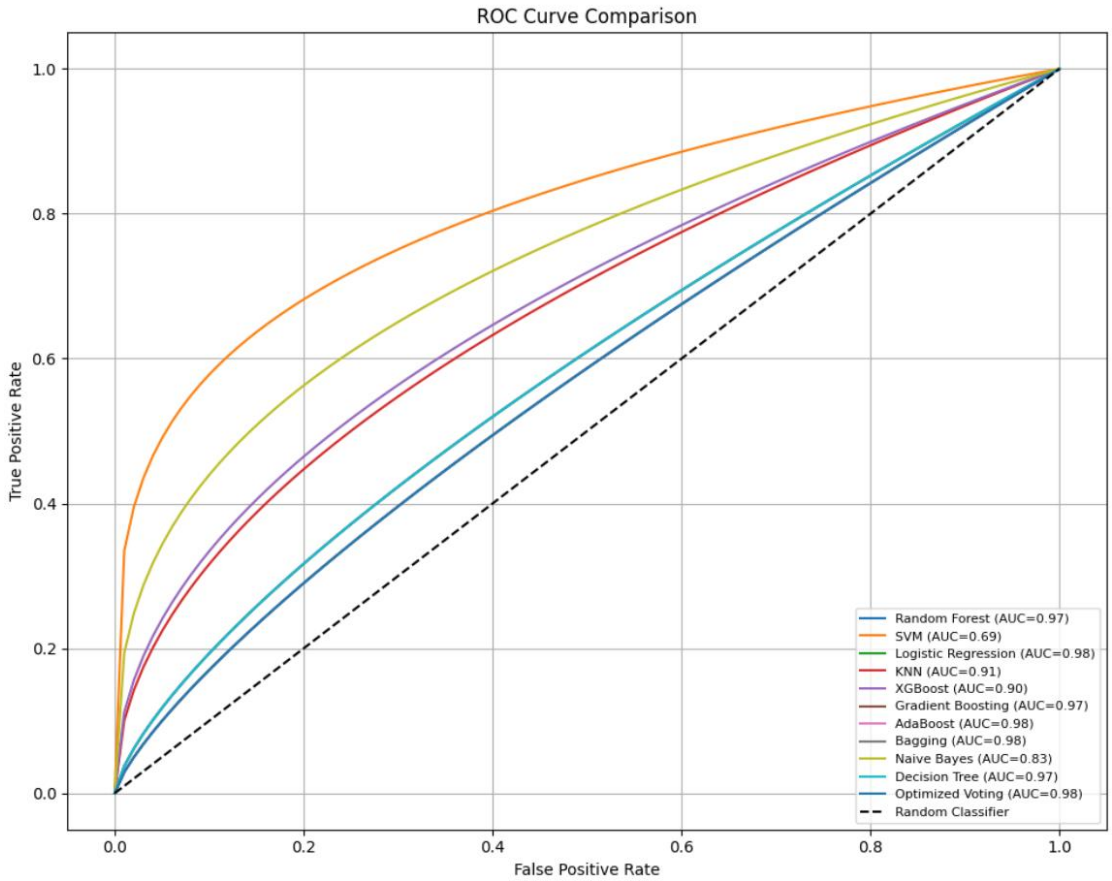

Εικόνα 17: Καμπύλες ROC

Από τα παραπάνω προκύπτει ότι τα συνδυαστικά (ensemble) μοντέλα (Random Forest, Gradient Boosting, XGBoost, AdaBoost, Bagging, και Optimized Voting) ξεπέρασαν με διαφορά τα υπόλοιπα σε ακρίβεια, ισορροπία και συνολική απόδοση. Ιδιαίτερη έμφαση μάλιστα πρέπει να δοθεί στον Optimized Voting Classifier, που

συγκεντρώνει τα πλεονεκτήματα διαφορετικών μοντέλων και έτσι επιτυγχάνει άριστη ικανότητα πρόβλεψης. Η ενσωμάτωση αυτών των μοντέλων σε ιατρικές εφαρμογές πρόγνωσης ενδέχεται να συμβάλει σημαντικά στην έγκαιρη ανίχνευση περιστατικών, λόγω της αυξημένης ακρίβειας και αξιοπιστίας που πετυχαίνουν, καθώς και στην καλύτερη διαχείριση των κινδύνων για τις εγκυμονούσες.

Αντίθετα, ο SVM, παρά την υψηλή Precision, δεν κατάφερε να ανταπεξέλθει στις απαιτήσεις της πρόβλεψης πρόωρου τοκετού λόγω χαμηλού Recall. Παρόμοια, ο Naïve Bayes, αν και απλός, δεν παρουσιάζει την απαιτούμενη απόδοση για την παρούσα εφαρμογή.

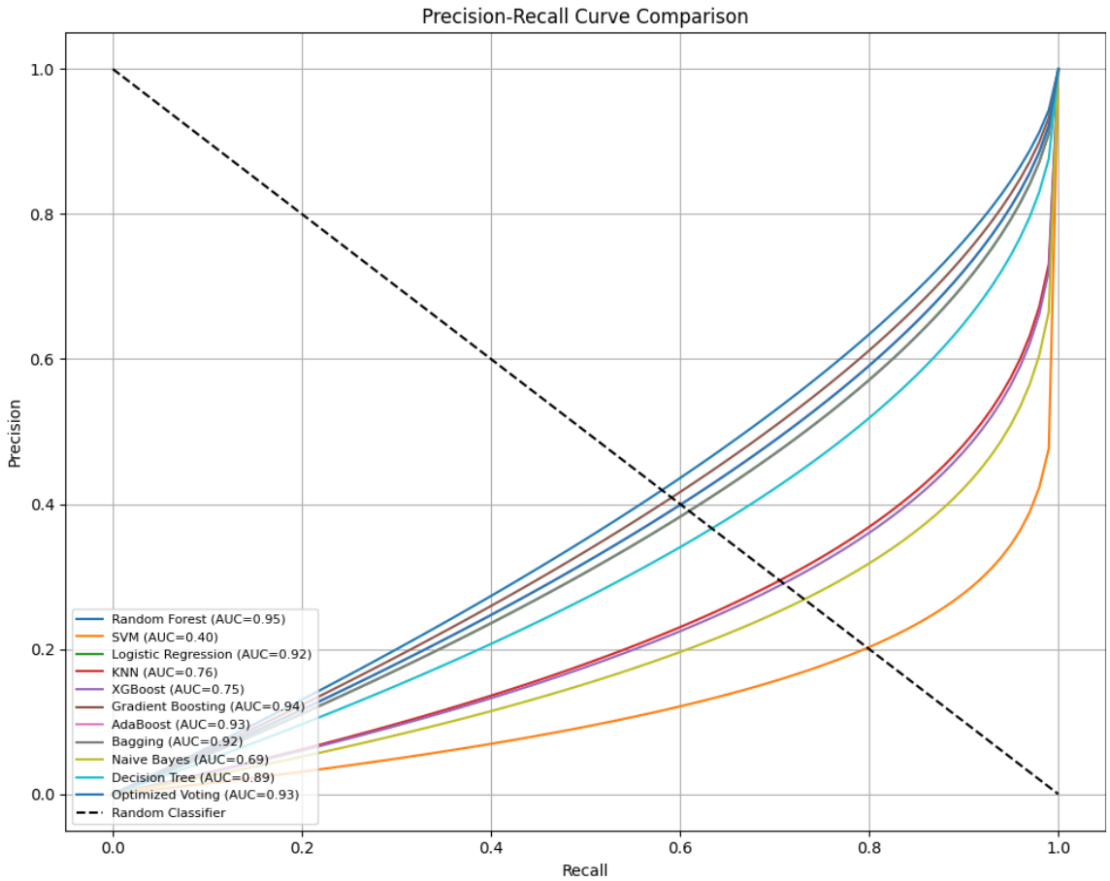

Εικόνα 18: Καμπύλες PR

4.5 ΣΥΓΚΡΙΣΗ ΜΕ ΠΡΟΗΓΟΥΜΕΝΗ ΑΝΑΛΥΣΗ ΚΑΙ ΈΛΕΓΧΟΣ ΣΤΑΤΙΣΤΙΚΗΣ ΣΗΜΑΝΤΙΚΟΤΗΤΑΣ

Στην ενότητα αυτή πραγματοποιείται η σύγκριση των αποτελεσμάτων της παρούσας μελέτης με εκείνα που είχαν προκύψει σε προηγούμενη ανάλυση για την πρόβλεψη του πρόωρου τοκετού, με χρήση του αρχικού dataset που περιείχε sampling bias.

Οι αλγόριθμοι και οι μετρικές αξιολόγησης που χρησιμοποιήθηκαν στην μελέτη με το αρχικό dataset [5] ήταν οι ίδιες και τα αποτελέσματά της παρουσιάζονται στον Πίνακα 5.

Πίνακας 5: Αποτελέσματα πρόβλεψης πρόωρου τοκετού στο αρχικό dataset [5]

Metric/Model	Accuracy	Precision	Recall	F1
Random Forest	0.86	0.88	0.90	0.86
SVM	0.69	1.00	0.07	0.12
Logistic Regression	0.90	0.92	0.84	0.86
K-Nearest Neighbors	0.67	0.54	0.29	0.37
Decision Tree	0.82	0.88	0.77	0.78
Gradient Boosting	0.85	0.88	0.87	0.84
AdaBoost	0.85	0.88	0.86	0.83
XGBoost	0.86	0.89	0.97	0.84
Naïve Bayes	0.79	0.90	0.42	0.55
Bagging	0.85	0.88	0.86	0.83
Optimized Voting	0.94	0.90	0.97	0.91

Όπως φαίνεται στον παραπάνω πίνακα (Πίνακας 5), τα περισσότερα μοντέλα επιτυγχάνουν ικανοποιητικά αποτελέσματα. Οι τιμές τους όμως, δεν είναι υψηλές σε όλες τις μετρικές, γεγονός που υποδεικνύει ότι υπάρχουν περιθώρια για βελτίωση που όντως επιτεύχθηκε βάσει των αποτελεσμάτων που περιγράφονται στο προηγούμενο κεφάλαιο.

Για να διερευνηθεί αν η βελτίωση που παρατηρείται στα αποτελέσματα της παρούσας μελέτης συγκριτικά με εκείνα της προηγούμενης είναι στατιστικά σημαντική, εφαρμόστηκε ο έλεγχος Wilcoxon signed-rank. Η επιλογή του συγκεκριμένου μη παραμετρικού ελέγχου βασίστηκε στη σχετική μεθοδολογική τεκμηρίωση του Demšar (2006) [21], ο οποίος προτείνει τη χρήση του για τη στατιστική σύγκριση ταξινομητών σε διαφορετικά σύνολα δεδομένων, όταν δεν πληρούνται παραμετρικές προϋποθέσεις όπως η κανονικότητα της κατανομής των διαφορών.

Στην παρούσα ανάλυση συγκρίθηκαν οι τέσσερις βασικές μετρικές (Accuracy, Precision, Recall και F1-score) για κάθε αλγόριθμο ξεχωριστά, μεταξύ των δύο datasets. Δηλαδή, για κάθε μετρική αξιολογήθηκε αν οι επιδόσεις των ίδιων αλγορίθμων παρουσιάζουν στατιστικά σημαντική διαφορά όταν εφαρμόζονται στο αρχικό και στο νέο dataset αντίστοιχα.

Η διαδικασία υλοποιήθηκε σε περιβάλλον Python με τη χρήση της συνάρτησης wilcoxon() από το πακέτο scipy.stats (Εικόνα 19). Για κάθε μετρική δημιουργήθηκαν δύο λίστες, οι οποίες περιείχαν τις τιμές από τους 11 αλγορίθμους, μία για το αρχικό και μία για το νέο dataset. Οι λίστες αυτές χρησιμοποιήθηκαν ως συζευγμένα δείγματα (paired samples) στον έλεγχο.

```
from scipy.stats import wilcoxon

# Τα scores από τους ίδιους 11 αλγορίθμους σε 2 διαφορετικά datasets
accuracy_before = [0.86, 0.69, 0.90, 0.67, 0.82, 0.85, 0.85, 0.86, 0.79, 0.85, 0.94]
accuracy_after =  [0.96, 0.58, 0.95, 0.93, 0.94, 0.96, 0.96, 0.96, 0.80, 0.95, 0.96]
precision_before= [0.88, 1.00, 0.92, 0.54, 0.88, 0.88, 0.88, 0.89, 0.90, 0.88, 0.90]
precision_after= [0.85, 1.00, 0.85, 0.66, 0.85, 0.83, 0.79, 0.85, 0.78, 0.85, 0.85]
recall_before= [0.90, 0.07, 0.84, 0.29, 0.77, 0.87, 0.86, 0.97, 0.42, 0.86, 0.97]
recall_after= [0.96, 0.11, 0.98, 0.83, 0.85, 0.94, 0.96, 0.94, 0.60, 0.94, 0.98]
f1_before= [0.86, 0.12, 0.86, 0.37, 0.78, 0.84, 0.83, 0.84, 0.55, 0.83, 0.91]
f1_after= [0.90, 0.19, 0.91, 0.74, 0.85, 0.88, 0.87, 0.89, 0.67, 0.89, 0.91]

# Wilcoxon signed-rank test
w_stat, p_val_w = wilcoxon(accuracy_after, accuracy_before)
print(f"Wilcoxon test p-value: {p_val_w:.4f}")
w_stat, p_val_w = wilcoxon(precision_after, precision_before)
print(f"Wilcoxon test p-value: {p_val_w:.4f}")
w_stat, p_val_w = wilcoxon(recall_after, recall_before)
print(f"Wilcoxon test p-value: {p_val_w:.4f}")
w_stat, p_val_w = wilcoxon(f1_after, f1_before)
print(f"Wilcoxon test p-value: {p_val_w:.4f}")

Wilcoxon test p-value: 0.0254
Wilcoxon test p-value: 0.0742
Wilcoxon test p-value: 0.0029
Wilcoxon test p-value: 0.0020
```

Εικόνα 19: Έλεγχος για Στατιστικά Σημαντική Διαφορά μεταξύ των Μετρικών

Τα αποτελέσματα του ελέγχου που αναφέρθηκε παραπάνω, έδειξαν στατιστικά σημαντική διαφορά (p-value< 0.05) στις μετρικές Accuracy (p-value= 0.0254), Recall (p-value= 0.0029) και F1-score (p-value= 0.0020), ενισχύοντας την υπόθεση ότι η απόδοση των ταξινομητών βελτιώθηκε στο νέο dataset. Αντίθετα, για τη μετρική Precision (p-value= 0.0742), η διαφορά δεν κρίνεται στατιστικά σημαντική, γεγονός που υποδηλώνει ότι η ακρίβεια των θετικών προβλέψεων δεν μεταβλήθηκε ουσιαστικά μεταξύ των δύο συνόλων δεδομένων.

Παρόλα αυτά, η p-value της Precision βρίσκεται κοντά στο παραδοσιακό όριο 0.05, γεγονός που μπορεί να θεωρηθεί ως οριακή ένδειξη πιθανής διαφοράς, η οποία όμως δεν είναι αρκετά ισχυρή για να επιβεβαιωθεί με τα δεδομένα που διαθέτουμε [22].

Τα παραπάνω συμπεράσματα, μπορούν να αιτιολογηθούν από την αλλαγή στο dataset, όπου πραγματοποιήθηκε μείωση και ανανέωση του αρχικού συνόλου δεδομένων. Συγκεκριμένα, η μείωση του dataset αφορούσε την τυχαία απομάκρυνση δεδομένων που προκαλούσαν sampling bias. Έτσι φαίνεται πως επιτράπηκε στους αλγορίθμους να μάθουν πιο αντιπροσωπευτικά και αξιόπιστα χαρακτηριστικά [23].

Η ταυτόχρονη βελτίωση τόσο του Recall όσο και του F1-score υποδηλώνει ότι η συνολική ικανότητα των ταξινομητών να εντοπίζουν σωστά τη θετική κλάση αυξήθηκε. Σε προβλήματα με ανισόρροπες τάξεις, όπως το παρόν, είναι σύνηθες η αύξηση του Recall να συνοδεύεται από ελαφρά μείωση στην Precision, ως συνέπεια των επιπλέον θετικών προβλέψεων που ενδέχεται να περιλαμβάνουν και ψευδώς θετικά αποτελέσματα. Στο πλαίσιο αυτό, η μετρική F1-score προτιμάται ως πιο

αντιπροσωπευτική της πραγματικής επίδοσης, καθώς ενσωματώνει και τις δύο διαστάσεις (Precision και Recall) με ισορροπημένο τρόπο [24].

Η οριακή μη στατιστικά σημαντική διαφορά στην Precision υποδηλώνει ότι, παρότι το νέο dataset βελτίωσε τη συνολική απόδοση, η ικανότητα των μοντέλων να αποφεύγουν ψευδώς θετικές προβλέψεις παρέμεινε σταθερή.

Η συνολική εικόνα των αποτελεσμάτων, με σημαντική βελτίωση στις περισσότερες κρίσιμες μετρικές και θετική μεταβολή στην πλειοψηφία των ταξινομητών, επιβεβαιώνει την αποτελεσματικότητα της διαδικασίας προεπεξεργασίας και της δημιουργίας του νέου dataset.

ΚΕΦΑΛΑΙΟ 5: ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ

ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ

5.1 ΣΗΜΑΣΙΑ ΚΑΙ ΑΝΑΓΚΑΙΟΤΗΤΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ

Η ακριβής εκτίμηση της εβδομάδας τοκετού αποτελεί κρίσιμο παράγοντα στην προγεννητική φροντίδα, καθώς επιτρέπει την έγκαιρη ανίχνευση κινδύνων, τον καλύτερο προγραμματισμό των ιατρικών παρεμβάσεων και τη βελτιστοποίηση των εκβάσεων τόσο για τη μητέρα όσο και για το νεογνό. Ειδικότερα, η πρόωρη γέννηση (τοκετός πριν την 37η εβδομάδα κύησης) συνδέεται με αυξημένο κίνδυνο επιπλοκών, όπως αναπνευστική δυσχέρεια, χαμηλό βάρος γέννησης και νεογνική νοσηρότητα. Συνεπώς, η δυνατότητα πρόβλεψης της ακριβούς εβδομάδας τοκετού με τη βοήθεια υπολογιστικών μοντέλων θα μπορούσε να συμβάλει ουσιαστικά στη βελτίωση της μαιευτικής πρακτικής.

Έτσι, το παρόν κεφάλαιο εστιάζει στην εφαρμογή αλγορίθμων μηχανικής μάθησης για την πρόβλεψη της εβδομάδας τοκετού.

5.2 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΚΑΙ ΔΙΑΣΤΑΥΡΟΥΜΕΝΗ ΕΠΙΚΥΡΩΣΗ

Πριν την εκπαίδευση των μοντέλων, πραγματοποιήθηκε διαδικασία καθαρισμού και προετοιμασίας των δεδομένων (Εικόνα 20). Αρχικά, η στήλη GA (Gestational Age – ηλικία κύησης) μετατράπηκε σε αριθμητική μορφή, με χρήση της μεθόδου pd.to_numeric, ενώ τυχόν μη αριθμητικές ή ελλιπείς τιμές (NaN) απομακρύνθηκαν. Στη συνέχεια, δημιουργήθηκε ένα νέο σύνολο δεδομένων όπου η μεταβλητή στόχος ήταν η GA, δηλαδή η εβδομάδα τοκετού, ενώ από τα δεδομένα εξαιρέθηκε η ίδια η GA καθώς και η Preterm_birth, καθώς η τελευταία περιλαμβάνει πληροφορία για το αν ο τοκετός ήταν πρόωρος ή όχι — στοιχείο που μπορεί να επηρεάσει την ακρίβεια των προβλέψεων. Τέλος, τα δεδομένα διαχωρίστηκαν σε σύνολο εκπαίδευσης (70%) και δοκιμής (30%) με χρήση της συνάρτησης train_test_split, χωρίς ανάγκη για στρωματοποίηση, καθώς πρόκειται για πρόβλημα παλινδρόμησης.

```
# Καθαρισμός δεδομένων
df['GA'] = pd.to_numeric(df['GA'], errors='coerce')
df_reg = df.dropna(subset=['GA']).copy()  # Αφαίρεση NaN από τη GA

X = df_reg.drop(columns=['GA', 'Preterm_birth']) # Όλες οι μεταβλητές εκτός των GA και Preterm_birth (επηρεάζει την πρόβλεψη)
y = df_reg['GA'] # Η μεταβλητή στόχος (GA - εβδομάδα τοκετού)

# Διαχωρισμός σε Train(70%)/Test(30%) (δεν χρειάζεται stratify)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42
)
```

Εικόνα 20: Καθαρισμός και εκπαίδευση δεδομένων

Για την αξιόπιστη αξιολόγηση της γενικευσιμότητας του μοντέλου, εφαρμόστηκε τεχνική διασταυρούμενης επικύρωσης (10-fold cross-validation) (Εικόνα 21), όπου το σύνολο εκπαίδευσης χωρίστηκε σε 10 υποσύνολα (folds). Σε κάθε επανάληψη, το

μοντέλο εκπαιδεύεται σε 9 από αυτά και αξιολογείται στο 1 που απομένει, εξασφαλίζοντας ότι κάθε δείγμα συμμετέχει μία φορά ως test και εννέα φορές ως train. Ενεργοποιήθηκε η τυχαία ανάμειξη των δεδομένων (shuffle=True) και χρησιμοποιήθηκε η random_state=42 για αναπαραγωγιμότητα των αποτελεσμάτων.

```
# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(rf_reg, X_train, y_train, cv=cv, scoring=scoring)
```

Εικόνα 21: 10-fold cross-validation

Οι επιδόσεις των μοντέλων αξιολογήθηκαν με χρήση κατάλληλων μετρικών, οι οποίες περιγράφονται αναλυτικά σε επόμενη ενότητα (5.4).

5.3 ΜΟΝΤΕΛΑ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ

Τα προβλεπτικά μοντέλα που αξιοποιήθηκαν κατά την διαδικασία πρόβλεψης της εβδομάδας τοκετού ήταν τα παρακάτω:

i) **Random Forest Regressor (Τυχαίο Δάσος Παλινδρόμησης)** (Εικόνα 22), μία μέθοδος συνόλου που δημιουργεί πολλαπλά δέντρα αποφάσεων και συνδυάζει τα αποτελέσματά τους. Είναι ιδιαίτερα αποδοτικό σε πολύπλοκα σύνολα δεδομένων και περιορίζει την υπερεκπαίδευση.

```
# Ορισμός μοντέλου Random Forest Regressor
rf_reg = RandomForestRegressor(n_estimators=100, random_state=42)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(rf_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
rf_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = rf_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 22: Υλοποίηση Random Forest Regressor

Σε αυτή τη μελέτη, το μοντέλο ορίστηκε με 100 δέντρα αποφάσεων, αριθμός που προσφέρει ικανοποιητική ισορροπία μεταξύ ακρίβειας και υπολογιστικού κόστους. Έπειτα αξιολογήθηκε με χρήση της τεχνικής 10-fold cross-validation. Μετά την επικύρωση, το μοντέλο εκπαιδεύτηκε στο πλήρες σύνολο εκπαίδευσης.

ii) **Support Vector Regressor (SVR)** (Εικόνα 23), το μοντέλο αυτό χρησιμοποιεί τεχνικές πυρήνων (kernel functions) για να μοντελοποιήσει μη γραμμικές σχέσεις, κάτι που το καθιστά κατάλληλο για δεδομένα με πολύπλοκη κατανομή. Αν και μπορεί να είναι υπολογιστικά απαιτητικό, συχνά προσφέρει υψηλή ακρίβεια.

Στην παρούσα υλοποίηση χρησιμοποιήθηκε συνδυασμός με το πρότυπο κανονικοποίησης StandardScaler, ώστε όλα τα χαρακτηριστικά να κλιμακωθούν σε συγκρίσιμη κλίμακα. Επιλέχθηκε ο πυρήνας rbf λόγω της ικανότητάς του να μοντελοποιεί μη γραμμικές σχέσεις, ενώ οι υπερπαράμετροι C=1.0 και ε=0.2 ορίστηκαν σε τυπικές τιμές που προσφέρουν μία ισορροπημένη απόδοση χωρίς υπερεκπαίδευση. Εφαρμόστηκε 10-fold cross-validation, ενώ το τελικό μοντέλο εκπαιδεύτηκε στο πλήρες σύνολο εκπαίδευσης και δοκιμάστηκε στο σύνολο ελέγχου.

```python
# Ορισμός μοντέλου SVR με scaling
# StandarScaler(): κανονικοποιεί τα χαρακτηριστικά ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1
# kernel='rbf': κατάλληλο για μη γραμμικά δεδομένα
# C=1.0: ρυθμίζει την ισορροπία μεταξύ απλότητας του μοντέλου και ακρίβειας στην εκπαίδευση (συνήθης χρήση αυτής της τιμής)
# epsilon=0.2: όριο ανοχής στο σφάλμα πρόβλεψης – τα σφάλματα μικρότερα από αυτό δεν τιμωρούνται (συνήθης χρήση αυτής της τιμής)
svr = make_pipeline(StandardScaler(), SVR(kernel='rbf', C=1.0, epsilon=0.2))

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(svr, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
svr.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = svr.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 23: Υλοποίηση SVR

iii) **Linear Regression (Γραμμική Παλινδρόμηση)** (Εικόνα 24), είναι απλός και ερμηνεύσιμος αλγόριθμος, ο οποίος υποθέτει γραμμική σχέση μεταξύ των χαρακτηριστικών και της εξαρτημένης μεταβλητής. Χρησιμοποιήθηκε ως βασικό σημείο αναφοράς και για την αποτίμηση της απόδοσης πιο σύνθετων μοντέλων.

Όπως και στα προηγούμενα μοντέλα, η εκπαίδευση και η αξιολόγηση υλοποιήθηκαν μέσω της 10-fold cross-validation. Το μοντέλο εφαρμόστηκε στο πλήρες σύνολο εκπαίδευσης (train set) και αξιολογήθηκε στο σύνολο δοκιμής (test set).

```
# Ορισμός μοντέλου Linear Regression
lin_reg = LinearRegression()

# 10- Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(lin_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
lin_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = lin_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 24: Υλοποίηση Linear Regression

iv) **K-Neighbors Regressor (KNN Παλινδρόμησης)** (Εικόνα 25), βασίζεται στην απόσταση μεταξύ των δειγμάτων, προβλέπει την τιμή ενός δείγματος με βάση τις τιμές των κοντινότερων γειτόνων. Είναι απλός, εύκολος στην υλοποίηση και χρήσιμος ως baseline μοντέλο.

Στην παρακάτω μελέτη, κάθε νέα πρόβλεψη βασίζεται στους πέντε πλησιέστερους γείτονες. Η διαδικασία περιλαμβάνει κανονικοποίηση των χαρακτηριστικών μέσω StandardScaler, ώστε όλες οι μεταβλητές να συνεισφέρουν ισότιμα στον υπολογισμό των αποστάσεων. Η εκπαίδευση και αξιολόγηση πραγματοποιήθηκαν με 10-fold cross-validation και δοκιμάστηκε η απόδοσή του στο test set.

```python
# Ορισμός μοντέλου KNN Regression με κανονικοποίηση
# StandarScaler(): κανονικοποιεί τα χαρακτηριστικά ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1
# n_neighbors=5: πρόβλεψη με βάση τις τιμές των 5 πιο κοντινών γειτόνων (συνήθης χρήση αυτής της τιμής)
knn_reg = make_pipeline(StandardScaler(), KNeighborsRegressor(n_neighbors=5))

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(knn_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
knn_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = knn_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 25: Υλοποίηση K-Neighbors Regressor

v) **Decision Tree Regressor (Δέντρο Απόφασης Παλινδρόμησης)** (Εικόνα 26), χρησιμοποιεί δενδροειδή δομή για να αποδώσει τον χώρο των χαρακτηριστικών. Αν και μπορεί να υπερεκπαιδευτεί σε μικρά σύνολα δεδομένων, παρέχει σαφή ερμηνεία των προβλέψεων και είναι ιδανικό για αρχική ανάλυση.

Και σε αυτόν τον αλγόριθμο, η εκπαίδευση πραγματοποιήθηκε στο πλήρες σύνολο εκπαίδευσης και η αξιολόγηση του συνόλου δοκιμής υλοποιήθηκε με την χρήση της 10-fold cross-validation.

```
# Ορισμός μοντέλου Decision Tree Regression
tree_reg = DecisionTreeRegressor(random_state=42)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(tree_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
tree_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = tree_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 26: Υλοποίηση Decision Tree Regressor

vi) **Gradient Boosting Regressor** (Εικόνα 27), αποτελεί τεχνική ενίσχυσης (boosting) που χτίζει διαδοχικά δέντρα με στόχο τη διόρθωση των σφαλμάτων των προηγούμενων. Παράγει υψηλής ακρίβειας μοντέλα αλλά απαιτεί ρύθμιση υπερπαραμέτρων για την αποφυγή υπερεκπαίδευσης.

Ακολουθήθηκε η συνήθης διαδικασία 10-fold cross-validation για την εκτίμηση των επιδόσεών του στο σύνολο εκπαίδευσης και στη συνέχεια αξιολόγηση στο test set.

```python
# Ορισμός μοντέλου Gradient Boosting Regressor
gb_reg = GradientBoostingRegressor(random_state=42)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(gb_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
gb_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = gb_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 27: Υλοποίηση Gradient Boosting Regressor

vii) **AdaBoost Regressor (Adaptive Boosting)** (Εικόνα 28), ο οποίος εστιάζει σε δύσκολες περιπτώσεις δίνοντάς τους μεγαλύτερη βαρύτητα σε κάθε επόμενη επανάληψη. Είναι αποδοτικός σε δεδομένα με μέτριο θόρυβο και συνδυάζει πολλούς αδύναμους παλινδρομητές σε ένα ισχυρό μοντέλο.

Ο αλγόριθμος εφαρμόστηκε χρησιμοποιώντας ως βάση δέντρα απόφασης με μέγιστο βάθος 3. Κάθε νέο μοντέλο επικεντρώνεται στα σφάλματα των προηγούμενων, αποδίδοντας μεγαλύτερο βάρος στις πιο δύσκολες περιπτώσεις. Το πλήθος των 100 εκτιμητών αποτελεί μία συνηθισμένη επιλογή που εξισορροπεί απόδοση και υπολογιστικό κόστος. Όπως και στα υπόλοιπα μοντέλα, εφαρμόστηκε 10-fold cross-validation και στη συνέχεια το μοντέλο εκπαιδεύτηκε στο σύνολο εκπαίδευσης και αξιολογήθηκε στο σύνολο δοκιμής.

```python
# Ορισμός μοντέλου AdaBoost με βάση decision tree
# DecisionTreeRegressor(max_depth=3):
# n_estimators=100:
ada_reg = AdaBoostRegressor(
    estimator=DecisionTreeRegressor(max_depth=3), n_estimators=100, random_state=42)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(ada_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
ada_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = ada_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 28: Υλοποίηση AdaBoost Regressor

viii) **XGBoost Regressor (Extreme Boosting)** (Εικόνα 29), μία βελτιωμένη έκδοση του Gradient Boosting, με βελτιστοποιημένη ταχύτητα και αποδοτικότητα μνήμης. Ενδείκνυται για δομημένα δεδομένα με ελλιπείς τιμές ή υψηλή διαστατικότητα.

Στην παρακάτω υλοποίηση επιλέχθηκε ο αριθμός των 100 εκτιμητών (τυπική επιλογή) για τις διαδοχικές ενισχύσεις που απαιτεί αυτό το μοντέλο. Ακολουθήθηκε διαδικασία 10-fold cross-validation πριν την τελική εκπαίδευση και αξιολόγηση στο test set.

```python
# Ορισμός μοντέλου XGBoost
# n_estimators=100: πόσες διαδοχικές ενισχύσεις (boosting rounds) θα γίνουν (συνήθης χρήση αυτής της τιμής)
# verbosity=0: καταστέλλει την εμφάνιση μηνυμάτων κατά την εκπαίδευση
xgb_reg = XGBRegressor(n_estimators=100, random_state=42, verbosity=0)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(xgb_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
xgb_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = xgb_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 29: Υλοποίηση XGBoost Regressor

ix) **Bagging Regressor (Bootstrap Aggregating)** (Εικόνα 30), μέθοδος που εκπαιδεύει πολλαπλά μοντέλα σε τυχαία δείγματα των δεδομένων και συνδυάζει τις προβλέψεις τους. Μειώνει τη διακύμανση και ενισχύει τη σταθερότητα των αποτελεσμάτων.

Στην παρούσα περίπτωση χρησιμοποιήθηκαν 100 δέντρα απόφασης ως βασικά υπομοντέλα, τα οποία προσφέρουν σταθερότητα και μειώνουν την διακύμανση χωρίς να αυξάνουν σημαντικά την προκατάληψη. Η αξιολόγηση του μοντέλου πραγματοποιήθηκε με 10-fold cross-validation και δοκιμή στο test set.

```python
# Ορισμός μοντέλου Bagging
# estimator=DecisionTreeRegressor(): δέντρο απόφασης για παλινδρόμηση
# n_estimators=100: χρησιμοποιούνται 100 διαφορετικά δέντρα (υπομοντέλα) για την τελική πρόβλεψη (συνήθης χρήση αυτής της τιμής)
bag_reg = BaggingRegressor(estimator=DecisionTreeRegressor(), n_estimators=100, random_state=42)

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(bag_reg, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
bag_reg.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = bag_reg.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 30: Υλοποίηση Bagging Regressor

x) **Voting Regressor** (Εικόνα 31), συνδυαστικό μοντέλο που συγκεντρώνει τις προβλέψεις από πολλούς διαφορετικούς παλινδρομητές και παράγει τελική πρόβλεψη βάσει μέσου όρου. Εκμεταλλεύεται τα πλεονεκτήματα κάθε μοντέλου, οδηγώντας συχνά σε αυξημένη ακρίβεια και γενίκευση.

Στην παρούσα εργασία, χρησιμοποιήθηκε ένας συνδυασμός γραμμικής παλινδρόμησης (Linear Regression) με κανονικοποίηση (StandardScaler) και του ενισχυτικού μοντέλου XGBoost (XGB Regressor). Το μοντέλο αξιολογήθηκε με 10-fold cross-validation και στη συνέχεια στο test set για επιβεβαίωση των επιδόσεών του.

```
# Ορισμός επιμέρους μοντέλων
lr = LinearRegression()
xgb_reg = XGBRegressor(random_state=42)

# Scaling μοντέλου
lr_pipe = make_pipeline(StandardScaler(), lr)

# Ορισμός μοντέλου Voting Regressor
voting = VotingRegressor(estimators=[('lr', lr_pipe), ('xgb', xgb_reg)])

# 10-Fold Cross-Validation
cv = KFold(n_splits=10, shuffle=True, random_state=42)
scoring = ['r2', 'neg_mean_absolute_error', 'neg_mean_squared_error']

cv_results = cross_validate(voting, X_train, y_train, cv=cv, scoring=scoring)

# Εκπαίδευση στο πλήρες training set
voting.fit(X_train, y_train)

# Προβλέψεις στο test set
y_pred = voting.predict(X_test)

# Αξιολόγηση στο test set
print("\nEvaluation on Test Set:")
print(f"R² Score: {r2_score(y_test, y_pred):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.4f}")
print(f"MSE: {mean_squared_error(y_test, y_pred):.4f}")
print(f"RMSE: {np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")
```

Εικόνα 31: Υλοποίηση Voting Regressor

5.4 ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ΥΠΕΡΠΑΡΑΜΕΤΡΩΝ ΜΕ GRID SEARCH CV

Για τη βελτίωση της απόδοσης του μοντέλου, εφαρμόστηκε βελτιστοποίηση υπερπαραμέτρων μέσω της μεθόδου GridSearchCV. Η τεχνική αυτή επιτρέπει την εξαντλητική αναζήτηση του βέλτιστου συνδυασμού υπερπαραμέτρων μέσα σε ένα προκαθορισμένο πλέγμα τιμών. Για κάθε πιθανό συνδυασμό, εφαρμόστηκε διασταυρούμενη επικύρωση (10-fold cross-validation) ώστε να διασφαλιστεί η σταθερότητα και η γενικευσιμότητα των αποτελεσμάτων. Η επιλογή του καλύτερου μοντέλου βασίστηκε στην απόδοση ως προς την μετρική αρνητικό MSE. Το τελικό μοντέλο εκπαιδεύτηκε εκ νέου στο πλήρες σύνολο εκπαίδευσης, χρησιμοποιώντας τις υπερπαραμέτρους που εντοπίστηκαν ως βέλτιστες από την προηγούμενη διαδικασία.

Για τον αλγόριθμο Random Forest (Εικόνα 32), εξετάστηκαν διάφοροι συνδυασμοί υπερπαραμέτρων όπως ο αριθμός των δέντρων (n_estimators), το μέγιστο βάθος κάθε δέντρου (max_depth), ο ελάχιστος αριθμός δειγμάτων για διαχωρισμό κόμβου (min_samples_split) και φύλλου (min_samples_leaf).

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'n_estimators': [100, 200]: αριθμός δέντρων στο δάσος
# 'max_depth': [None, 10, 20]: μέγιστο βάθος κάθε δέντρου
# 'min_samples_split': [2, 5]: ελάχιστος αριθμός δειγμάτων για διαχωρισμό εσωτερικού κόμβου
# 'min_samples_leaf': [1, 2]: ελάχιστος αριθμός δειγμάτων σε φύλλο
param_grid = {
    'n_estimators': [100, 200],
    'max_depth': [None, 10, 20],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2]
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=RandomForestRegressor(random_state=42),
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 32: Βελτιστοποίηση Random Forest Regressor

Για τον SVR (Εικόνα 33) χρησιμοποιήθηκε pipeline που περιελάμβανε προεπεξεργασία δεδομένων και αναζητήθηκαν υπερπαράμετροι όπως το C (συντελεστής ποινής), το ε (περιθώριο ανοχής σφάλματος), ο πυρήνας rbf, καθώς και η παράμετρος gamma ώστε να καθοριστεί η επιρροή του κάθε δείγματος. Η αναζήτηση προκειμένου να εξασφαλίσει καλύτερα αποτελέσματα, επικεντρώθηκε σε μη γραμμικές σχέσεις.

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'svr__C': [0.1, 1, 10]: πόσο αυστηρά τιμωρείται το σφάλμα (όσο μεγαλύτερο είναι το C τόσο λιγότερη είναι η ανοχή στα σφάλματα)
# 'svr__epsilon': [0.1, 0.2, 0.3]: το περιθώριο μέσα στο οποίο δεν υπάρχει ποινή για το σφάλμα πρόβλεψης
# 'svr__gamma': ['scale', 'auto']: καθορίζει την επιρροή κάθε δείγματος
# 'svr__kernel': ['rbf']: κατάλληλο για μη γραμμικά δεδομένα
param_grid = {
    'svr__C': [0.1, 1, 10],
    'svr__epsilon': [0.1, 0.2, 0.3],
    'svr__gamma': ['scale', 'auto'],
    'svr__kernel': ['rbf']
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=pipeline,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 33: Βελτιστοποίηση SVR

Η βελτιστοποίηση της Linear Regressor (Εικόνα 34) έγινε μέσω της Ridge Regression ως προς την υπερπαράμετρο alpha. Αυτή η υπερπαράμετρος ελέγχει τον βαθμό κανονικοποίησης του μοντέλου. Χρησιμοποιήθηκαν τιμές από πολύ μικρές έως μεγάλες, ώστε να εξεταστεί η ευαισθησία του μοντέλου και να αποφευχθεί η υπερπροσαρμογή.

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'alpha': [0.01, 0.1, 1, 10, 100]: ελέγχει το μέγεθος της κανονικοποίησης
param_grid = {
    'alpha': [0.01, 0.1, 1, 10, 100]
}

# Ορισμός του GridSearchCV με Ridge Regression για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=Ridge(),
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 34: Βελτιστοποίηση Linear Regression

Για τον KNN (Εικόνα 35) έγινε αναζήτηση στο πλήθος των γειτόνων (n_neighbors), στο είδος βαρών (weights) και στο είδος της απόστασης (p), επιτρέποντας στο μοντέλο να προσαρμοστεί καλύτερα στις τοπικές δομές των δεδομένων.

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'knn__n_neighbors': [3, 5, 7, 9]: αριθμός γειτόνων
# 'knn__weights': ['uniform', 'distance']: uniform = όλοι οι γείτονες έχουν ίδιο βάρος, distance = οι πιο κοντινοί γείτονες μετράνε περισσότερο
# 'knn__p': [1, 2]: απόσταση (1 = Manhattan, 2 = Euclidean)
param_grid = {
    'knn__n_neighbors': [3, 5, 7, 9],
    'knn__weights': ['uniform', 'distance'],
    'knn__p': [1, 2]
}

# Ορισμός του GridSearchCV με Ridge Regression για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=pipeline,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 35: Βελτιστοποίηση K-Neighbors Regressor

Η βελτιστοποίηση του μοντέλου Decision Tree (Εικόνα 36) έγινε εξετάζοντας το μέγιστο βάθος (max_depth), το ελάχιστο μέγεθος για διαχωρισμό κόμβου (min_samples_split) και φύλλου (min_samples_leaf) και τον αριθμό χαρακτηριστικών που λαμβάνονται υπόψη για διαχωρισμό (max_features).

Το Gradient Boosting Regressor (Εικόνα 37) βελτιστοποιήθηκε ως προς τον αριθμό δέντρων (n_estimators), το βάθος κάθε δέντρου (max_depth), τον ρυθμό μάθησης

(learning_rate) και το υποσύνολο δειγμάτων (subsample) που χρησιμοποιείται για κάθε δέντρο.

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'max_depth': [None, 5, 10, 20]: μέγιστο βάθος κάθε δέντρου
# 'min_samples_split': [2, 5, 10]: ελάχιστος αριθμός δειγμάτων για διαχωρισμό εσωτερικού κόμβου
# 'min_samples_leaf': [1, 2, 4]: ελάχιστος αριθμός δειγμάτων σε φύλλο
# 'max_features': [None, 'sqrt', 'log2']: αριθμός χαρακτηριστικών που εξετάζονται για διαχωρισμό
param_grid = {
    'max_depth': [None, 5, 10, 20],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4],
    'max_features': [None, 'sqrt', 'log2']
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=tree_reg,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 36: Βελτιστοποίηση Decision Tree Regressor

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'n_estimators': [100, 200, 300]: αριθμός δέντρων
# 'max_depth': [3, 5, 7]: μέγιστο βάθος κάθε δέντρου
# 'learning_rate': [0.01, 0.1, 0.2]: ρυθμός μάθησης
# 'subsample': [0.8, 1.0]: ποσοστό δειγμάτων για κάθε δέντρο
param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [3, 5, 7],
    'learning_rate': [0.01, 0.1, 0.2],
    'subsample': [0.8, 1.0]
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=gb_reg,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 37: Βελτιστοποίηση Gradient Boosting Regressor

Για το AdaBoost (Εικόνα 38) αναζητήθηκαν οι βέλτιστες τιμές σε πλήθος δέντρων (n_estimators), βάθος του κάθε δέντρου (estimator__max_depth) καθώς και τον ρυθμό μάθησης (learning_rate).

Το μοντέλο XGBoost (Εικόνα 39) ρυθμίστηκε ως προς την πολυπλοκότητα του εκτιμητή - δέντρου (max_depth, learning_rate), το ποσοστό δειγμάτων που χρησιμοποιείται για κάθε δέντρο (subsample) αλλά και το ποσοστό χαρακτηριστικών που χρησιμοποιείται για κάθε δέντρο (colsample_bytree).

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'n_estimators': [50, 100, 200]: αριθμός δέντρων
# 'learning_rate': [0.01, 0.1, 1]: ρυθμός μάθησης
# 'estimator__max_depth': [2, 3, 5]: μέγιστο βάθος κάθε δέντρου
param_grid = {
    'n_estimators': [50, 100, 200],
    'learning_rate': [0.01, 0.1, 1],
    'estimator__max_depth': [2, 3, 5]
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=ada_reg,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 38: Βελτιστοποίηση AdaBoost Regressor

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'n_estimators': [50, 100, 200]: αριθμός δέντρων
# 'max_depth': [3, 5, 7]: μέγιστο βάθος κάθε δέντρου
# 'learning_rate': [0.01, 0.1, 0.2]: ρυθμός μάθησης
# 'subsample': [0.7, 1.0]: ποσοστό δειγμάτων που χρησιμοποιείται για κάθε δέντρο
# 'colsample_bytree': [0.7, 1.0]: ποσοστό χαρακτηριστικών που χρησιμοποιείται για κάθε δέντρο
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [3, 5, 7],
    'learning_rate': [0.01, 0.1, 0.2],
    'subsample': [0.7, 1.0],
    'colsample_bytree': [0.7, 1.0]
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=xgb_reg,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 39: Βελτιστοποίηση XGB Regressor

Ο Bagging Regressor (Εικόνα 40) εξετάστηκε ως προς τον αριθμό δέντρων (n_estimators), το ποσοστό δειγμάτων σε κάθε δέντρο (max_samples) και χαρακτηριστικών (max_features), καθώς και τις παραμέτρους του βασικού εκτιμητή - δέντρου (estimator_max_depth, estimator_min_samples_split).

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'n_estimators': [50, 100, 200]: αριθμός δέντρων
# 'max_samples': [0.7, 1.0]: ποσοστό δειγμάτων κάθε δέντρου
# 'max_features': [0.7, 1.0]: ποσοστό χαρακτηριστικών κάθε δέντρου
# 'estimator__max_depth': [None, 5, 10]: μέγιστο βάθος κάθε δέντρου
# 'estimator__min_samples_split': [2, 5]: ελάχιστος αριθμός δειγμάτων για διαχωρισμό εσωτερικού κόμβου
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_samples': [0.7, 1.0],
    'max_features': [0.7, 1.0],
    'estimator__max_depth': [None, 5, 10],
    'estimator__min_samples_split': [2, 5]
}

# Ορισμός του GridSearchCV για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=bag_reg,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
)
```

Εικόνα 40: Βελτιστοποίηση Bagging Regressor

Τέλος, για τον Voting Regressor (ensemble μοντέλο) (Εικόνα 41), η βελτιστοποίηση έγινε κυρίως στις παραμέτρους του XGBoost (n_estimators, max_depth, learning_rate) που συμμετέχει στη σύνθεση.

```
# Ορισμός του πλέγματος παραμέτρων για τον Grid Search
# 'xgb__n_estimators': [50, 100, 200]: αριθμός δέντρων
# 'xgb__max_depth': [3, 5, 7]: μέγιστο βάθος κάθε δέντρου
# 'xgb__learning_rate': [0.01, 0.1, 0.2]: ρυθμός μάθησης
param_grid = {
    'xgb__n_estimators': [50, 100, 200],
    'xgb__max_depth': [3, 5, 7],
    'xgb__learning_rate': [0.01, 0.1, 0.2]
}

# Ορισμός του GridSearchCV με για εύρεση των καλύτερων παραμέτρων
# cv=10: 10-fold cross-validation
# n_jobs=-1: χρήση όλων των διαθέσιμων πυρήνων CPU
# verbose=1: επίπεδο λεπτομέρειας στην έξοδο
grid_search = GridSearchCV(
    estimator=voting,
    param_grid=param_grid,
    cv=10,
    scoring='neg_mean_squared_error',
    n_jobs=-1,
    verbose=1
```

Εικόνα 41: Βελτιστοποίηση Voting Regressor

5.5 ΑΞΙΟΛΟΓΗΣΗ ΜΟΝΤΕΛΩΝ

Για την αξιολόγηση της απόδοσης των εφαρμοζόμενων μοντέλων χρησιμοποιούνται οι εξής τέσσερις βασικές μετρικές [25]:

- **R^2 Score (Συντελεστής Προσδιορισμού):** Μετράει το ποσοστό της διακύμανσης των δεδομένων εξόδου που εξηγείται από το μοντέλο. Τιμές κοντά στο 1 υποδηλώνουν υψηλή ακρίβεια πρόβλεψης, ενώ τιμές κοντά στο 0 το αντίθετο.
- **MAE (Mean Absolute Error):** Υπολογίζει τον μέσο όρο των απόλυτων διαφορών μεταξύ των πραγματικών και των προβλεπόμενων τιμών. Είναι εύκολη στην ερμηνεία και δεν επηρεάζεται από ακραίες τιμές.
- **MSE (Mean Squared Error):** Είναι ο μέσος όρος των τετραγώνων των σφαλμάτων. Δίνει μεγαλύτερη βαρύτητα σε μεγαλύτερα σφάλματα, τιμωρώντας περισσότερο τις μεγάλες αποκλίσεις.
- **RMSE (Root Mean Squared Error):** Είναι η τετραγωνική ρίζα του MSE και εκφράζεται στην ίδια μονάδα μέτρησης με τις τιμές-στόχους, γεγονός που διευκολύνει την ερμηνεία του μεγέθους του σφάλματος.

Η συνδυαστική χρήση αυτών των μετρικών επιτρέπει μία πιο ολοκληρωμένη και αξιόπιστη αποτίμηση της συμπεριφοράς του κάθε μοντέλου που εφαρμόστηκε προκειμένου να επιτευχθεί η πρόβλεψη της εβδομάδας τοκετού.

5.6 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΕΩΝ

5.6.1 Αποτελέσματα πρόβλεψης εβδομάδας τοκετού

Στην παρούσα ενότητα παρουσιάζονται τα αποτελέσματα της παλινδρόμησης για την πρόβλεψη εβδομάδας τοκετού με χρήση των αλγορίθμων μηχανικής μάθησης της ενότητας 5.3. Οι τιμές των μετρικών αξιολόγησης για κάθε μοντέλο συνοψίζονται στον Πίνακα 6.

Πίνακας 6: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού

Metric/Model	R^2 score	MAE	MSE	RMSE
Random Forest Regressor	0.76	0.92	1.89	1.37
SVR	0.41	1.43	4.63	2.15
Linear Regression	0.59	1.38	3.22	1.79
K-Neighbors Regressor	0.38	1.41	4.90	2.21
Decision Tree Regressor	0.48	1.26	4.11	2.02
Gradient Boosting Regressor	0.74	0.99	2.03	1.42
AdaBoost Regressor	0.66	1.23	2.65	1.63
XGB Regressor	0.72	0.99	2.13	1.46
Bagging Regressor	0.76	0.91	1.87	1.36
Voting Regressor	0.71	1.09	2.27	1.50

Ο Random Forest επιτυγχάνει ιδιαίτερα καλή απόδοση με το υψηλότερο R^2 score (0.76) και χαμηλές τιμές σφαλμάτων (MAE: 0.92, RMSE: 1.37), αποδεικνύοντας ικανότητα γενίκευσης και αξιοπιστίας στην πρόβλεψη.

Ο SVR εμφάνισε τη χαμηλότερη επίδοση σε όλες τις μετρικές, με R^2 μόλις 0.41 και το μεγαλύτερο RMSE (2.15), γεγονός που το καθιστά λιγότερο κατάλληλο μοντέλο για το πρόβλημα αυτό.

Η Linear Regression, παρόλο που δεν προορίζεται τυπικά για παλινδρόμηση, παρουσίασε μέτρια αποτελέσματα (R^2: 0.59, RMSE: 1.79).

Ο KNN είχε τη χαμηλότερη R^2 τιμή (0.38) και το υψηλότερο MSE και RMSE (4.90 και 2.21 αντίστοιχα), γεγονός που δείχνει ότι το μοντέλο δυσκολεύεται να προσαρμοστεί σε προβλήματα συνεχούς πρόβλεψης.

Το Decision Tree είχε μέτρια επίδοση, με R^2 0.48 και RMSE 2.02, επιβεβαιώνοντας την τάση των δέντρων στην υπερεκπαίδευση.

Ο Gradient Boosting σημείωσε πολύ καλή απόδοση (R^2: 0.74) και χαμηλό σφάλμα (RMSE: 1.42), αποδεικνύοντας την αποτελεσματικότητά του στην πρόβλεψη πολύπλοκων μη γραμμικών σχέσεων.

Το AdaBoost παρουσίασε R^2 score 0.66 και RMSE 1.63, προσφέροντας ισορροπία ακρίβειας και σταθερότητας.

Ο XGBoost πέτυχε απόδοση με R^2 0.72 και RMSE 1.46, επιβεβαιώνοντας τη φήμη του ως ισχυρού αλγορίθμου παλινδρόμησης σε προβλήματα υψηλής πολυπλοκότητας.

Το Bagging Regressor απέδωσε τις χαμηλότερες τιμές σφάλματος (MAE: 0.91, RMSE: 1.36) και R^2 score 0.76, αποδεικνύοντας εξαιρετική προσαρμογή χωρίς υπερβολική παραμετροποίηση.

Τέλος, ο Voting Regressor, ως συνδυαστικό μοντέλο, εμφάνισε σταθερά καλή απόδοση (R^2: 0.71, RMSE: 1.50), συνδυάζοντας την ακρίβεια πολλαπλών ισχυρών μοντέλων.

Συμπερασματικά, τα συνδυαστικά μοντέλα (Random Forest, XGBoost, Bagging και Voting) αποδεικνύονται τα πλέον κατάλληλα και σε προβλήματα παλινδρόμησης, όπως η πρόβλεψη της εβδομάδας τοκετού, καθώς επιτυγχάνουν υψηλή ακρίβεια και χαμηλά σφάλματα.

5.6.2 Αποτελέσματα πρόβλεψης εβδομάδας τοκετού μετά την βελτιστοποίηση

Η παρούσα ενότητα παρουσιάζει τα αποτελέσματα παλινδρόμησης για την πρόβλεψη της εβδομάδας τοκετού, όπως προέκυψαν μετά την εφαρμογή βελτιστοποίησης υπερπαραμέτρων σε κάθε αλγόριθμο μέσω Grid Search CV. Οι τιμές των βασικών μετρικών συνοψίζονται στον Πίνακα 7.

Πίνακας 7: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού μετά την βελτιστοποίηση

Metric/Model	R^2 score	MAE	MSE	RMSE
Random Forest Regressor	0.76	0.92	1.89	1.37
SVR	0.57	1.24	3.36	1.83
Linear	0.59	1.37	3.18	1.79

Metric/Model	R^2 score	MAE	MSE	RMSE
Regression				
K-Neighbors Regressor	0.39	1.38	4.78	2.18
Decision Tree Regressor	0.66	1.07	2.66	1.63
Gradient Boosting Regressor	0.75	0.93	1.90	1.38
AdaBoost Regressor	0.75	0.98	1.93	1.38
XGB Regressor	0.74	0.96	2.04	1.43
Bagging Regressor	0.75	0.96	1.93	1.36
Voting Regressor	0.71	1.08	2.27	1.50

Ο Random Forest απέδωσε πολύ καλά, με R^2 score 0.76 και χαμηλά σφάλματα (MAE: 0.92, RMSE: 1.37), καταδεικνύοντας τη σταθερότητα και την ικανότητά του στην πρόβλεψη συνεχών τιμών.

Ο SVR, μετά τη βελτιστοποίηση, παρουσίασε αξιοπρεπή απόδοση με R^2 0.57 και RMSE 1.83, επιτυγχάνοντας επαρκή προσέγγιση της στοχευόμενης μεταβλητής.

Η Linear Regression, αν και δεν αποτελεί τυπικό μοντέλο παλινδρόμησης, πέτυχε R^2 0.59 και RMSE 1.79, προσφέροντας αποδεκτή ακρίβεια.

Ο KNN εμφάνισε περιορισμένη απόδοση με R^2 0.39 και RMSE 2.18, γεγονός που υποδηλώνει μειωμένη ικανότητα μοντελοποίησης πολύπλοκων σχέσεων.

Το Decision Tree παρουσίασε αξιόλογη επίδοση με R^2 0.66 και RMSE 1.63, επιτυγχάνοντας ισορροπία μεταξύ απλότητας και αποτελεσματικότητας.

Ο Gradient Boosting κατέγραψε υψηλό R^2 (0.75) και χαμηλό RMSE (1.38), αποδεικνύοντας την ικανότητά του να ανταποκρίνεται σε προβλήματα παλινδρόμησης με ακρίβεια.

Το AdaBoost απέδωσε R^2 score 0.75 και RMSE 1.38, επιβεβαιώνοντας τη δυναμική του στις συνεχείς προβλέψεις.

Ο XGBoost σημείωσε σταθερή και υψηλή απόδοση με R^2 0.74 και RMSE 1.43, επιδεικνύοντας την ισχυρή του συμπεριφορά.

Ο Bagging Regressor διατήρησε εξαιρετική απόδοση με R^2 score 0.75 και το χαμηλότερο RMSE (1.36) από όλα τα μοντέλα, υποδηλώνοντας υψηλή ακρίβεια και ανθεκτικότητα σε υπερεκπαίδευση.

Τέλος, ο Voting Regressor, αξιοποιώντας τα πλεονεκτήματα πολλών μοντέλων, σημείωσε ικανοποιητική απόδοση με R^2 0.71 και RMSE 1.50, προσφέροντας σταθερότητα και αξιοπιστία.

Με την εφαρμογή βελτιστοποίησης υπερπαραμέτρων, οι αλγόριθμοι ενισχυμένης μάθησης, όπως το Gradient Boosting, AdaBoost, XGBoost και Bagging, ανέδειξαν την ικανότητά τους να μοντελοποιούν πολύπλοκα πρότυπα με υψηλή ακρίβεια και χαμηλό σφάλμα.

5.6.3 Σύγκριση αποτελεσμάτων πρόβλεψης εβδομάδας τοκετού πριν και μετά την βελτιστοποίηση

Η συγκριτική αξιολόγηση των αποτελεσμάτων πριν και μετά τη βελτιστοποίηση αποκαλύπτει σημαντικές διαφοροποιήσεις στην απόδοση ορισμένων αλγορίθμων. Αλγόριθμοι όπως ο SVR, το Decision Tree και το AdaBoost εμφάνισαν αξιοσημείωτη βελτίωση σε όλους σχεδόν τους δείκτες, ιδιαίτερα στο R^2 score και στο RMSE. Αντίθετα, κάποια μοντέλα όπως το Random Forest και το Bagging διατήρησαν παρόμοια επίπεδα απόδοσης πριν και μετά τη βελτιστοποίηση, επιβεβαιώνοντας τη σταθερότητα και αξιοπιστία τους. Επιπλέον, η Linear Regression και ο KNN δεν παρουσίασαν αξιοσημείωτες βελτιώσεις, υποδηλώνοντας ενδεχομένως περιορισμούς στην ικανότητά τους να προσαρμοστούν σε σύνθετες προβλέψεις παλινδρόμησης. Τα μοντέλα ενισχυμένης μάθησης (Gradient Boosting, AdaBoost, XGBoost) και τα συνδυαστικά (Bagging, Voting) παρέμειναν στην κορυφή της απόδοσης και μετά τη βελτιστοποίηση, παρουσιάζοντας χαμηλά σφάλματα και υψηλά R^2 scores. Συνολικά, η βελτιστοποίηση συνέβαλε στην ενίσχυση της ακρίβειας για αρκετούς αλγορίθμους, κυρίως εκείνους που είναι ευαίσθητοι στις υπερπαραμέτρους, ενώ επιβεβαίωσε την αποτελεσματικότητα των ισχυρών ensemble μεθόδων σε προβλήματα παλινδρόμησης όπως η πρόβλεψη της εβδομάδας τοκετού.

5.7 ΠΡΟΒΛΕΨΗ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ

Στις προηγούμενες ενότητες του παρόντος κεφαλαίου περιγράφηκε αναλυτικά η διαδικασία πρόβλεψης της εβδομάδας τοκετού (μεταβλητή GA). Αρχικά, η GA καταγραφόταν ως δεκαδικός αριθμός, αποτυπώνοντας με ακρίβεια τις εβδομάδες και ημέρες κύησης. Σε αυτή την ενότητα, ωστόσο, εξετάζεται η πρόβλεψη της εβδομάδας τοκετού ως ακέραια μεταβλητή.

Η συγκεκριμένη μετατροπή κρίθηκε σκόπιμη, καθώς σε κλινικό επίπεδο η διάκριση ανάμεσα σε ολόκληρες εβδομάδες έχει πρακτική σημασία για σκοπούς πρόβλεψης ή και λήψης αποφάσεων. Συγκεκριμένα, η μεταβλητή GA μετατράπηκε σε ακέραιο αριθμό μέσω στρογγυλοποίησης προς τα κάτω, ώστε κάθε τιμή της αντιστοιχεί πλέον σε πλήρη εβδομάδα κύησης (Εικόνα 42).

```
# Καθαρισμός δεδομένων
df['GA'] = pd.to_numeric(df['GA'], errors='coerce')
df_reg = df.dropna(subset=['GA']).copy()

# Στρογγυλοποίηση της GA στο ακέραιο μέρος
df_reg['GA'] = np.floor(df_reg['GA']).astype(int)

X = df_reg.drop(columns=['GA', 'Preterm_birth']) # Όλες οι μεταβλητές εκτός των GA και Preterm_birth (επηρεάζει την πρόβλεψη)
y = df_reg['GA'] # Η μεταβλητή στόχος (GA - εβδομάδα τοκετού)
```

Εικόνα 42: Μετατροπή της GA σε ακέραια τιμή

Πέραν αυτής της μετατροπής, οι υπόλοιπες διαδικασίες υλοποίησης παρέμειναν αμετάβλητες. Χρησιμοποιήθηκαν οι ίδιοι αλγόριθμοι, οι ίδιες παράμετροι και η ίδια κατανομή των δεδομένων σε σύνολα εκπαίδευσης και ελέγχου. Έτσι διασφαλίστηκε ότι η σύγκριση των αποτελεσμάτων είναι δίκαιη και βασίζεται αποκλειστικά στην αλλαγή της μορφής της μεταβλητής-στόχου (GA) από δυαδική σε ακέραια.

Στον πίνακα 8 παρουσιάζονται τα αποτελέσματα που προέκυψαν από την υλοποίηση των διαφόρων αλγορίθμων για την πρόβλεψη της εβδομάδας τοκετού ως ακέραια μεταβλητή.

Πίνακας 8: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού ως ακέραια μεταβλητή

Metric/Model	R^2 score	MAE	MSE	RMSE
Random Forest Regressor	0.74	0.85	2.02	1.42
SVR	0.39	1.39	4.76	2.18
Linear Regression	0.58	1.37	3.25	1.80
K-Neighbors Regressor	0.36	1.40	5.03	2.24
Decision Tree Regression	0.30	1.31	5.44	2.33
Gradient Boosting Regressor	0.73	0.96	2.11	1.45
AdaBoost Regressor	0.62	1.29	2.97	1.72
XGB Regressor	0.70	0.95	2.32	1.52
Bagging Regressor	0.74	0.88	2.05	1.43
Voting Regressor	0.69	1.07	2.40	1.55

Ο Random Forest εμφάνισε εξαιρετική απόδοση, επιτυγχάνοντας ένα από τα υψηλότερα R^2 scores (0.74) και πολύ χαμηλές τιμές σφάλματος (MAE: 0.85, RMSE: 1.42).

Ο SVR κατέγραψε σχετικά χαμηλό σκορ (0.39) και υψηλές τιμές σφάλματος (RMSE: 2.18), υποδηλώνοντας περιορισμένη προσαρμοστικότητα στο συγκεκριμένο πρόβλημα.

Η Linear Regression πέτυχε μέτρια αποτελέσματα (R^2 score: 0.58), δείχνοντας ότι η σχέση των μεταβλητών δεν είναι αυστηρά γραμμική.

Το KNN μοντέλο εμφάνισε το χαμηλότερο MAE (1.40) και το υψηλότερο RMSE (2.24), γεγονός που δηλώνει αστάθεια στις προβλέψεις του και μειωμένη γενίκευση. Το σκορ του (0.36) ήταν χαμηλό, καταδεικνύοντας περιορισμένη αποδοτικότητα στο συγκεκριμένο πρόβλημα.

Το Decision Tree εμφάνισε το χαμηλότερο σκορ (0.30) και σχετικά υψηλές τιμές σφάλματος (RMSE: 2.33), γεγονός που υποδηλώνει υπερπροσαρμογή (overfitting) στο εκπαιδευτικό σύνολο και αδυναμία γενίκευσης.

Ο Gradient Boosting σημείωσε υψηλό σκορ (0.73) και χαμηλά σφάλματα (RMSE: 1.45).

Το AdaBoost κατέγραψε ικανοποιητικό σκορ (0.62) και σχετικά χαμηλό RMSE (1.72), αποδίδοντας καλύτερα από απλούς αλγόριθμους, αλλά υστερώντας σε σχέση με τα πιο εξελιγμένα μοντέλα ενίσχυσης.

Ο XGBoost, αν και θεωρείται προηγμένος αλγόριθμος, δεν εμφάνισε το υψηλότερο σκορ (0.70). Ωστόσο, διατήρησε καλές επιδόσεις (RMSE: 1.52) και έδειξε σταθερότητα στην πρόβλεψη.

Ο Bagging Regressor είχε πολύ καλή απόδοση (R^2 score: 0.74, RMSE: 1.43), επιβεβαιώνοντας ότι η τεχνική bootstrap aggregation είναι ιδιαίτερα αποτελεσματική σε προβλήματα παλινδρόμησης με περίπλοκα δεδομένα.

Ο Voting Regressor, αν και συνδυαστικό μοντέλο, είχε ελαφρώς χαμηλότερο σκορ (0.69) και υψηλότερο RMSE (1.55) από τα επιμέρους καλύτερα μοντέλα. Παρότι συγκεντρώνει προβλέψεις, δεν ξεπέρασε την ακρίβεια των κορυφαίων ενισχυτικών μεθόδων.

Ο Πίνακας 9 περιέχει τα αποτελέσματα της πρόβλεψης εβδομάδας τοκετού ως ακέραια μεταβλητή μετα την εφαρμογή βελτιστοποίησης Grid Search CV.

Πίνακας 9: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού ως ακέραια μεταβλητή μετά την βελτιστοποίηση

Metric/Model	R^2 score	MAE	MSE	RMSE
Random Forest	0.74	0.85	2.02	1.42

Metric/Model	R^2 score	MAE	MSE	RMSE
Regressor				
SVR	0.57	1.24	3.38	1.84
Linear Regression	0.58	1.36	3.25	1.80
K-Neighbors Regressor	0.38	1.38	4.81	2.19
Decision Tree Regression	0.51	1.17	3.85	1.96
Gradient Boosting Regressor	0.74	0.89	2.04	1.42
AdaBoost Regressor	0.73	1.02	2.11	1.45
XGB Regressor	0.74	0.87	2.00	1.41
Bagging Regressor	0.74	0.91	2.04	1.43
Voting Regressor	0.70	1.08	2.36	1.53

Η απόδοση του Random Forest παρέμεινε αμετάβλητη μετά τη βελτιστοποίηση (R^2 score: 0.74, RMSE: 1.42), γεγονός που υποδηλώνει ότι το μοντέλο βρισκόταν ήδη σε αποδοτικό επίπεδο και δεν ωφελήθηκε περαιτέρω.

Ο SVR παρουσίασε σημαντική βελτίωση με την παραμετροποίηση καθώς το R^2 score ανέβηκε από 0.39 σε 0.57 και το RMSE μειώθηκε από 2.18 σε 1.84. Η προσαρμογή των υπερπαραμέτρων μέσω Grid Search CV φαίνεται να επέτρεψε στο μοντέλο να εκμεταλλευτεί καλύτερα τη δομή των δεδομένων.

Η Linear Regression διατήρησε σταθερή απόδοση (R^2: 0.58, RMSE: 1.80), επιβεβαιώνοντας πως η φύση της μεθόδου περιορίζει τη δυνατότητα περαιτέρω βελτίωσης, ανεξαρτήτως παραμετροποίησης.

Το KNN παρουσίασε οριακή βελτίωση με αύξηση του R^2 score και μείωση του RMSE. Η μικρή αυτή μεταβολή υποδηλώνει πως το μοντέλο δεν είναι ιδιαίτερα αποτελεσματικό για αυτό το πρόβλημα, ακόμα και μετά τη βελτιστοποίηση.

Το Decision Tree ωφελήθηκε αισθητά από τη βελτιστοποίηση, με R^2 από 0.30 να ανεβαίνει σε 0.51 και RMSE να μειώνεται από 2.33 σε 1.96. Η ρύθμιση παραμέτρων όπως το βάθος ή τα ελάχιστα δείγματα ανά φύλλο φαίνεται να συνέβαλε σε πιο γενικευμένες προβλέψεις.

Στον Gradient Boosting παρόλο που είχε ήδη υψηλή απόδοση, παρατηρήθηκε μία μικρή αλλά ουσιαστική βελτίωση.

Ο AdaBoost παρουσίασε εντυπωσιακή άνοδο στο R^2 από 0.62 σε 0.73 και μείωση του RMSE από 1.72 σε 1.45. Η παραμετροποίηση αύξησε τη δυνατότητα του μοντέλου να αξιοποιεί αδύναμους ταξινομητές πιο αποτελεσματικά.

Το XGBoost ενίσχυσε περαιτέρω την ήδη υψηλή του απόδοση (R^2 από 0.70 σε 0.74, RMSE από 1.52 σε 1.41), επιβεβαιώνοντας την ικανότητά του να γενικεύει αποτελεσματικά με σωστό tuning.

Η απόδοση του Bagging ήταν σχεδόν σταθερή (R^2: 0.74, RMSE: 1.43 και στις δύο περιπτώσεις), γεγονός που υποδηλώνει ανθεκτικότητα και σταθερότητα του μοντέλου.

Το Voting Regressor βελτιώθηκε ελαφρώς σε R^2 και RMSE. Ως ensemble μοντέλο, επηρεάζεται από την απόδοση των υπομοντέλων του, οπότε η βελτιστοποίησή τους είχε θετικό αλλά περιορισμένο αποτέλεσμα.

5.8 ΣΥΓΚΡΙΣΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ ΩΣ ΠΡΑΓΜΑΤΙΚΗ ΚΑΙ ΩΣ ΑΚΕΡΑΙΑ ΜΕΤΑΒΛΗΤΗ

Προκειμένου να αξιολογηθεί η επίδραση της μετατροπής της εβδομάδας τοκετού (GA) από δεκαδική σε ακέραια τιμή, πραγματοποιήθηκε σύγκριση της απόδοσης των αλγορίθμων σε αμφότερες τις περιπτώσεις. Στον Πίνακα 10 παρουσιάζονται τα αντίστοιχα αποτελέσματα για το R^2 score και το σφάλμα RMSE, τόσο με την αρχική (πραγματική) μορφή της μεταβλητής όσο και με τη στρογγυλοποιημένη (ακέραια). Η διαφορά των τιμών αυτών δίνει μία σαφή εικόνα του πόσο επηρεάστηκε η απόδοση κάθε μοντέλου από τη μεταβολή αυτή.

Πίνακας 10: Σύγκριση Απόδοσης Μοντέλων με GA ως Δεκαδική και Ακέραιη Τιμή (Χωρίς Grid Search CV)

Metric/Model	R^2 score (πραγματική GA)	R^2 score (ακέραια GA)	Διαφορά R^2 score	RMSE (πραγματική GA)	RMSE (ακέραια GA)	Διαφορά RMSE
Random Forest Regressor	0.76	0.74	-0.02	1.37	1.42	+0.05
SVR	0.41	0.39	-0.02	2.15	2.18	+0.03
Linear Regression	0.59	0.58	-0.01	1.79	1.80	+0.01
K-Neighbors Regressor	0.38	0.36	-0.02	2.21	2.24	+0.03
Decision Tree	0.48	0.30	-0.18	2.02	2.33	+0.31

Metric/Model	R^2 score (πραγματική GA)	R^2 score (ακέραια GA)	Διαφορά R^2 score	RMSE (πραγματική GA)	RMSE (ακέραια GA)	Διαφορά RMSE
Regression						
Gradient Boosting Regressor	0.74	0.73	-0.01	1.42	1.45	+0.03
AdaBoost Regressor	0.66	0.62	-0.04	1.63	1.72	+0.09
XGB Regressor	0.72	0.70	-0.02	1.46	1.52	+0.06
Bagging Regressor	0.76	0.74	-0.02	1.36	1.43	+0.07
Voting Regressor	0.71	0.69	-0.02	1.50	1.55	+0.05

Η μετατροπή της εβδομάδας τοκετού (GA) από δεκαδική σε ακέραια τιμή πραγματοποιήθηκε με σκοπό τη βελτίωση της ερμηνευσιμότητας σε κλινικά περιβάλλοντα. Ωστόσο, η εν λόγω στρογγυλοποίηση επέφερε μικρές διαφοροποιήσεις στην απόδοση των μοντέλων παλινδρόμησης.

Συγκρίνοντας τις δύο προσεγγίσεις (πραγματική vs ακέραιη GA), διαπιστώθηκε ότι οι περισσότεροι αλγόριθμοι παρουσίασαν μικρή μείωση στο R^2 score (κατά 0.01–0.04) και ελαφρώς αυξημένο σφάλμα RMSE (κατά 0.03–0.09 μονάδες). Η μόνη αξιοσημείωτη επιδείνωση εντοπίστηκε στο μοντέλο Decision Tree Regressor, του οποίου η απόδοση μειώθηκε σημαντικά (πτώση 0.18 στο R^2 score και αύξηση 0.31 στο RMSE), πιθανόν λόγω απώλειας πληροφορίας από την στρογγυλοποίηση.

Αντίθετα, μοντέλα όπως το Random Forest, Bagging Regressor και Gradient Boosting διατήρησαν πολύ καλή απόδοση ακόμα και με την ακέραιη GA, γεγονός που τα καθιστά κατάλληλα για εφαρμογές με απαιτήσεις σε κλινική χρήση.

Επιπροσθέτως, αντίστοιχη ανάλυση που αφορούσε τα αποτελέσματα μετά τη βελτιστοποίηση των μοντέλων επιβεβαιώνει ότι η μετατροπή της GA από δεκαδική σε ακέραια τιμή επηρεάζει ελαφρώς την απόδοση, παρουσιάζοντας παρόμοια μοτίβα μείωσης στο R^2 και μικρής αύξησης στο RMSE. Αυτά τα ευρήματα ενισχύουν την παρατήρηση ότι τα ensemble μοντέλα διατηρούν την αξιοπιστία και την ακρίβειά τους, ενώ τα απλούστερα μοντέλα παλινδρόμησης εμφανίζουν μειωμένη απόδοση λόγω της στρογγυλοποίησης.

Συμπερασματικά, η στρογγυλοποίηση της GA ενδέχεται να μειώνει την ακρίβεια της πρόβλεψης αν δεν γίνει χρήση κατάλληλων αλγορίθμων. Για αυτό και η επιλογή μεταξύ δεκαδικής ή ακέραιας μορφής θα πρέπει να βασίζεται κυρίως στην τελική χρήση των αποτελεσμάτων και όχι αποκλειστικά στην ελαφρά διαφορά απόδοσης.

5.9 ΕΝΑΛΛΑΚΤΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΠΡΟΒΛΕΨΗΣ ΕΒΔΟΜΑΔΑΣ ΤΟΚΕΤΟΥ

Για τη βελτίωση των αποτελεσμάτων και την απλοποίηση του προβλήματος, εξετάστηκαν δύο επιπλέον προσεγγίσεις πρόβλεψης που βασίζονται στην ομαδοποίηση της μεταβλητής GA (εβδομάδα τοκετού) σε λιγότερες κατηγορίες. Συγκεκριμένα, δοκιμάστηκαν προσεγγίσεις που ομαδοποιούν τις εβδομάδες είτε σε μηνιαία διαστήματα είτε ανά δύο εβδομάδες, με στόχο να μειωθεί η πολυπλοκότητα και να βελτιωθεί η ακρίβεια. Οι διαχωρισμοί πραγματοποιήθηκαν εντός του χρονικού διαστήματος 25ης έως 42ης εβδομάδας κύησης, το οποίο προέκυψε από τα ίδια τα δεδομένα του συνόλου, όπου παρατηρήθηκαν ως ελάχιστη και μέγιστη τιμή οι 25.29 και 41.86 εβδομάδες αντίστοιχα. Η κάθε προσέγγιση περιγράφεται αναλυτικά στις υποενότητες 5.9.1 και 5.9.2.

5.9.1 Πρόβλεψη μήνα τοκετού (ομαδοποίηση κατά μήνα)

Σε αυτή την προσέγγιση επιχειρήθηκε η πρόβλεψη του μήνα τοκετού μέσω κατηγοριοποίησης της εβδομάδας τοκετού (GA) σε τρεις διακριτές ομάδες: 6ος–8ος μήνας (25≤ GA ≤35), 9ος μήνας (36≤ GA ≤40) και 10ος μήνας (GA≥ 41) (Εικόνα 43). Η ομαδοποίηση αυτή προέκυψε με βάση την κατανομή και τον αριθμό των διαθέσιμων δειγμάτων του συνόλου δεδομένων ανά μήνα τοκετού. Η συγκεκριμένη προσέγγιση αξιοποιεί το πλεονέκτημα της πιο ισορροπημένης εκπροσώπησης των τάξεων, διευκολύνοντας την εκπαίδευση σταθερών και γενικεύσιμων μοντέλων.

```
# Δημιουργία κατηγορικής μεταβλητής με βάση την GA
def month_birth(ga):
    if ga <= 35:
        return '6ος-8ος μήνας'
    elif ga <= 40:
        return '9ος μήνας'
    else:
        return '10ος μήνας'

# Καθαρισμός δεδομένων
df['GA'] = pd.to_numeric(df['GA'], errors='coerce')
df_clean = df.dropna(subset=['GA']).copy()
# Εφαρμογή της συνάρτησης month_birth σε κάθε GA και αποθήκευση του αποτελέσματος στη νέα στήλη 'month_birth'
df_clean['month_birth'] = df_clean['GA'].apply(month_birth)
```

Εικόνα 43: Δημιουργία κατηγορικής μεταβλητής «μήνας τοκετού» (month_birth) βάσει της GA

Πιο συγκεκριμένα, η μεταβλητή στόχος δημιουργήθηκε εφαρμόζοντας κατάλληλη συνάρτηση στους καθαρισμένους αριθμητικούς δείκτες της GA. Το σύνολο δεδομένων διαχωρίστηκε σε σύνολα εκπαίδευσης (70%) και ελέγχου (30%) με χρήση δειγματοληψίας (stratify), ώστε να διατηρηθεί η αναλογία των κατηγοριών. Στο εκπαιδευτικό σύνολο εφαρμόστηκε τεχνική εξισορρόπησης SMOTE για την αντιμετώπιση της ανισοκατανομής των τάξεων.

Ακολούθως, εκπαιδεύτηκαν τα μοντέλα της ενότητας 4.2 καθώς πρόκειται για πρόβλημα ταξινόμησης. Για την αξιολόγηση εφαρμόστηκε 10-fold cross-validation ως προς τις μετρικές Accuracy, Precision, Recall και F1-score (αναλυτική

παρουσίαση και ερμηνεία της κάθε μετρικής στην ενότητα 4.3). Τέλος, το μοντέλο δοκιμάστηκε στο σύνολο ελέγχου, παρέχοντας τα τελικά αποτελέσματα.

Όπως και στην ενότητα 5.4, εφαρμόστηκε βελτιστοποίηση υπερπαραμέτρων με τη μέθοδο GridSearchCV, προκειμένου να εντοπιστεί ο βέλτιστος συνδυασμός παραμέτρων ανά αλγόριθμο, και να επιτευχθούν τα καλύτερα δυνατά αποτελέσματα.

Στον Πίνακα 11 παρουσιάζονται τα αποτελέσματα πρόβλεψης μήνα τοκετού για καθένα από τα μοντέλα που εφαρμόστηκαν.

Πίνακας 11: Αποτελέσματα πρόβλεψης μήνα τοκετού

Metric/Model	Κατηγορία (μήνας τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
Random Forest	6ος-8ος	0.84	0.70	0.90	0.79
	9ος		0.93	0.85	0.89
	10ος		0.70	0.76	0.73
SVM	6ος-8ος	0.78	0.73	0.90	0.80
	9ος		0.90	0.77	0.83
	10ος		0.52	0.73	0.61
Logistic Regression	6ος-8ος	0.77	0.68	0.68	0.80
	9ος		0.96	0.96	0.81
	10ος		0.49	0.49	0.62
K-Nearest Neighbors	6ος-8ος	0.68	0.00	0.00	0.00
	9ος		0.68	1.00	0.81
	10ος		0.00	0.00	0.00
Decision Tree	6ος-8ος	0.75	0.62	0.64	0.63
	9ος		0.88	0.77	0.82
	10ος		0.50	0.76	0.60
Gradient Boosting	6ος-8ος	0.84	0.71	0.92	0.80
	9ος		0.94	0.83	0.88
	10ος		0.66	0.78	0.72
AdaBoost	6ος-8ος	0.78	0.71	0.90	0.80
	9ος		0.93	0.73	0.82
	10ος		0.50	0.84	0.63
XGBoost	6ος-8ος	0.86	0.72	0.92	0.81
	9ος		0.95	0.85	0.90
	10ος		0.71	0.81	0.76
Naïve Bayes	6ος-8ος	0.30	0.73	0.56	0.64
	9ος		0.62	0.09	0.16
	10ος		0.19	0.95	0.31
Bagging	6ος-8ος	0.81	0.68	0.87	0.76
	9ος		0.92	0.80	0.86
	10ος		0.60	0.78	0.68
Optimized Voting	6ος-8ος	0.82	0.70	0.95	0.80
	9ος		0.95	0.80	0.87

Metric/Model	Κατηγορία (μήνας τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
	10ος		0.61	0.81	0.70

Όπως φαίνεται στον παραπάνω πίνακα οι περισσότεροι αλγόριθμοι πέτυχαν ικανοποιητικά επίπεδα ακρίβειας και ισορροπημένων μετρικών στις κατηγορίες μήνα τοκετού, με τους XGBoost, Gradient Boosting και Random Forest να ξεχωρίζουν, παρουσιάζοντας υψηλή ακρίβεια (έως 0.86) και καλά επίπεδα F1-score σε όλες τις τάξεις. Ο SVM και ο Optimized Voting εμφάνισαν επίσης αξιόλογες επιδόσεις, ειδικά στον 6ο–8ο και 9ο μήνα, αν και υστέρησαν ελαφρώς στον 10ο. Αντίθετα, αλγόριθμοι όπως οι Naïve Bayes και K-Nearest Neighbors απέδωσαν σημαντικά χαμηλότερα, με ιδιαίτερη αδυναμία στην αναγνώριση του πρώιμου (6ος-8ος μήνας) και καθυστερημένου τοκετού (10ος μήνας). Η Logistic Regression και το AdaBoost κινήθηκαν σε ενδιάμεσες επιδόσεις, ενώ ο Bagging διατήρησε καλή συνολική ακρίβεια, ιδιαίτερα στον 9ο μήνα. Συνολικά, διαφαίνεται ότι οι ensemble μέθοδοι και τα ενισχυτικά μοντέλα υπερέχουν αφού επιτυγχάνουν υψηλά ποσοστά σωστής ταξινόμησης στις περισσότερες κατηγορίες.

Αντίστοιχα, στον Πίνακα 12 προβάλλονται τα αποτελέσματα πρόβλεψης μήνα τοκετού μετά την εφαρμογή της βελτιστοποίησης.

Πίνακας 12: Αποτελέσματα πρόβλεψης μήνα τοκετού μετά την βελτιστοποίηση

Metric/Model	Κατηγορία (μήνας τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
Random Forest	6ος-8ος	0.84	0.70	0.90	0.79
	9ος		0.92	0.85	0.88
	10ος		0.69	0.73	0.71
SVM	6ος-8ος	0.75	0.71	0.82	0.76
	9ος		0.85	0.77	0.81
	10ος		0.46	0.57	0.51
Logistic Regression	6ος-8ος	0.79	0.71	0.95	0.81
	9ος		0.95	0.74	0.83
	10ος		0.51	0.84	0.63
K-Nearest Neighbors	6ος-8ος	0.74	0.80	0.72	0.76
	9ος		0.86	0.74	0.80
	10ος		0.44	0.76	0.56
Decision Tree	6ος-8ος	0.75	0.62	0.64	0.63
	9ος		0.88	0.77	0.82
	10ος		0.50	0.76	0.60
Gradient Boosting	6ος-8ος	0.84	0.71	0.92	0.80
	9ος		0.93	0.84	0.88
	10ος		0.68	0.73	0.70

Metric/Model	Κατηγορία (μήνας τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
AdaBoost	6ος-8ος	0.84	0.70	0.90	0.79
	9ος		0.92	0.86	0.89
	10ος		0.72	0.70	0.71
XGBoost	6ος-8ος	0.83	0.71	0.92	0.80
	9ος		0.93	0.83	0.88
	10ος		0.65	0.76	0.70
Naïve Bayes	6ος-8ος	0.47	0.73	0.36	0.71
	9ος		0.74	0.76	0.48
	10ος		0.23	0.95	0.35
Bagging	6ος-8ος	0.82	0.67	0.85	0.75
	9ος		0.91	0.83	0.87
	10ος		0.66	0.73	0.69
Optimized Voting	6ος-8ος	0.77	0.67	0.97	0.79
	9ος		0.98	0.68	0.81
	10ος		0.51	0.95	0.66

Μετά τη βελτιστοποίηση των υπερπαραμέτρων μέσω Grid Search CV, παρατηρείται γενική βελτίωση ή σταθερότητα στις επιδόσεις των περισσότερων αλγορίθμων. Τα ensemble μοντέλα όπως τα AdaBoost, Gradient Boosting, XGBoost και Bagging διατήρησαν ή ενίσχυσαν τις επιδόσεις τους, επιτυγχάνοντας υψηλή ακρίβεια και F1-score, ιδιαίτερα στην πρόβλεψη κανονικού (9ος μήνας) τοκετού. Ο XGBoost και το AdaBoost σημείωσαν συνολικά τις καλύτερες επιδόσεις με εξαιρετική ισορροπία ανάμεσα στις κατηγορίες. Η Logistic Regression ενισχύθηκε σημαντικά στην πρόβλεψη του πρώιμου και καθυστερημένου τοκετού, ενώ ο K-Nearest Neighbors βελτιώθηκε εντυπωσιακά σε σχέση με πριν, φτάνοντας σε αξιοπρεπή αποτελέσματα σε όλες τις τάξεις. Ο SVM και ο Optimized Voting παρουσίασαν μικρές αυξομειώσεις. Αντίθετα, ο Naïve Bayes παρέμεινε σχετικά αδύναμος, ιδιαίτερα στον 10ο μήνα. Συμπερασματικά, η βελτιστοποίηση συνέβαλε στη σταθεροποίηση και ενίσχυση της γενίκευσης για τα πιο αποδοτικά μοντέλα, ενισχύοντας τη χρηστικότητά τους στην πρόβλεψη του μήνα τοκετού.

5.9.2 Πρόβλεψη εβδομάδας τοκετού σε διαστήματα δύο εβδομάδων

Σε αυτή την ενότητα επιχειρείται μία πιο λεπτομερής προσέγγιση στην πρόβλεψη του χρόνου τοκετού, με στόχο την κατηγοριοποίηση της εβδομάδας τοκετού (GA) σε διαστήματα διάρκειας δύο εβδομάδων. Η προσέγγιση αυτή επιδιώκει την αύξηση της ακρίβειας πρόβλεψης σε σχέση με την προηγούμενη ομαδοποίηση κατά μήνα τοκετού.

Η μεταβλητή στόχος δημιουργήθηκε με βάση τα αριθμητικά δεδομένα της GA, τα οποία κατανεμήθηκαν στις κατηγορίες (25–30, 31-32, 33-34, 35-36, 37-38, 39-40 και 41–42) (Εικόνα 44). Ο διαχωρισμός τροποποιήθηκε έτσι καθώς ο αριθμός των δειγμάτων σε ορισμένες κατηγορίες – εβδομάδες ήταν κατά πολύ περιορισμένος.

```python
# Δημιουργία κατηγορικής μεταβλητής με βάση την GA
def ga_bin_2weeks(ga):
    # Στρογγυλοποίηση προς τα κάτω και μετατροπή σε integer
    week = int(np.floor(ga))

    if 25 <= week <= 30:
        return '25-30'
    elif 31 <= week <= 32:
        return '31-32'
    elif 33 <= week <= 34:
        return '33-34'
    elif 35 <= week <= 36:
        return '35-36'
    elif 37 <= week <= 38:
        return '37-38'
    elif 39 <= week <= 40:
        return '39-40'
    elif 41 <= week <= 42:
        return '41-42'
    else:
        return 'εκτός ορίων'

# Καθαρισμός δεδομένων
df['GA'] = pd.to_numeric(df['GA'], errors='coerce')
df_clean = df.dropna(subset=['GA']).copy()
# Εφαρμογή της συνάρτησης ga_bin σε κάθε GA και αποθήκευση του αποτελέσματος στη νέα στήλη 'ga_bin'
df_clean['ga_bin'] = df_clean['GA'].apply(ga_bin_2weeks)
```

Εικόνα 44: Δημιουργία κατηγορικής μεταβλητής «ga_bin» βάσει της GA

Όπως και στην προηγούμενη ανάλυση, εφαρμόστηκε καθαρισμός δεδομένων, διαχωρισμός σε σύνολα εκπαίδευσης (70%) και ελέγχου (30%) με διατήρηση της κατανομής, καθώς και εξισορρόπηση τάξεων μέσω SMOTE, λόγω της αυξημένης ανισοκατανομής μεταξύ των ομάδων. Στη συνέχεια εφαρμόστηκαν οι ίδιοι ταξινομητές όπως στην ενότητα 5.9.1, ενώ πραγματοποιήθηκε και βελτιστοποίηση υπερπαραμέτρων με Grid Search για τη βελτίωση των αποτελεσμάτων.

Ο Πίνακας 13 περιέχει τα αποτελέσματα πρόβλεψης εβδομάδας τοκετού σε διαστήματα δύο εβδομάδων.

Πίνακας 13: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού σε διαστήματα δύο εβδομάδων

Metric/Model	Κατηγορία (εβδομάδα τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
Random Forest	25-30	0.73	0.67	0.67	0.67
	31-32		0.59	0.83	0.69
	33-34		0.40	0.18	0.25
	35-36		0.50	0.22	0.31
	37-38		0.71	0.74	0.73
	39-40		0.81	0.83	0.82
	41-42		0.00	0.00	0.00
SVM	25-30	0.59	0.00	0.00	0.00
	31-32		0.67	0.75	0.71

Metric/Model	Κατηγορία (εβδομάδα τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
	33-34		0.00	0.00	0.00
	35-36		0.15	0.22	0.18
	37-38		0.62	0.54	0.58
	39-40		0.68	0.70	0.69
	41-42		0.08	0.25	0.12
Logistic Regression	25-30	0.55	0.60	1.00	0.75
	31-32		0.57	0.50	0.53
	33-34		0.20	0.18	0.19
	35-36		0.11	0.22	0.15
	37-38		0.58	0.55	0.57
	39-40		0.73	0.62	0.67
	41-42		0.11	0.50	0.18
K-Nearest Neighbors	25-30	0.57	0.00	0.00	0.00
	31-32		0.00	0.00	0.00
	33-34		0.05	1.00	0.09
	35-36		0.00	0.00	0.00
	37-38		0.00	0.00	0.00
	39-40		0.00	0.00	0.00
	41-42		0.00	0.00	0.00
Decision Tree	25-30	0.60	0.33	0.33	0.33
	31-32		0.52	0.62	0.57
	33-34		0.15	0.18	0.17
	35-36		0.14	0.11	0.12
	37-38		0.59	0.54	0.56
	39-40		0.71	0.73	0.72
	41-42		0.00	0.00	0.00
Gradient Boosting	25-30	0.74	0.67	0.67	0.67
	31-32		0.65	0.71	0.68
	33-34		0.33	0.18	0.24
	35-36		0.00	0.00	0.00
	37-38		0.72	0.80	0.76
	39-40		0.82	0.85	0.84
	41-42		0.00	0.00	0.00
AdaBoost	25-30	0.48	0.40	0.67	0.50
	31-32		0.57	0.50	0.53
	33-34		0.60	0.27	0.38
	35-36		0.17	0.33	0.22
	37-38		0.47	0.51	0.49
	39-40		0.67	0.50	0.58
	41-42		0.00	0.00	0.00
XGBoost	25-30	0.76	0.67	0.67	0.67
	31-32		0.67	0.83	0.74
	33-34		0.27	0.27	0.27
	35-36		0.25	0.11	0.15
	37-38		0.77	0.80	0.78

Metric/Model	Κατηγορία (εβδομάδα τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
	39-40		0.86	0.85	0.86
	41-42		0.00	0.00	0.00
Naïve Bayes	25-30	0.16	0.06	0.67	0.10
	31-32		0.71	0.21	0.32
	33-34		0.18	0.18	0.18
	35-36		0.05	0.67	0.10
	37-38		0.29	0.03	0.05
	39-40		0.67	0.16	0.25
	41-42		0.11	1.00	0.19
Bagging	25-30	0.70	0.50	0.67	0.57
	31-32		0.61	0.58	0.60
	33-34		0.30	0.55	0.39
	35-36		0.43	0.33	0.38
	37-38		0.72	0.73	0.72
	39-40		0.82	0.78	0.80
	41-42		0.00	0.00	0.00
Optimized Voting	25-30	0.74	0.67	0.67	0.67
	31-32		0.63	0.79	0.70
	33-34		0.09	0.09	0.09
	35-36		0.25	0.11	0.15
	37-38		0.74	0.81	0.77
	39-40		0.86	0.83	0.84
	41-42		0.00	0.00	0.00

Από τον πίνακα, παρατηρείται ότι οι Random Forest, Gradient Boosting, XGBoost και Optimized Voting παρουσιάζουν τις καλύτερες επιδόσεις συνολικά, ιδιαίτερα στις κατηγορίες 37–38 και 39–40 εβδομάδες, με υψηλά ποσοστά Accuracy, Recall και F1-score. Οι SVM και Logistic Regression εμφάνισαν μέτρια απόδοση σε ορισμένες κατηγορίες (ιδίως 31–32 και 39–40), αλλά αποτυγχάνουν πλήρως σε άλλες όπως οι 33–34 και 41–42 εβδομάδες. Το Decision Tree και ο Bagging είχαν σταθερή αλλά μέτρια απόδοση, ενώ ο K-Nearest Neighbors απέτυχε πλήρως, προβλέποντας ελάχιστα σωστά ή και καθόλου σε πολλές κατηγορίες. Ο Naïve Bayes παρουσίασε πολύ χαμηλές επιδόσεις, με αστοχία στις περισσότερες κατηγορίες, παρά κάποιες μεμονωμένες περιπτώσεις υψηλού Recall. Συνολικά, οι ensemble μέθοδοι υπερέχουν, και σε αυτή την προσέγγιση πρόβλεψης.

Ο Πίνακας 14 αντίστοιχα, περιλαμβάνει τα αποτελέσματα πρόβλεψης εβδομάδας τοκετού σε διαστήματα δύο εβδομάδων όπως αυτά προέκυψαν μετά την βελτιστοποίηση.

Πίνακας 14: Αποτελέσματα πρόβλεψης εβδομάδας τοκετού σε διαστήματα δύο εβδομάδων μετά την βελτιστοποίηση

Metric/Model	Κατηγορία (εβδομάδα τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
Random Forest	25-30	0.72	0.67	0.67	0.67
	31-32		0.56	0.79	0.66
	33-34		0.29	0.18	0.22
	35-36		0.33	0.11	0.17
	37-38		0.74	0.70	0.72
	39-40		0.80	0.85	0.82
	41-42		0.00	0.00	0.00
SVM	25-30	0.63	0.00	0.00	0.00
	31-32		0.60	0.62	0.61
	33-34		0.00	0.00	0.00
	35-36		0.20	0.22	0.21
	37-38		0.62	0.61	0.62
	39-40		0.74	0.77	0.75
	41-42		0.20	0.25	0.22
Logistic Regression	25-30	0.59	0.50	1.00	0.67
	31-32		0.59	0.54	0.57
	33-34		0.22	0.18	0.20
	35-36		0.15	0.33	0.21
	37-38		0.60	0.55	0.58
	39-40		0.79	0.67	0.72
	41-42		0.12	0.50	0.19
K-Nearest Neighbors	25-30	0.57	0.00	0.00	0.00
	31-32		0.45	0.38	0.41
	33-34		0.12	0.09	0.11
	35-36		0.17	0.11	0.13
	37-38		0.52	0.54	0.53
	39-40		0.71	0.73	0.72
	41-42		0.12	0.25	0.17
Decision Tree	25-30	0.60	0.33	0.33	0.33
	31-32		0.52	0.62	0.57
	33-34		0.15	0.18	0.17
	35-36		0.14	0.11	0.12
	37-38		0.59	0.54	0.56
	39-40		0.71	0.73	0.72
	41-42		0.00	0.00	0.00
Gradient Boosting	25-30	0.76	0.67	0.67	0.67
	31-32		0.64	0.75	0.69
	33-34		0.17	0.09	0.12
	35-36		0.00	0.00	0.00
	37-38		0.76	0.80	0.78
	39-40		0.83	0.89	0.86
	41-42		0.00	0.00	0.00
AdaBoost	25-30	0.71	0.67	0.67	0.67

Metric/Model	Κατηγορία (εβδομάδα τοκετού)	Accuracy	Precision macro	Recall macro	F1 macro
	31-32		0.68	0.79	0.73
	33-34		0.25	0.18	0.21
	35-36		0.20	0.11	0.14
	37-38		0.66	0.77	0.71
	39-40		0.82	0.78	0.80
	41-42		0.00	0.00	0.00
XGBoost	25-30		0.67	0.67	0.67
	31-32		0.62	0.83	0.71
	33-34		0.27	0.27	0.27
	35-36	0.75	0.00	0.00	0.00
	37-38		0.77	0.78	0.78
	39-40		0.84	0.85	0.84
	41-42		0.00	0.00	0.00
Naïve Bayes	25-30		0.50	0.67	0.57
	31-32	0.53	0.65	0.46	0.54
	33-34		0.25	0.18	0.21
	35-36		0.13	0.33	0.19
	37-38		0.59	0.31	0.41
	39-40		0.73	0.71	0.72
	41-42		0.08	0.75	0.15
Bagging	25-30		0.50	0.67	0.57
	31-32		0.55	0.71	0.62
	33-34		0.30	0.27	0.29
	35-36	0.75	0.50	0.22	0.31
	37-38		0.77	0.77	0.77
	39-40		0.84	0.85	0.84
	41-42		0.00	0.00	0.00
Optimized Voting	25-30		0.50	0.67	0.57
	31-32		0.60	0.75	0.67
	33-34		0.17	0.18	0.17
	35-36	0.68	0.20	0.11	0.14
	37-38		0.62	0.82	0.71
	39-40		0.87	0.69	0.77
	41-42		0.00	0.00	0.00

Η βελτιστοποίηση των μοντέλων βελτίωσε την απόδοση ορισμένων αλγορίθμων, χωρίς όμως να εξαλείψει τις προκλήσεις σε δύσκολες κατηγορίες όπως οι 33–36 και 41–42 εβδομάδες. Οι Gradient Boosting, XGBoost και Bagging εξακολουθούν να παρουσιάζουν τις καλύτερες επιδόσεις συνολικά, ειδικά στις κύριες κατηγορίες τοκετού (37–38 και 39–40 εβδομάδες), με τις υψηλότερες τιμές Accuracy και F1-score. Οι Random Forest και AdaBoost διατήρησαν αξιοπρεπή ακρίβεια στις περισσότερες κατηγορίες, ενώ οι Logistic Regression και SVM εμφάνισαν μέτρια βελτίωση, με καλύτερες επιδόσεις σε κατηγορίες με περισσότερα δείγματα. Οι K-Nearest Neighbors και Naïve Bayes παρέμειναν αδύναμοι, παρότι εμφανίζουν

κάποιες μεμονωμένες θετικές επιδόσεις. Το Optimized Voting μοντέλο διατήρησε σταθερή απόδοση σε βασικές κατηγορίες, αλλά υστέρησε σημαντικά στις υπόλοιπες. Συνολικά, οι ensemble και boosting μέθοδοι ενισχυμένες με βελτιστοποίηση παραμένουν η πιο αξιόπιστη επιλογή για την πρόβλεψη εβδομάδας τοκετού.

ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ

ΣΥΜΠΕΡΑΣΜΑΤΑ

Η παρούσα εργασία είχε ως απώτερο σκοπό την πρόβλεψη της εβδομάδας κύησης που θα λάβει χώρα ο τοκετός μίας εγκύου γυναίκας. Μία τέτοια πρόβλεψη είναι ιδιαίτερα κρίσιμη σε περιπτώσεις πρόωρου τοκετού όπου κατάλληλη φαρμακευτική αγωγή πρέπει να δοθεί εγκαίρως για να αποτραπεί αυτή η εξέλιξη. Μάλιστα, η δυνατότητα πρόβλεψης της εβδομάδας τοκετού είναι ιδιαίτερα χρήσιμη για γυναίκες που ζουν σε απομακρυσμένες περιοχές και δεν έχουν άμεση πρόσβαση σε νοσοκομειακές μονάδες. Για την υλοποίηση της πρόβλεψης εφαρμόστηκαν αλγόριθμοι μηχανικής μάθησης με διαφορετικές προσεγγίσεις και μοντελοποιήσεις ώστε να επιτευχθεί η μέγιστη ακρίβεια.

Κατά την διαδικασία της πρόβλεψης χρησιμοποιήθηκε υπάρχον σύνολο δεδομένων που περιλαμβάνει παραμέτρους σχετικές με ελάχιστα δημογραφικά στοιχεία και πολλές εργαστηριακές και κλινικές εξετάσεις. Πρόκειται για το ίδιο σύνολο δεδομένων με εκείνο της μελέτης των Kyparissidis-Kokkinidis κ.ά. [5]. Η μελέτη αυτή επίσης εξέταζε το πρόβλημα της πρόβλεψης του πρόωρου τοκετού.

Στην παρούσα εργασία όμως, αυτό το σύνολο δεδομένων υπέστη μία επεξεργασία, καθώς έπειτα από μελέτη αποδείχθηκε ότι περιείχε μία προκατάληψη ως προς την δειγματοληψία του (sampling bias). Το νέο σύνολο δεδομένων που δημιουργήθηκε περιείχε μικρότερο αριθμό δειγμάτων αλλά τις ίδιες παραμέτρους.

Μετά την απαραίτητη επεξεργασία του αρχικού συνόλου δεδομένων και την δημιουργία του νέου, ακολούθησε μία σειρά αναλύσεων με στόχο την διερεύνηση της δυνατότητας πρόβλεψης του χρόνου τοκετού.

Αρχικά, επιχειρήθηκε η δυαδική πρόβλεψη πρόωρου ή τελειόμηνου τοκετού, με την χρήση των αλγορίθμων Random Forest, SVM, Logistic Regression, KNN, Decision Tree, Gradient Boosting, XGBoost, AdaBoost, Naïve Bayes, Bagging και Optimized Voting. Τα αποτελέσματα ήταν πολύ ικανοποιητικά όπως φανερώθηκε από τις τιμές στις μετρικές που αξιοποιήθηκαν (Accuracy, Precision, Recall, F1-score). Συγκεκριμένα ο Optimized Voting πέτυχε τις καλύτερες αποδόσεις σε όλες τις μετρικές (Accuracy: 0.96, Precision: 0.85, Recall: 0.98, F1: 0.91). Επιπλέον, πραγματοποιήθηκε έλεγχος στατιστικής σημαντικότητας των αποτελεσμάτων της παρούσας μελέτης σε σύγκριση με εκείνα της μελέτης των Kyparissidis-Kokkinidis κ.ά., όπου διαπιστώθηκε σημαντική βελτίωση στις περισσότερες κρίσιμες μετρικές και θετική μεταβολή στην πλειοψηφία των ταξινομητών. Αυτό το γεγονός επιβεβαίωσε την αποτελεσματικότητα της διαδικασίας προεπεξεργασίας και της δημιουργίας του νέου συνόλου δεδομένων.

Στη συνέχεια, η ανάλυση μετατράπηκε σε πρόβλημα παλινδρόμησης, καθώς προβλεπόταν συγκεκριμένα η τιμή της μεταβλητής GA (εβδομάδα τοκετού) που ήταν πραγματική. Έτσι εφαρμόστηκαν οι αλγόριθμοι Random Forest Regressor, SVR, Linear Regression, K-Neighbors Regressor, Decision Tree Regressor, Gradient Boosting Regressor, XGBoost Regressor, AdaBoost Regressor, Bagging Regressor και Voting Regressor. Οι νέες μετρικές αξιολόγησης των αποτελεσμάτων ήταν οι R^2

score, MAE, MSE και RMSE. Τα αποτελέσματα έδειξαν ότι ο Bagging Regressor πέτυχε την καλύτερη απόδοση (R^2 score: 0.74, MAE: 0.91, MSE: 1.87, RMSE: 1.36).

Προκειμένου να βελτιωθούν τα αποτελέσματα και στους υπόλοιπους αλγορίθμους, το πρόβλημα προσεγγίστηκε ως πολυταξινόμηση, αφού η μεταβλητή GA μετατράπηκε σε ακέραια. Η εν λόγω στρογγυλοποίηση ωστόσο, επέφερε μικρές διαφοροποιήσεις στην απόδοση των μοντέλων. Έπειτα από σύγκριση διαπιστώθηκε ότι κάποιοι αλγόριθμοι διατήρησαν σταθερή απόδοση στην ακρίβεια της πρόβλεψης, ενώ αρκετοί μείωσαν την ακρίβειά τους. Την καλύτερη απόδοση πέτυχε ο Random Forest Regressor (R^2 score: 0.74, MAE: 0.85, MSE: 2.02, RMSE: 1.42) που είχε και προηγουμένως παρόμοια συμπεριφορά.

Ακολούθησε η πρόβλεψη του μήνα τοκετού, η οποία παρείχε μία πιο απλοποιημένη κατηγοριοποίηση. Αν και ο αριθμός κατηγοριών ήταν μικρότερος, οι αλγόριθμοι δεν κατάφεραν να επιτύχουν υψηλή ακρίβεια – πιθανώς λόγω της έντονης ανισορροπίας στον αριθμό δειγμάτων των κατηγοριών. Η κατηγορία του κανονικού – τελειόμηνου τοκετού ($9^{ος}$ μήνας) είχε τις καλύτερες και πιο σταθερές αποδόσεις, ακολουθεί ο πρόωρος τοκετός ($6^{ος}$-$8^{ος}$ μήνας) και πιο δύσκολος στην πρόβλεψη αποδείχθηκε ο καθυστερημένος τοκετός ($10^{ος}$ μήνας). Ο αλγόριθμος XGBoost είχε την καλύτερη απόδοση συγκριτικά με τους υπόλοιπους για κάθε κατηγορία.

Η τελευταία προσέγγιση, η ομαδοποίηση σε διαστήματα δύο εβδομάδων, αποδείχθηκε αρκετά αποδοτική για την πρόβλεψη ιδίως των κατηγοριών 37-38 και 39-40 εβδομάδες. Οι χειρότερες αποδόσεις σημειώθηκαν στις κατηγορίες 41-42 και 33-36 εβδομάδες. Το γεγονός αυτό επίσης οφείλεται στην ανισοκατανομή των δειγμάτων στις επιμέρους κατηγορίες. Ο XGBoost πέτυχε τις καλύτερες αποδόσεις και σε αυτή την προσέγγιση.

Συμπερασματικά, μετά από την ανάλυση και προσέγγιση της πρόβλεψης του πρόωρου τοκετού από διαφορετικές σκοπιές, αποδείχθηκε ότι η επιλογή του κατάλληλου αλγορίθμου και η σωστή αναπαράσταση των δεδομένων είναι καθοριστικοί παράγοντες στην επίτευξη υψηλής ακρίβειας.

Μάλιστα προέκυψε και το συμπέρασμα ότι τα συνδυαστικά μοντέλα (Random Forest, XGBoost, Bagging, Optimized Voting) σε κάθε περίπτωση παρουσιάζουν την μέγιστη ή σταθερά καλή απόδοση συγκριτικά με τα υπόλοιπα απλά μοντέλα που μελετήθηκαν σε αυτή την εργασία. Αυτό επιβεβαιώνει και την ικανότητα των συνδυαστικών (ensemble) μοντέλων να αξιοποιούν τα πλεονεκτήματα των επιμέρους αλγορίθμων που χρησιμοποιούν ώστε να επιτύχουν την μέγιστη ακρίβεια στους υπολογισμούς τους.

Παρά τα παραπάνω αισιόδοξα αποτελέσματα, ορισμένα βασικά προβλήματα όπως η ανισορροπία στο σύνολο δεδομένων και η έλλειψη αρκετών δειγμάτων από συγκεκριμένες ακραίες (π.χ. υπερβολικά πρόωρος ή καθυστερημένος τοκετός) παραμένουν. Ακόμη, ένας παράγοντας για την πρόβλεψη του πρόωρου τοκετού, που απουσιάζει από την παρούσα μελέτη, είναι τα δεδομένα από όλα τα στάδια της κύησης.

ΚΕΦΑΛΑΙΟ 7: ΕΠΙΛΟΓΟΣ ΚΑΙ ΜΕΛΛΟΝΤΙΚΗ ΔΟΥΛΕΙΑ

ΕΠΙΛΟΓΟΣ ΚΑΙ ΜΕΛΛΟΝΤΙΚΗ ΔΟΥΛΕΙΑ

Η εργασία αυτή ανέδειξε τη δυνατότητα εφαρμογής τεχνικών μηχανικής μάθησης για την πρόβλεψη του χρόνου τοκετού και συγκεκριμένα του πρόωρου. Μέσα από διαφορετικές προσεγγίσεις πρόβλεψης (δυαδική ταξινόμηση, παλινδρόμηση, πολυταξινόμηση και κατηγοριοποίηση σε εβδομαδιαία διαστήματα), αξιολογήθηκε η ακρίβεια της πρόβλεψης.

Τα αποτελέσματα που περιγράφονται αναλυτικά στο Κεφάλαιο 6, ήταν πολύ αισιόδοξα και έδειξαν ότι τα συνδυαστικά (ensemble) μοντέλα υπερτερούν ως προς την ακρίβεια αλλά και τη σταθερότητα των προβλέψεων στις διάφορες προσεγγίσεις που εφαρμόστηκαν. Η αναγνώριση και διόρθωση του sampling bias στο αρχικό dataset, καθώς και η δημιουργία ενός ισορροπημένου συνόλου δεδομένων, συνέβαλαν σημαντικά στη βελτίωση των αποτελεσμάτων, αποδεικνύοντας τη σημασία της προσεκτικής προεπεξεργασίας.

Διαπιστώθηκε επίσης, ότι ορισμένα βασικά προβλήματα όπως η ανισορροπία στο σύνολο δεδομένων και η έλλειψη αρκετών δειγμάτων από συγκεκριμένες ακραίες κατηγορίες (π.χ. υπερβολικά πρόωρος ή καθυστερημένος τοκετός) παραμένουν παρά την απαλοιφή της προκατάληψης. Ακόμη, ένας παράγοντας για την πρόβλεψη του πρόωρου τοκετού, που απουσιάζει από την παρούσα μελέτη, είναι τα δεδομένα από όλα τα στάδια της κύησης για μία πιο ολοκληρωμένη εικόνα της πορείας της εγκυμοσύνης.

Εν κατακλείδι, η εργασία απέδειξε ότι η μηχανική μάθηση μπορεί να αποτελέσει ένα πολύτιμο εργαλείο στον τομέα της προγεννητικής φροντίδας, αρκεί να ενισχυθεί με αρκετά και ποιοτικά δεδομένα, ισορροπία και κατάλληλες τεχνικές ερμηνείας. Για αυτό και προτείνεται ως μελλοντική εργασία η συλλογή και ενσωμάτωση περισσότερων και ποιοτικότερων χαρακτηριστικών (ιατρικές εξετάσεις, οικογενειακό ιστορικό, εξελίξεις κατά τη διάρκεια της κύησης) καθώς και η ενσωμάτωση ερμηνευτικών εργαλείων (όπως SHAP), για μεγαλύτερη διαφάνεια στα αποτελέσματα.

ΠΑΡΑΡΤΗΜΑ Ι: ΑΝΑΦΟΡΕΣ

ΒΙΒΛΙΟΓΡΑΦΙΑ

[1] Vogel, J. P., Chawanpaiboon, S., Moller, A. B., Watananirun, K., Bonet, M., & Lumbiganon, P. (2018). The global epidemiology of preterm birth. *Best practice & research Clinical obstetrics & gynaecology*, *52*, 3-12.

[2] Behrman, R. E., & Butler, A. S. (2007). Preterm birth: causes, consequences, and prevention.

[3] El Naqa, I., & Murphy, M. J. (2015). What is machine learning?. In *Machine learning in radiation oncology: theory and applications* (pp. 3-11). Cham: Springer International Publishing.

[4] Ramchurn, S. D., Stein, S., & Jennings, N. R. (2021). Trustworthy human-AI partnerships. *Iscience*, *24*(8).

[5] Kyparissidis-Kokkinidis, I., Rigas, E. S., Logaras, E., Tsakiridis, I., Dagklis, T., Lagakis, P., ... & Bamidis, P. D. An Explainable AI-Based Decision Support Tool to Predict Preterm Birth. In *IEEE-EMBS International Conference on Biomedical and Health Informatics*.

[6] Vovsha, I., Rajan, A., Salleb-Aouissi, A., Raja, A., Radeva, A., Diab, H., ... & Wapner, R. (2014, March). Predicting preterm birth is not elusive: Machine learning paves the way to individual wellness. In *2014 AAAI Spring Symposium Series*.

[7] Begum, M., Redoy, R. M., & Anty, A. D. (2021, February). Preterm baby birth prediction using machine learning techniques. In *2021 International Conference on Information and Communication Technology for Sustainable Development (ICICT4SD)* (pp. 50-54). IEEE.

[8] Koivu, A., & Sairanen, M. (2020). Predicting risk of stillbirth and preterm pregnancies with machine learning. *Health information science and systems*, *8*(1), 14.

[9] AlSaad, R., Malluhi, Q., & Boughorbel, S. (2022). PredictPTB: an interpretable preterm birth prediction model using attention-based recurrent neural networks. *BioData Mining*, *15*(1), 6.

[10] Zhang, Y., Du, S., Hu, T., Xu, S., Lu, H., Xu, C., ... & Zhu, X. (2023). Establishment of a model for predicting preterm birth based on the machine learning algorithm. *BMC Pregnancy and Childbirth*, *23*(1), 779.

[11] Watson, H. A., Carter, J., Seed, P. T., Tribe, R. M., & Shennan, A. H. (2017). The QUiPP App: a safe alternative to a treat-all strategy for threatened preterm labor. *Ultrasound in Obstetrics & Gynecology*, *50*(3), 342-346.

[12] Moreira, M. W., Rodrigues, J. J., Marcondes, G. A., Neto, A. J. V., Kumar, N., & Diez, I. D. L. T. (2018, May). A preterm birth risk prediction system for mobile health applications based on the support vector machine algorithm. In *2018 IEEE International Conference on Communications (ICC)* (pp. 1-5). IEEE.

[13] Grzymala-Busse, J. W., & Woolery, L. K. (1994). Improving prediction of preterm birth using a new classification scheme and rule induction. In *Proceedings of the Annual Symposium on Computer Application in Medical Care* (p. 730). American Medical Informatics Association.

[14] Despotović, D., Zec, A., Mladenović, K., Radin, N., & Turukalo, T. L. (2018, September). A machine learning approach for an early prediction of preterm delivery. In *2018 IEEE 16th International Symposium on Intelligent Systems and Informatics (SISY)* (pp. 000265-000270). IEEE.

[15] Narmadha, P., Indhuja, S. U., Bhavadharani, V., & Helen, R. (2024, April). Preterm Birth Prediction using Machine Learning. In *2024 International Conference on Inventive Computation Technologies (ICICT)* (pp. 1-6). IEEE.

[16] Mahoney, T., Varshney, K., & Hind, M. (2020). *AI fairness*. O'Reilly Media, Incorporated.

[17] Nazer, L. H., Zatarah, R., Waldrip, S., Ke, J. X. C., Moukheiber, M., Khanna, A. K., ... & Mathur, P. (2023). Bias in artificial intelligence algorithms and recommendations for mitigation. *PLOS digital health*, *2*(6), e0000278.

[18] Feldman, M., Friedler, S. A., Moeller, J., Scheidegger, C., & Venkatasubramanian, S. (2015, August). Certifying and removing disparate impact. In *proceedings of the 21th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 259-268).

[19] Besse, P., del Barrio, E., Gordaliza, P., Loubes, J. M., & Risser, L. (2022). A survey of bias in machine learning through the prism of statistical parity. *The American Statistician*, *76*(2), 188-198.

[20] Vujović, Ž. (2021). Classification model evaluation metrics. *International Journal of Advanced Computer Science and Applications*, *12*(6), 599-606.

[21] Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine learning research, 7(Jan), 1-30.

[22] Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: context, process, and purpose. *The American Statistician*, *70*(2), 129-133.

[23] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, *21*(9), 1263-1284.

[24] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PloS one*, *10*(3), e0118432.

[25] Botchkarev, A. (2018). Performance metrics (error measures) in machine learning regression, forecasting and prognostics: Properties and typology. *arXiv preprint arXiv:1809.03006*.